

港澳台侨及海外留学生硕士学位论文

题名：基于先验本体约束与双空间表示学习的 APT 组织攻击偏好预测方法

Title: A Method for APT Organization Attack Preference Prediction Based on Prior Ontology Constraints and Dual-Space Representation Learning

作者姓名：李之聿（中国台湾）

指导教师姓名及学位、职称：孙玉霞 副教授

学科、专业名称：电子信息（计算机技术）

学位类型：专业学位

论文提交时间：2026 年 5 月

论文答辩时间：2026 年 6 月

答辩委员会主席：蒋运承 教授

论文评阅人：

学位授予单位和日期：暨南大学 2026 年 6 月

独创性声明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得 暨南大学 或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

学位论文作者签名：

李之丰

签字日期：2026年6月19日

学位论文版权使用授权书

本学位论文作者完全了解 暨南大学 有关保留、使用学位论文的规定，有权保留并向国家有关部门或机构送交论文的复印件和磁盘，允许论文被查阅和借阅。本人授权 暨南大学 可以将学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。

(保密的学位论文在解密后适用本授权书)

学位论文作者签名：

李之丰

签字日期：2026年6月14日

学位论文作者毕业后去向：国内就业

工作单位：诺亚方舟

通讯地址：广东省广州市天河区

导师签名：

孙玉霞

签字日期：2026年6月19日

电话：13232255759

邮编：510630

摘 要

高级持续性威胁（APT）攻击具有隐蔽性强、攻击周期长等特点，对其攻击偏好进行准确预测具有重要意义。现有威胁情报构建的 APT 知识图谱往往存在严重的数据稀疏问题；同时，主流知识图谱表示学习多在欧式空间中进行，在面对 APT 固有的“组织 → 战役 → 工具 → 变种”层级结构时，极易产生几何拥挤效应，导致底层节点表示退化。针对上述挑战，本文提出一种由数据层层级本体重构与模型层欧式——双曲两阶段表示学习共同组成的 APT 组织攻击偏好预测方法。

在数据重构阶段，本文利用大语言模型进行高层语义归纳，构建 7 个高层抽象节点本体框架，形成面向双曲空间的层级化本体。为规避开放域生成的事实幻觉风险，本文将大语言模型限定于高层语义归纳与本体框架设计，底层实体与高层节点间的 `subClassOf` 层级关系则通过人工校验的确定性规则字典注入，从而在提升语义表达能力的同时保证图谱结构的可靠性。重构后，图谱的 Gromov δ 值由 0.2566 降至 0.1957，表明数据的层级拓扑特性有所改善，为后续非欧几何建模提供了结构基础。

在表示学习阶段，本文构建了“欧式——双曲”两阶段建模框架。第一阶段，结合领域预训练语言模型与图神经网络，在欧式空间中捕获实体的局部语义与邻域结构特征，获得较稳定的初始表示；第二阶段，通过指数映射将欧式嵌入平滑投影至庞加莱球，在双曲空间中利用测地线距离进行全局层级结构的微调，从而缓解欧式空间的几何容量瓶颈。

在针对 APT 攻击偏好预测任务的系统评估中，本文进一步构建了面向层级结构的 APT 知识图谱数据集 APT-Hier，并在本文采用的任务驱动单向严格过滤评估协议下开展系统评估。实验结果表明，在 APT-Hier 攻击偏好预测任务中，完整方法在 Hits@10、Hits@3、Hits@1 和 MRR 等前列排序指标上取得较优表现，说明层级本体重构与欧式——双曲两阶段表示学习能够提升模型对核心攻击偏好关系的候选排序能力。需要指出的是，模型优势主要体现在前列召回与高位排序质量上，而非所有排名指标均取得最优。进一步消融实验表明，在当前实验设置下，层级本体重构、欧式语义迁移与双曲空间建模对模型性能具有不同程度的支持作用，相关组件之间呈现出一定协同依赖关系。

关键词：高级持续性威胁；知识图谱；先验本体约束；攻击偏好预测；双空间表示学习；双曲表示学习

Abstract

Advanced Persistent Threat (APT) attacks are characterized by strong concealment and prolonged attack cycles. Accurately predicting their attack preferences holds practical significance for proactive cyber defense. APT knowledge graphs constructed from existing threat intelligence suffer from severe data sparsity. Meanwhile, mainstream knowledge graph representation learning operates predominantly in Euclidean space. The inherent "organization $\rightarrow$ campaign $\rightarrow$ tool $\rightarrow$ variant" hierarchy of APT graphs tends to produce geometric crowding effects. This causes degradation of leaf-node representations and limits prediction accuracy. To address these challenges, this thesis proposes an APT attack preference prediction method consisting of a data-level hierarchical ontology reconstruction module and a model-level Euclidean–hyperbolic two-stage representation learning module.

In the data reconstruction phase, an LLM abstracts the original 21 fine-grained entity labels into 7 high-level abstract nodes. This forms a hierarchical ontology oriented toward hyperbolic space embedding. To mitigate factual hallucination from open-domain generation, this paper restricts large language models to high-level semantic induction and ontology design. The sub-ClassOf hierarchy between low-level entities and high-level nodes is injected through a manually verified deterministic rule dictionary, thereby enhancing semantic expressiveness while preserving the structural reliability of the knowledge graph.

In the representation learning phase, a Euclidean–hyperbolic two-stage framework is constructed. In the first stage, a domain-pretrained language model combined with a graph neural network captures local semantic and neighborhood structural features. This yields relatively stable initial representations in Euclidean space. In the second stage, Euclidean embeddings are projected onto the Poincaré Ball via exponential mapping. Geodesic distances in hyperbolic space are then employed to refine the global hierarchical structure. This alleviates the geometric capacity bottleneck inherent to Euclidean space.

This paper further constructs APT-Hier, a hierarchically restructured APT knowledge graph dataset, as a data-level contribution. Under the task-specific unidirectional strict-filtered evaluation protocol adopted in this thesis, the complete framework achieves competitive performance

on leading ranking-oriented metrics, including Hits@10, Hits@3, Hits@1, and MRR, in the APT-Hier attack preference prediction task. These results suggest that hierarchical ontology reconstruction and Euclidean-hyperbolic two-stage representation learning can improve the candidate ranking quality of core attack preference relations. It should be noted that the observed advantage mainly lies in top-ranked retrieval and high-position ranking quality, rather than in uniformly optimal performance across all ranking metrics.

Further ablation studies show that, under the current experimental setting, hierarchical ontology reconstruction, Euclidean semantic transfer, and hyperbolic modeling provide different degrees of support to model performance, and that these components exhibit a certain synergistic dependency.

Key Words: Advanced Persistent Threat; Knowledge Graph; Prior Ontology Constraints; Attack Preference Prediction; Dual-Space Representation Learning; Hyperbolic Representation Learning

目 录

摘要	I
Abstract.....	II
1 绪论	1
1.1 研究背景与意义	1
1.2 研究现状与问题分析	3
1.3 本文研究问题	5
1.4 主要研究内容与创新点	5
1.5 论文结构	7
2 基础知识	8
2.1 知识图谱表示学习与预测任务	8
2.2 图神经网络与图拓扑重构	10
2.3 双曲空间表示学习	11
2.4 大语言模型与知识图谱增强	13
2.5 本章小结	14
3 基于先验本体约束与双空间表示学习的攻击偏好预测模型	16
3.1 任务定义与多维特征空间建模	16
3.2 方法框架	18
3.3 基于 LLM 辅助语义归纳与确定性规则注入的层级本体构建	19
3.4 两阶段欧式——双曲表示学习框架	29
3.5 本章小结	38
4 实验与结果分析	40
4.1 实验设置	40
4.2 对比基线模型	45
4.3 整体性能对比	48
4.4 核心组件有效性与协同分析	52
4.5 双曲空间中的实体径向分布与语义解释	54
4.6 层级约束注入规模敏感性分析	55

4.7 本章小结	57
5 总结与展望	58
5.1 本文工作总结	58
5.2 研究局限性	59
5.3 未来研究展望	60
附录	62
A.1 LLM 辅助高层语义归纳的预研验证	62
参考文献	65
在学期间发表论文的清单	71
致谢	72

图目录

图 1-1	2024 年 APT 活动攻击目标行业分布	1
图 3-1	整体方法框架图	19
图 3-2	实体语义相似度热力图	22
图 3-3	基于 CyBERT 特征的层次聚类树状图	22
图 3-4	APT-Hier 中层级拓扑重构演化对比示意图	27
图 3-5	拓扑演化对比图	28
图 3-6	Poincaré Ball 中实体层级分布示意图	33
图 4-1	各关系类型的三元组数量分布	40
图 4-2	不同偏好关系在庞加莱球中的径向距离分布	55

表目录

表 3-1	APT 知识图谱实体类型与数量统计.....	20
表 3-2	基于双重权威框架的 LLM 聚类结果交叉验证	23
表 3-3	高层抽象节点在双曲空间中的层级映射设计	24
表 3-4	各版本数据集规模统计	27
表 3-5	数据集几何拓扑度量结果对比（含通用拓扑参考）	28
表 4-1	实验数据集基础统计信息	41
表 4-2	APT-Hier 数据集划分详情.....	42
表 4-3	实验环境配置	44
表 4-4	APT-Flat 数据集上的通用链接预测结果对比	49
表 4-5	APT-Hier 数据集上的通用链接预测结果对比	49
表 4-6	APT-Flat 数据集上的攻击偏好预测结果对比	50
表 4-7	APT-Hier 数据集上的攻击偏好预测结果对比	50
表 4-8	核心模型多随机种子稳定性验证结果	52
表 4-9	核心组件协同分析与消融实验结果	53
表 4-10	层级约束注入规模敏感性实验结果.....	56
表 A-1	预研验证：典型多角色实体在不同三元组语境下的消歧测试.....	63
表 A-2	高层抽象节点语义一致性验证结果	63
表 A-3	高层抽象节点语境级验证样本分布	64
表 A-4	高层抽象节点映射中的典型语义歧义案例	64

1 绪论

1.1 研究背景与意义

随着信息基础设施的持续扩张与数字化进程的加速，高级持续性威胁（Advanced Persistent Threat, APT）已成为当前网络安全领域最具隐蔽性与破坏性的攻击形态之一。APT 攻击通常由具备较强资源背景的攻击组织发起，具有长期潜伏、定向攻击与多阶段协同等特征，其攻击过程涵盖初始入侵、权限提升、横向移动以及数据窃取等多个阶段，并通过持续迭代与多路径渗透实现对目标系统的长期控制^[1]。

已有威胁情报与全局监测数据表明，全球 APT 攻击形势与区域地缘政治冲突保持高度共振。从攻击目标行业分布的演化拓扑来看，尽管国家级政府部门仍是 APT 组织的首要高优目标（事件占比约 22%），但其攻击偏好已呈现出显著的“非国家行为体外溢”与“功利化激进”趋势^[2]。值得高度警惕的是，各类非政府组织、高价值个人（16%）以及高校与科研机构（11%）正面临高频次的渗透威胁。最新年度实战分析指出，具备丰富前沿知识储备的高校、科研院所及企业研发部门，因其网络边界防护体系相对薄弱，极易遭遇复杂的鱼叉式钓鱼攻击，现已成为境外 APT 组织实施间谍活动与供应链投毒的核心跳板区。




图 1-1 2024 年 APT 活动攻击目标行业分布

进一步地,最新威胁情报表明,APT 攻击在复杂度与规模上持续提升:攻击手段逐渐融合社会工程、供应链攻击及人工智能辅助技术,攻击活动呈现出更强的隐蔽性与系统性。与此同时,攻击组织在全球范围内的活动频率与技术成熟度不断增强,逐步演化为具有“生态化”与“产业化”特征的持续对抗体系^[2-5]。

从攻击过程来看,APT 攻击在战术技术程序(Tactics, Techniques and Procedures, TTPs)层面呈现出相对稳定的阶段化模式。现有研究普遍将其攻击流程划分为初始入侵、建立驻留、权限提升、横向移动、命令控制(C2)通信以及数据窃取等多个递进阶段,现有研究通常采用 Cyber Kill Chain 模型对 APT 攻击进行阶段化描述,该模型将攻击过程划分为多个连续阶段,用于刻画攻击者的行为路径与演进过程^[1]。

在实际攻击中,攻击者通常通过漏洞利用或社会工程手段获取初始访问权限,随后借助持久化机制维持长期控制,并通过凭据窃取与横向移动逐步扩大攻击范围。在此过程中,DLL 侧加载等免杀技术以及隐蔽通信机制被广泛应用,以规避检测并延长攻击周期。

值得注意的是,上述技术路径在不同攻击事件中呈现出高度重复性,这反映出 APT 组织在攻击工具与技术选择上存在稳定的行为模式。这种模式化特征为后续基于历史情报进行攻击行为预测提供了重要依据。

进一步的威胁情报分析表明,APT 组织在不同攻击活动中往往复用特定的工具链、攻击技术及命令控制基础设施。同一组织或其子组织在多个行动中呈现出高度一致的技术选择与攻击路径,这种跨事件的复用现象在具有关联关系的攻击组织之间尤为显著。

相关报告指出,部分典型 APT 组织(如 Lazarus、Gamaredon 等)在持续攻击活动中保持高度活跃,其攻击工具与技术路径在不同事件中呈现出明显的复用特征^[6]。这一现象表明,APT 攻击并非完全随机,而是具有可学习的行为偏好模式。

因此,若能够基于历史威胁情报对攻击行为进行建模,并进一步预测攻击组织在未来可能采用的攻击手段或目标对象,将有助于实现从被动响应向主动防御的转变。具体而言,若能够提前识别攻击组织在工具使用、漏洞利用与目标行业选择上的潜在偏好,防御方可据此优先配置针对性检测规则、加固重点资产并优化安全资源投入,从而在有限防御资源约束下提升主动威胁管理效率,具有重要的现实意义。

然而,当前各类安全机构发布的 APT 威胁情报普遍存在信息碎片化与描述不完整的问题。不同报告中所记录的攻击指标(Indicators of Compromise, IOC)与 TTP 信息往往彼此独立,缺乏统一建模与跨源关联,难以形成对 APT 组织攻击行为的系统性认知。

知识图谱(Knowledge Graph, KG)以“实体—关系—实体”三元组的形式对领域知

识进行结构化表达，其核心价值在于显式刻画概念之间的语义关联，并支持基于图结构的推理^[7]。这一特性与 APT 攻击的内在结构高度契合：APT 攻击在本质上是一个由攻击组织、所用战术、技术手段、目标行业与受害资产等多类实体协同构成的结构化过程，攻击组织在不同攻击活动中对工具、技术与目标的选择呈现稳定的关联模式，而这种模式恰好可以被知识图谱的图结构自然承载。具体而言，通过将 APT 组织、恶意软件、攻击目标及漏洞等实体及其关系结构化表示为三元组形式，可以构建面向 APT 领域的语义网络，并进一步将攻击行为预测问题转化为在已知图结构上推断缺失或潜在关系的链接预测（Link Prediction）任务。这一建模路径的内在逻辑在于：借助显式的实体关联结构，将攻击行为预测从单纯的统计或序列建模问题，转化为基于结构化先验的图推理问题，从而充分利用攻击实体之间的语义关联，弥补单纯依赖序列特征或频次统计的预测方法在可解释性与小样本泛化方面的不足。

然而，现有 APT 知识图谱在数据规模、结构质量以及建模方法等方面仍存在明显不足，限制了其在攻击预测任务中的应用效果。本文的研究正是在这一背景下展开。

1.2 研究现状与问题分析

现有研究主要可从知识图谱构建与链接预测建模两个方向进行分析。在知识图谱构建方面，部分工作基于 APT 威胁情报提取结构化信息。据天际友盟发布的《2024 年下半年全球主要 APT 攻击活动报告》，2024 年下半年全球共披露逾百个 APT 组织的 188 起攻击活动，攻击目标持续向地缘政治敏感领域集中^[6]。Ren 等人利用非结构化情报并结合 STIX 标准^[8] 定义了 12 类实体与 11 类关系^[9]，同时引入钻石模型分析 APT 攻击意图，但其实体划分粒度较为粗略，且未涉及自动化预测机制。Sarhan 等人则构建了开放网络威胁情报知识图谱 Open-CyKG，主要侧重于通用漏洞信息的整合，对 APT 组织行为的针对性建模相对不足^[10]。在本体设计层面，MALOnt 为恶意软件威胁情报提供了系统性本体框架，将恶意软件属性、行为与关联关系形式化定义^[11]。

国内研究中，高见等针对网络威胁情报构建了基于本体的分析体系^[12]，元玉璐等进一步将安全知识图谱应用于天地一体化网络的攻击研判^[13]，Yang 等提出基于知识图谱的威胁情报建模框架以支持网络安全分析^[14]。此外，亦有研究从情报自动化采集与实体关系抽取角度丰富 APT 知识图谱的构建路径^[15-17]，并探索将知识图谱应用于网络攻击预测与漏洞检测等下游任务^[18,19]。

总体而言，现有 APT 知识图谱存在三方面问题：其一，数据规模偏小，三元组数量通常在数千条以内，图谱稀疏度高；其二，实体类型定义粗粒度，对恶意软件变种、哈

希值、攻击手法等细粒度实体区分不足；其三，缺乏系统性的数据增强策略，导致模型训练数据不均衡。

在知识图谱链接预测建模方面，主流方法可划分为翻译模型、旋转模型、语义匹配模型和图神经网络模型四类。翻译模型（TransE^[20] 及其变体）将关系建模为头实体到尾实体的平移向量，结构简洁但对复杂关系模式的表达能力有限；TransH^[21]、TransR^[22] 通过引入超平面或关系特定投影矩阵加以改进，但参数量随关系数增加较为显著。旋转模型（RotatE^[23]、QuatE^[24] 等）将关系建模为复数或超复数空间中的旋转变换，RotatE 能够推断对称、反对称和合成等多种关系模式；QuatE 进一步扩展至四元数空间；DualE^[25] 通过对偶四元数将平移与旋转关系统一建模，从而能够刻画更为丰富的关系模式。结合图神经网络的模型（如 R-GCN^[26]、CompGCN^[27]）通过邻域信息聚合增强实体表示，在多关系图场景中取得了一定效果。然而，在高度稀疏的领域知识图谱中，由于结构连接有限，模型容易过度依赖已有观测模式，导致表示泛化能力受限，并伴随过平滑风险；此外，在关系类型较少的场景下，其性能优势也难以充分体现。

在面向 APT 场景的知识图谱语义建模方面，亦有研究尝试引入预训练语言模型增强实体表示或战术技术识别能力^[28,29]，但上述方法仍主要在欧式空间中展开建模。一个共同局限在于，其嵌入过程均基于欧式空间进行建模，而难以刻画复杂的层级关系结构。对于 APT 场景而言，其知识图谱通常呈现出多层级的组织形式，例如由攻击组织发起具体行动（Campaign），在行动中执行一系列操作（Action），调用相应工具（Tool），并进一步关联到具体的恶意软件（Malware）实例，整体形成由上至下逐步展开的树状结构，其中底层节点数量显著增加。欧式空间的体积随维度呈多项式增长，在容纳这类指数扩张的层级结构时会产生“几何拥挤（Geometric Crowding）”效应——该效应最早由 Nickel 与 Kiela 在庞加莱球层级嵌入研究中系统阐述^[30]，指欧式空间中大量叶子节点因维度容量不足而在嵌入空间中相互叠压、难以区分的现象：大量叶子节点（如具体的哈希值、恶意软件变种）在嵌入空间中相互叠压，模型无法有效区分不同深度的节点，从而损害预测精度。以本文实验数据为例，Malware 与 Tool 类实体合计占图谱节点总量的 40% 以上，而 APT 组织与 Campaign 类顶层实体数量极少，这种严重不均衡的分布恰好对应了层级树底层节点密集的几何特征，欧式空间对此缺乏有效的表达能力。

双曲空间（Hyperbolic space）的体积随半径呈指数增长，其几何性质与树结构天然契合，已在具有显著层级拓扑特征的通用知识图谱任务上表现出一定优势^[31–33]。但是直接在双曲空间中展开训练将面临诸多工程挑战：由于双曲空间本质上属于非欧几何系统，其梯度更新必须在黎曼流形上通过切空间映射来寻找测地线，这种复杂的转换极易

引发数值不稳定；同时，这种纯粹的几何空间变换对参数的初始状态极为苛刻，常规的随机初始化往往会导致优化发散；此外，当前主流预训练语言模型提取的特征均基于欧式空间，难以将其蕴含的丰富语义直接无损迁移至双曲架构中，从而制约了该方法在复杂语义场景下的效能。如何将欧式空间的语义表达能力与双曲空间的层级建模能力有机结合，是本文方法设计的核心着力点。

与此同时，大语言模型（LLM）在从非结构化文本中推断隐含知识方面具备较强能力，为弥合威胁情报来源分散、结构异构等问题^[33]，并缓解图谱稀疏性提供了新的技术路径。在信息抽取层面，甄珍等针对中文网络安全文本的实体关系抽取工作表明，领域特定语料上的关系抽取质量直接影响下游图谱的完整性^[34]。LLM 可用于对威胁情报中的实体语义进行抽象与归纳，从而辅助构建更高层级的语义结构。然而，针对具体关系的自动生成仍面临事实一致性与可控性不足的问题，直接依赖开放域生成可能引入结构性噪声。然而，LLM 生成的知识如何与图谱原有结构对齐、如何在不引入噪声的前提下有效注入训练过程，目前尚缺乏系统性方案，直接拼接可能导致实体指代不一致、关系语义混乱等问题。

1.3 本文研究问题

针对上述分析，本文围绕以下核心问题展开研究：

（1）如何基于 APT 威胁情报构建一个具有细粒度实体类型、覆盖完整攻击链路的知识图谱，并通过 LLM 引导的语义抽象与本体重构机制缓解图谱的稀疏性与实体类型分布不均衡问题？

（2）如何设计一个从欧式空间到双曲空间的两阶段表示学习框架，在保留语义特征的同时有效建模 APT 知识图谱中的层级结构，从而提升攻击偏好预测的精度？

前者关注数据层面的质量问题，核心在于通过 LLM 对原始图谱进行语义聚类与层级本体重构 (Hierarchical Ontology Reconstruction)；后者关注建模层面的几何问题，核心在于设计合理的空间迁移机制，使双曲嵌入能够充分利用欧式预训练所获得的语义信息。两个问题相互关联：更高质量的图谱为几何建模提供更可靠的训练数据；更强的层级建模能力又反过来验证了数据增强策略对层级结构保留的有效性。

1.4 主要研究内容与创新点

为解决 APT 攻击知识图谱稀疏性与层级结构建模困难的核心问题，本文提出一个由先验本体约束与双曲几何协同驱动的双空间表示学习方法，并据此构建了面向层级结

构的 APT 知识图谱基准及配套评估协议。需要强调的是，本文的核心方法并非“数据增强”与“双曲建模”两个相互独立的模块，而是一个二者强耦合、不可分割的整体：层级本体重构所提供的并非额外训练数据，而是一种面向双曲几何的结构归纳偏置（Structural Inductive Bias），该偏置只有通过双曲空间建模才能被有效“几何兑现”；若脱离双曲建模而在欧式空间中引入相同的层级关系，反而会加剧几何拥挤、导致性能下降（详见第 4.3、4.4 节实验）。本文的创新点可归纳为以下两个方面。

创新点一：提出先验本体约束与双曲几何协同的双空间表示学习方法。针对传统欧式空间在建模层级扩张拓扑时的几何容量瓶颈，以及直接在双曲流形上随机初始化训练时的优化不稳定问题，本文设计了一套先验本体约束与双曲几何协同的双空间表示学习方法。在结构先验侧，本文以 Gromov δ -双曲性作为是否引入层级建模的量化判据，并提出“语义—数量正交解耦”的径向锚定机制：以语义特征决定实体在流形上的角度与聚类归属，以实体在原始图谱中的数量规模作为庞加莱球径向坐标的启发式先验，从而将“少量高层实体—大量底层实例”的金字塔分布主动映射至双曲空间的指数膨胀容量中。在表示学习侧，本文构建欧式—双曲两阶段框架：第一阶段在欧式空间中结合领域预训练语言模型与图神经网络，捕获实体的局部语义与邻域结构特征；第二阶段通过指数映射将欧式嵌入平滑投影至庞加莱球，并以测地线距离对全局层级结构进行精细化建模，实现从局部语义到全局层级的表示优化。该方法将结构先验与几何建模统一在同一框架内，二者协同形成对攻击偏好关系的层级化表达能力。

创新点二：构建面向层级结构的 APT-Hier 基准与任务驱动的评估协议。在数据资源层面，本文在现有 APT-Flat（1,476 个实体、4,746 条三元组）基础上，提出一套可复现的层级化重构协议：首先在离线阶段借助大语言模型对原始 21 类细粒度实体标签进行高层语义抽象归纳，构建由 7 个高层抽象节点组成的本体框架（并入原始实体集合后形成容量为 1,483 个实体的封闭词表）；随后基于人工校验后的确定性映射规则注入 1,253 条 subClassOf 层级归属关系，将三元组规模由 4,746 条扩展至 5,999 条，由此得到面向层级结构的 APT-Hier 基准。该协议将大语言模型的作用严格限定于其相对可靠的高层语义归纳环节，而把对事实一致性要求较高的关系注入交由确定性规则完成，从机制上规避了开放域生成的事实幻觉与语义漂移风险。在评估层面，针对 APT 攻击偏好预测与通用链接预测在动机与机制上的本质差异，本文进一步提出任务驱动的单向严格过滤评估协议（Task-driven Unidirectional Strict-Filtered Setting），使评估指标能够真实反映模型在前瞻性偏好预测场景下的排序能力。

围绕上述方法与基准，本文开展了系统性实验验证。在 APT-Flat 与 APT-Hier 两个

版本数据集上，本文分别从通用链接预测与攻击偏好预测两个角度，将所提方法与覆盖欧式嵌入、图神经网络及双曲嵌入的多类基线模型进行对比，并通过消融实验与敏感性分析考察层级本体重构、欧式语义迁移与双曲空间建模之间的作用关系。实验结果表明，在 APT-Hier 攻击偏好预测任务设定下，完整方法在 Hits@10、Hits@3、Hits@1 与 MRR 等前列排序指标上取得较优表现，其中 Hits@10 达到 0.514；该优势主要体现在前列召回与高位排序质量上，而非所有排名指标均取得最优。消融实验进一步显示，去除层级本体重构、欧式语义迁移或双曲建模中的任一组件，模型在部分关键指标上均出现不同程度下降；尤其在保留层级关系但移除双曲建模（即纯欧式建模）时性能下降最为明显，表明三者并非彼此孤立发挥作用，而是在完整框架中形成了协同依赖关系。

1.5 论文结构

本文围绕 APT 攻击偏好预测任务，从数据层级结构增强与表示学习模型设计两个方面展开，整体结构安排如下：

第 1 章为绪论，介绍研究背景与意义，分析当前研究现状与存在问题，并明确本文的研究内容与创新点。

第 2 章为相关基础知识，主要介绍知识图谱表示学习、图神经网络、双曲空间建模以及大语言模型在知识图谱增强中的应用，为后续方法设计提供理论基础。

第 3 章为方法设计，围绕数据层与模型层两个方面展开：首先提出层级本体重构方法，将原始 APT-Flat 重构为具有显式层级先验的 APT-Hier；其次设计欧式—双曲两阶段表示学习框架，以充分利用该层级结构完成攻击偏好预测。

第 4 章为实验与结果分析。该章首先在 APT-Flat 上开展控制实验，用于分析模型层双空间框架的独立有效性；随后在 APT-Hier 上开展完整方法的主对比实验，并通过消融实验与敏感性分析进一步验证数据层层级本体重构与模型层双空间表示学习的独立贡献及协同作用。

第 5 章为总结与展望，总结全文工作，并对未来可能的研究方向进行展望。

2 基础知识

本章系统介绍与本文研究密切相关的基础理论，包括知识图谱嵌入模型（欧式空间）、图神经网络在知识图谱补全中的建模方式、双曲空间表示学习的几何基础、多几何空间表示学习方法，以及大语言模型在知识图谱增强中的定型用法与风险控制。上述内容分别对应本文方法中的关键技术组件，为后续章节的方法设计奠定理论基础。

2.1 知识图谱表示学习与预测任务

2.1.1 问题定义与评分框架

知识图谱可形式化为 $\mathcal{G} = (\mathcal{E}, \mathcal{R}, \mathcal{T})$ ，其中 $\mathcal{E}$ 为实体集合， $\mathcal{R}$ 为关系集合， $\mathcal{T} \subseteq \mathcal{E} \times \mathcal{R} \times \mathcal{E}$ 为已知三元组集合，每条三元组 (h, r, t) 表示头实体 h 与尾实体 t 之间存在类型为 r 的关系。知识图谱补全通常以链路预测任务加以形式化：对于查询 $(h, r, ?)$ 或 $(?, r, t)$ ，目标是从全体候选实体中找出最可能补全该三元组的实体，并将其排在尽可能靠前的位置。KGE 的通用做法是设计评分函数 $f(h, r, t)$ 衡量三元组合理性，并以负采样构造伪三元组，透过排序或分类式损失让真实三元组得分高于负样本。

在 APT 攻击偏好预测场景中，该任务形式上对应于查询攻击组织可能使用的工具或目标对象，但其与传统知识图谱补全任务在动机与机制上存在本质区别。传统知识图谱补全的动机在于修复图谱自身的不完整性：由于知识抽取过程的有损性，图谱中客观存在但未被收录的事实需要被还原；其机制是在封闭世界或局部封闭世界假设下，依据已观察到的三元组分布，对缺失三元组的存在性进行后验推断，目标是恢复“事实上已经存在但未被观察到”的关系。而 APT 攻击偏好预测的动机并非补全已发生事实，而是基于攻击组织的历史行为模式，对其在未来可能采取的攻击技术、目标行业等“尚未发生”的关系进行前瞻性建模；其机制是将攻击组织的行为倾向编码为嵌入空间中的偏好分布，进而对候选关系进行排序，目标是识别攻击组织最可能选择的行为路径。两类任务在三个层面存在核心差异：在时间属性上，前者面向已发生事实，后者面向未发生行为；在评价目标上，前者关注命中率与整体准确性，后者更强调高位排序质量与候选优先级，这也是本文在评估时重点关注 Hits@K 与 MRR 等前列排序指标的原因；在模型假设上，前者依赖图谱内部的结构闭合性，后者则需要建模攻击主体的偏好异质性与层级语义结构。正是基于上述区别，本文不直接套用通用知识图谱补全的建模范式，而是

在数据层引入层级本体重构、在模型层引入欧式—双曲两阶段表示学习，以适配 APT 攻击偏好预测在层级结构表达与前瞻性排序方面的特殊需求。

2.1.2 翻译模型：TransE 与 TransH

翻译类模型是 KGE 领域最具代表性的方法族之一，其核心思想是将关系建模为向量空间中的平移操作。TransE 假设对于合法三元组 (h, r, t) ，实体嵌入满足 $\mathbf{h} + \mathbf{r} \approx \mathbf{t}$ ，并以 $-\|\mathbf{h} + \mathbf{r} - \mathbf{t}\|$ 作为评分依据^[20]。该方法结构简洁、计算开销低，在一对一关系上表现良好，但对一对多、多对多等复杂映射关系的建模能力相对有限。TransH 以关系特定超平面投影后再平移，使同一实体在不同关系下可具有不同的投影表示，较符合复杂映射关系的直觉^[21]。

2.1.3 语义匹配模型：DistMult、ComplEx、TuckER、ConvE

语义匹配模型多以乘法交互刻画关系。DistMult 的双线性形式计算量低，但由于对称性，对反对称关系的区分在部分任务下可能不足^[35]。ComplEx 将表示扩展至复数空间，利用共轭内积支持非对称关系建模^[36]。TuckER 以 Tucker 张量分解提供较强的表达能力与参数共享机制，常作为强基线之一^[37]。ConvE 以 2D 卷积学习更丰富的嵌入交互特征，并提醒链路预测评估需留意数据集构造可能导致的偏差风险^[38]。

2.1.4 旋转与复数空间模型：RotatE、QuatE、DualE

旋转类模型从代数结构出发，将关系建模为嵌入空间中的旋转变换，而非简单平移。RotatE 在复数空间中将关系表示为逐元素的相位旋转： $\mathbf{t} \approx \mathbf{h} \circ \mathbf{r}$ ，其中 $\circ$ 为 Hadamard 乘积，关系模长被约束为 1^[23]。这一设计使模型能够统一刻画对称、反对称、逆关系及复合关系等多种模式。QuatE 将嵌入空间进一步扩展至四元数域，利用四元数乘法的旋转语义建模更为丰富的空间变换^[24]。DualE 则引入对偶四元数结构，在单一代数框架内同时编码旋转与平移两类几何变换，使关系的表达更为完备^[25]。

然而，上述所有方法——无论是翻译模型、语义匹配模型还是旋转模型——均在欧式空间中展开建模。欧式空间的体积随维度以多项式速率增长，当知识图谱呈现出显著的层级扩张拓扑时，其表示能力面临根本性的几何瓶颈。在本文所关注的 APT 威胁情报场景中，恶意软件（MAL）与攻击工具（TOOL）实体合计占图谱节点总量的 40% 以上，而高层概念实体（如 CAMPAIGN）数量极少，整体形成典型的“金字塔”型长尾分布。在这种指数扩张的层级结构下，欧式空间容易因维度容量不足而导致大量叶子节点在嵌入空间中相互叠压，产生所谓“几何拥挤”效应^[39]，可能影响链路预测的区分精度。这一根本局限为引入双曲空间表示学习提供了核心动机。

2.2 图神经网络与图拓扑重构

图神经网络 (Graph Neural Network, GNN) 通过消息传递机制迭代聚合邻居节点信息, 使实体表示能够感知图结构中的局部上下文, 弥补了传统嵌入方法孤立建模每条三元组的不足。图卷积网络 (GCN) 是最基础的 GNN 变体, 其通过对称归一化的邻接矩阵实现同等权重的邻域聚合^[40]。在此基础上, 图注意力网络 (GAT) 进一步引入了注意力机制^[41], 打破了结构上均等聚合的局限, 允许模型自适应地为不同邻居分配差异化权重。这种对邻域节点进行“差异化加权感知”的技术思想, 也为后续复杂知识图谱中基于节点相关性的加权拓扑建模 (如共现加权机制) 奠定了演进逻辑。

2.2.1 多关系扩展: R-GCN 与 CompGCN

知识图谱并非普通无向图, R-GCN 以关系类型区分邻居信息的变换矩阵, 支持有向多关系图建模, 并提出参数分解以降低关系种类多时的参数量^[26]。CompGCN 进一步把关系向量纳入卷积并引入实体—关系组合算子, 使节点与关系能在同一框架下共同更新^[27]。

2.2.2 NoGE 与共现加权的单图建模

NoGE (Node Co-occurrence based Graph Neural Network) 在上述工作的基础上提出了一种将实体节点与关系节点统一纳入同质图中联合建模的思路^[42]。与 R-GCN、CompGCN 将实体和关系置于不同处理层级的策略不同, NoGE 将每个关系视为与实体地位对等的独立节点, 基于三元组中实体与关系的共现频率为节点对赋予边权, 由此构建带权邻接矩阵。

然而, 知识图谱的基本单位是带关系语义的三元组 (h, r, t) , 若直接把实体视作节点、把关系视作边, 则图卷积过程往往难以充分保留关系本身的语义角色。为此, 一项关键思想是 Levi 图变换 (Levi Graph Transformation)。在这种变换下, 原始知识图谱

$$\mathcal{G} = (\mathcal{E}, \mathcal{R}, \mathcal{F})$$

被转换为新图

$$\mathcal{G}' = (\mathcal{V}, \mathcal{A}),$$

其中节点集合

$$\mathcal{V} = \mathcal{E} \cup \mathcal{R}.$$

也就是说, 原本仅作为边类型存在的关系, 被重新视为图中的普通节点, 与实体节点处于统一地位。这样做的好处在于: 实体与关系都可以参与消息传播, 图神经网络不再只

是在实体之间传播信息，而是能够在“实体—关系—实体”的路径上进行显式建模，从而更自然地保留知识图谱的结构特征。

在 Levi 图基础上，还需进一步定义节点之间的邻接关系及权重。对于新图 $\mathcal{G}'$ 中任意两个节点 u, v ，其邻接矩阵元素可表示为

$$A_{u,v} = \lambda \cdot \frac{\#C(u,v)}{\#C(u)},$$

其中， $\#C(u,v)$ 表示节点 u 与 v 在上下文中共同出现的频次， $\#C(u)$ 表示节点 u 的出现总频次， $\lambda \in (0, 1]$ 为平滑因子，用于抑制异常高频节点带来的偏置影响。该加权方式本质上利用共现频率来近似刻画节点间的结构相关性，使重构后的图不再是简单的二值连接，而是具有强弱差异的加权拓扑。这类处理有助于后续图编码器在欧式空间中学习更稳定的局部结构表征。

在编码器设计上，NoGE 提出对偶四元数图神经网络（DualQGNN）作为消息传递模块，将对偶四元数运算嵌入邻域聚合过程，理论上能在单次前向传播中同时编码平移与旋转两类几何变换，对复杂关系模式具备较强的表达能力。

尽管 NoGE 等图神经网络方法在结构信息利用上具有一定优势，但其性能高度依赖图谱自身的连通质量。APT 威胁情报数据天然具有隐蔽性和高稀疏性，导致 GNN 在孤立节点或浅层连接处难以获取充分的监督信号，这也进一步凸显了借助外部知识进行结构增强的必要性。

此外，针对 APT 威胁情报场景，已有研究尝试将领域文本信息与知识图谱结构进行联合建模。例如，部分方法引入领域预训练语言模型（如 CyBERT^[43]）对实体语义进行初始化，并结合图结构编码与对比学习机制来提升表示质量（如 KLEC 方法^[44]）。该类方法在缓解图谱稀疏带来的表示不足问题方面取得了一定效果，但其建模仍主要基于欧式空间，对图谱中潜在的层级结构刻画相对有限。在具有明显层级特征的数据场景下，其表示能力在特定实验设置下可能存在进一步提升空间。

2.3 双曲空间表示学习

双曲空间是一种具有负曲率的非欧几何空间，其体积随半径呈指数增长，更适合表示层级结构数据^[30]。

对于 APT 知识图谱而言，”攻击组织 → 战役 → 攻击工具 → 恶意软件变种”这一

典型的纵向归属结构，恰好具有越往底层实体数目越庞大的金字塔分布。欧式空间在容纳这类结构时，大量叶子节点（如具体的哈希值、恶意软件变种）因维度容量不足而被迫聚集在彼此相邻的区域，嵌入表示失去区分度。双曲空间由于其指数膨胀的体积结构，能够为每一层级分配充足的几何容量，有效缓解这一几何拥挤现象^[31,32]。

2.3.1 Poincaré 球、距离与指数映射

曲率为 $-c$ 的 Poincaré 球定义为 $\mathbb{B}_c^d = \{\mathbf{x} \in \mathbb{R}^d \mid c\|\mathbf{x}\|^2 < 1\}$ 。两点距离可由双曲距离 $d_c(\mathbf{x}, \mathbf{y})$ 表示，并依赖 Möbius 运算^[30,45]。双曲距离定义为：

$$d_c(\mathbf{x}, \mathbf{y}) = \frac{2}{\sqrt{c}} \operatorname{arctanh}(\sqrt{c}\|-\mathbf{x} \oplus_c \mathbf{y}\|)$$

相比欧式距离，其在边界区域增长更快，有助于区分层级节点。为衔接欧式向量与双曲流形，常用原点指数映射

$$\exp_0^c(\mathbf{v}) = \tanh(\sqrt{c}\|\mathbf{v}\|) \frac{\mathbf{v}}{\sqrt{c}\|\mathbf{v}\|},$$

其可把欧式切向量压缩到球内并维持流形约束。

该映射将切空间中的欧式向量 $\mathbf{v}$ 压缩至庞加莱球内部，方向保持不变，模长则由 $\tanh$ 函数进行非线性压缩以满足球体约束。当 $\|\mathbf{v}\|$ 较小时，映射近似线性，欧式空间中的相对距离关系得以保留；当 $\|\mathbf{v}\|$ 增大时，映射将向量逐步推向球面区域。值得注意的是，指数映射为单射，不同欧式向量对应不同的双曲点，确保了信息在映射过程中不会产生混叠，这一性质对于跨空间的参数传递至关重要。基于指数映射和对数映射，可以进一步定义莫比乌斯矩阵乘法

$$M \otimes_c \mathbf{x} = \exp_0^c(M \log_0^c(\mathbf{x})),$$

以在双曲空间中实现类似线性变换的操作。

双曲空间在层级建模任务中更具表达优势，在具有明显树状结构的数据中，通常在层级结构建模任务中具有优势。

2.3.2 多关系双曲嵌入：MuRP

MuRP (Multi-relational Poincaré Graph Embeddings) 是首个将上述双曲几何算子系统性应用于多关系知识图谱嵌入的方法，也是目前面向层级知识图谱的代表性双曲嵌入

模型之一^[46]。对于三元组 (h, r, t) ，MuRP 的评分函数定义为：

$$f_{\text{MuRP}}(h, r, t) = -d_{\mathbb{D}}(\mathbf{h}_H \oplus_{\mathcal{M}} \mathbf{r}_H, \mathbf{t}_H)$$

其中 $d_{\mathbb{D}}$ 为庞加莱球上的双曲距离， $\oplus_{\mathcal{M}}$ 为莫比乌斯加法， $\mathbf{h}_H, \mathbf{r}_H, \mathbf{t}_H$ 分别为实体与关系在双曲空间中的嵌入表示。评分函数的语义为：经关系驱动变换后的头实体表示若与尾实体表示在双曲距离上足够近，则该三元组得分高，被判定为合法。正如原文献的基准测试所示^[46]，MuRP 在层级关系丰富的数据集（如 WN18RR）上表现出明显优于欧式基线的性能，这在实验层面印证了双曲几何对层级拓扑的适配优势。本文在双曲表示学习阶段选用 MuRP 评分函数，其结构相对简洁、参数效率较高，在中等规模知识图谱场景下无需引入过多额外假设，适合与欧式阶段的预训练表示进行联动优化。

2.3.3 注意力机制双曲嵌入：AttH

AttH (Attention-based Hyperbolic Knowledge Graph Embedding) 在 MuRP 的基础上引入了关系特定的注意力机制，将实体的切空间变换与双曲距离计算相结合^[47]。与 MuRP 直接以莫比乌斯加法建模关系平移不同，AttH 对头实体施加关系驱动的旋转与反射变换，再将变换后的实体嵌入投影至庞加莱球，其评分函数定义为：

$$f_{\text{AttH}}(h, r, t) = -d_{\mathbb{D}}(\mathbf{W}_r \otimes_c \mathbf{h}_H \oplus_{\mathcal{M}} \mathbf{r}_H, \mathbf{t}_H) + b_h + b_t$$

其中 $\mathbf{W}_r$ 为关系特定的变换矩阵， $\otimes_c$ 为双曲空间中的莫比乌斯矩阵乘法。该设计使模型能够在双曲流形上同时刻画旋转与平移两类几何变换，理论上具备更强的关系模式表达能力。在 WN18RR 等层级数据集上，AttH 展现出优于 MuRP 的性能，但其引入的变换矩阵在小规模稀疏图谱场景下会显著增加参数量，存在过拟合风险。本文将其纳入双曲基线对比，以评估复杂双曲变换机制在 APT 威胁情报场景下的实验效果。

2.4 大语言模型与知识图谱增强

近年来，大语言模型 (Large Language Model, LLM) 在知识抽取、关系推断和结构化生成等任务中表现出较强的语言理解能力，也因此被逐渐引入知识图谱构建与增强流程。与传统监督式信息抽取相比，LLM 的优势在于其能够利用预训练阶段获得的大规模语义知识，在样本有限或标注不足条件下，通过提示设计完成一定程度的隐含知识发现^[48]。对于知识图谱而言，LLM 的常见应用方式主要包括三类：其一，直接从非结构化文本中抽取实体与关系；其二，对已有图谱中的缺失关系进行推断与补全；其三，将图谱结构信息反馈给语言模型，用于增强生成与问答能力。本文与上述三类研究的关联并不在于让 LLM 直接补全图谱关系，而在于利用其对高层语义进行抽象归纳，辅助构建本体框架；具体的层级关系注入则由人工校验后的确定性映射规则完成。因而，本文

与通用的“LLM 关系补全”工作存在明显区别，其关注重点在于如何在强约束条件下借助 LLM 改善数据层的语义组织方式，而非直接依赖 LLM 生成结构化事实。

尽管如此，现有研究也表明，LLM 在结构化知识任务中的应用仍高度依赖输入信息的组织形式。例如，有工作尝试利用语言模型进行实体对齐，通过筛选关键属性与关系并结合多轮投票机制缓解推理偏差，但其结果质量仍受限于输入结构的完整性与一致性^[49]。这一现象说明，单纯依赖语言模型进行推断，仍难以保证结构层面的稳定性与可控性。

LLM 在知识图谱增强中的主要风险集中于两方面：事实幻觉（Factual Hallucination）与语义漂移（Semantic Drift）。相关研究^[50]明确指出，尽管大模型具备强大的参数化知识记忆，但在生成复杂的逻辑查询或领域实体时，极易脱离真实路径，产生严重的‘幻觉实体（Hallucination Entities）’。此外，当实体包含多重语义（如某恶意软件既是文件又是工具）时，若缺乏图谱局部拓扑的显式约束，大模型在长文本推理中常发生概念偏移，即语义漂移现象。现有研究^[51,52]虽尝试通过偏好对齐或检索增强来缓解上述问题，但在缺乏确定性本体约束时，仍难以从根本上杜绝发散性错误。这构成了本文放弃开放域生成，转而采用‘闭集词表 + 强规则约束’进行受控重构的核心理论动机。

从理论上讲，LLM 对知识图谱增强的价值不只是“增加数据量”，更重要的是在一定条件下补充原始图谱中未被显式记录、但与领域知识一致的潜在结构信息。对于层级关系尤其如此。许多威胁情报文本虽然不会直接写出标准化的上下位标签关系，但会通过描述对象类别、所属系列、攻击工具变种或功能归属，隐含地表达出实体之间的纵向组织方式。若能在严格约束下将此类隐含关系转化为结构化三元组，则有助于使图谱在拓扑上表现出更明确的层级特征。这一作用更多体现在数据组织质量和结构可学习性方面，而不是简单追求关系数量扩张。换言之，LLM 增强是否能带来性能收益，仍需取决于生成质量、约束强度以及后续表示空间是否与新增结构相匹配。

2.5 本章小结

本章系统介绍了本文方法所依赖的四类核心基础理论。在知识图谱嵌入方面，回顾了翻译模型、语义匹配模型与旋转模型的基本设计思路，并指出欧式空间在面对层级扩张拓扑时的根本几何局限；在图神经网络方面，梳理了从 R-GCN、CompGCN 到 NoGE 的多关系图建模演进脉络，分析了共现加权单图结构在知识图谱补全中的优势与适用边界；在双曲空间表示学习方面，介绍了庞加莱球模型的几何基础、指数映射的跨空间衔接机制，以及 MuRP 的多关系双曲评分函数，并明确了直接在双曲空间训练所面临的工

程挑战；在大语言模型增强方面，分析了 LLM 在知识图谱补全中的应用潜力与幻觉风险，阐述了事前强约束策略的设计动机。

上述理论为后续 APT-Hier 数据构建与两阶段表示学习框架提供了基础支撑。

3 基于先验本体约束与双空间表示学习的攻击偏好预测模型

本章围绕 APT 知识图谱中的攻击偏好预测任务，分别从数据层与表示学习层进行建模：在数据层，通过引入层级结构对原始图谱进行重构；在模型层，构建欧式—双曲两阶段表示学习框架，以适配重构后的层级拓扑特性。

3.1 任务定义与多维特征空间建模

3.1.1 链接补全任务的拓扑几何表示

针对 APT 威胁情报场景，本文将知识图谱形式化定义为有向标记多重图 $\mathcal{G} = (\mathcal{E}, \mathcal{R}, \mathcal{T})$ ，其中 $\mathcal{E}$ 为实体集合， $\mathcal{R}$ 为关系类型集合， $\mathcal{T} \subseteq \mathcal{E} \times \mathcal{R} \times \mathcal{E}$ 为已观测三元组集合，每条三元组 $(h, r, t) \in \mathcal{T}$ 表示头实体 h 与尾实体 t 之间存在类型为 r 的有向关系。在底层算法框架上，本文将攻击偏好预测转化为知识图谱链接补全（Knowledge Graph Completion）任务。该补全任务的基础目标是：对于测试查询 $(h, r, ?)$ ，从候选实体集合 $\mathcal{E}$ 中检索出最可能的尾实体 t^* ，使 $(h, r, t^*) \in \mathcal{T}_{\text{true}}$ 但 $(h, r, t^*) \notin \mathcal{T}$ 成立。

在上述补全任务中，表示学习模型所依赖的几何空间并非一种中性的先验决策，而是深刻受制于图谱自身的内在拓扑性质。为科学量化图谱的层级拓扑特征，本文引入 Gromov δ -双曲性作为核心评估指标^[53]。对于无权图 $G = (V, E)$ ，其 Gromov δ 值可通过四点条件（Four-point Condition）严格定义：对图中任意四点 $x, y, z, w \in V$ ，设其两两距离构成的三对距离和为：

$$S_1 = d(x, y) + d(z, w), \quad S_2 = d(x, z) + d(y, w), \quad S_3 = d(x, w) + d(y, z),$$

不妨令 $S_1 \geq S_2 \geq S_3$ ，则定义

$$\delta(x, y, z, w) = \frac{1}{2}(S_1 - S_2),$$

图谱的全局双曲性为 $\delta = \sup_{x, y, z, w \in V} \delta(x, y, z, w)$ 。纯树结构满足 $\delta = 0$ ， δ 值越小，图谱的树状层级特性越强，越适合在双曲几何空间中嵌入^[30]。

本文在第 3.3 节所构建的增强图谱 APT-Hier 中，经抽样测算（ $N = 5000$ 个四元节点组），平均 Gromov δ 值为 0.1957，显著低于复杂网状结构的通用图谱 FB15k-237^[54]（ $\delta = 1.34$ ），与具有强层级特征的词网图谱 WN18RR^[38]（ $\delta = 0.24$ ）处于同一数量级。该几何指标从数据结构角度说明该图谱具备一定的层级特征，为后续引入双曲空间建模提

供了动机：欧几里得空间的体积随维度以多项式速率增长，无法在有限维度内为指数扩张的层级结构提供充足的表示容量，导致大量叶子节点在嵌入空间中发生几何拥挤；而双曲空间的体积随半径以指数速率增长，与树状拓扑的节点密度分布天然契合。

为实现跨空间的有效预测，知识图谱嵌入的通用范式在于设计合理的评分函数 $f : \mathcal{E} \times \mathcal{R} \times \mathcal{E} \rightarrow \mathbb{R}$ ，其核心机制是确保真实存在的三元组得分显著高于随机构造的负样本，从而据此对候选实体进行排序。面向 APT 图谱的双重几何特性，本文设计了两阶段的评分与链接预测机制：在欧几里得阶段，采用基于邻域聚合的结构感知评分以捕获局部共现特征；在双曲阶段，则以庞加莱距离为基础的 MuRP 评分函数作为最终解码器。两阶段空间通过指数映射 (Exponential Map) ^[45] 实现特征参数的跨流形平滑传递，最终统一以双曲评分函数的输出作为链接预测任务的判别依据。

3.1.2 攻击偏好的业务语义约束

如前文所述，一般的基础知识图谱补全任务不对实体类型或关系类型做额外限制。而在 APT 攻击偏好预测场景中，预测目标具有明确的业务语义约束。

为此，本文定义偏好预测子空间 $\mathcal{T}_{pref} \subset \mathcal{T}$ ，且该子空间中的三元组需满足以下约束条件：

$$h \in \mathcal{E}_{APT}, \quad r \in \{target, use, exploit\}$$

其中， $\mathcal{E}_{APT}$ 表示攻击组织实体集合；*target*、*use*、*exploit* 分别表示攻击目标、工具使用与漏洞利用关系。因此，针对具体的 APT 攻击偏好预测场景，本文将高度不确定的威胁预测问题进一步转化为严格的条件概率排序过程。给定攻击组织实体 $h \in \mathcal{E}_{APT}$ 与偏好关系类型 $r \in \mathcal{R}_{pref}$ ，攻击偏好预测任务被建模为条件排序问题：从候选实体空间 $\mathcal{E}$ 中，按照条件得分 $f(h, r, t)$ 的降序，检索最可能构成 (h, r, t^*) 的尾实体。这一形式化将高度不确定的威胁预测问题约束在可量化的几何距离最小化框架内：

$$t^* = \arg \max_{t \in \mathcal{E}} f(h, r, t) = \arg \min_{t \in \mathcal{E}} d_{\mathbb{B}}(\mathbf{h}_H \oplus_{\mathcal{M}} \mathbf{r}_H, \mathbf{t}_H),$$

其中 $d_{\mathbb{B}}(\cdot, \cdot)$ 为庞加莱球上的双曲距离， $\oplus_{\mathcal{M}}$ 为莫比乌斯加法， $\mathbf{h}_H, \mathbf{r}_H, \mathbf{t}_H$ 分别为实体与关系在双曲空间中的嵌入表示（详见第 3.4.2 节）。距离最小化在几何上等价于：关系驱动变换后的头实体嵌入与尾实体嵌入在庞加莱球中处于最近的测地线距离，此时对应的尾实体 t^* 即为该攻击组织在当前关系语义下偏好程度最高的实体。

需要指出的是，上式展示了双曲空间中基于距离度量预测尾实体的通用形式。为更

精准地捕捉 APT 偏好关系在层级树中的语义缩放与拓扑跃迁，本文在实际模型优化时采用了修正后的双维度变换距离函数（具体公式推导见第 3.4.4 节）。

从实际安全防御的角度来看，上述形式化将业务层面的攻击偏好预测，严格映射到了算法层面的图谱补全评估框架之内：测试集三元组中属于 $\mathcal{T}_{\text{pref}}$ 的查询，对应安全分析师最关心的三类前瞻性预测——“该 APT 组织下一步最可能攻击哪些行业（target）”、“最可能调用哪些工具（use）”以及“最可能利用哪些漏洞（exploit）”。Hits@10 指标在此场景下具有直接的业务含义：若真实的攻击目标或工具在模型输出的前 10 名候选中出现，分析师即可优先部署针对性防御，无需在数百候选实体中逐一排查。

3.2 方法框架

针对上述问题，本文提出一个由数据层层级本体重构与模型层欧式——双曲两阶段表示学习共同组成的整体框架，最终服务于 APT 攻击关系的链接预测任务。在数据层，本文首先对原始 APT-Flat 图谱执行层级本体重构：结合 CyBERT 语义特征、层次聚类与大语言模型辅助命名构建高层本体框架，再通过人工校验后的确定性映射规则注入 subClassOf 层级关系，得到具有显式层级先验的 APT-Hier。在模型层，本文进一步在该重构图谱上构建欧式——双曲两阶段表示学习框架：第一阶段在欧式空间中学习实体的局部语义与邻域结构表示，第二阶段通过指数映射将其迁移到双曲空间，并在庞加莱球中进一步建模全局层级关系与攻击偏好关系。因此，本文完整方法并非仅指某一单独模型结构，而是由“APT-Hier 构建”与“欧式——双曲两阶段表示学习”共同构成的整体方法框架。需要特别说明的是，此处的层级本体重构不应被理解为与下游模型解耦的数据预处理：它对模型是非中性的——其所注入的层级关系本质上是一种面向双曲几何的结构归纳偏置，只有在双曲空间建模下才能被有效利用并转化为预测性能；若在欧式空间中引入相同的层级关系，反而可能因几何拥挤而损害性能（详见第 4.3、4.4 节）。正是这种“重构—几何”强耦合关系，使数据层重构构成本文方法不可分割的组成部分，而非独立的数据准备步骤。

图 3-1 从整体上展示了本文完整方法的两层框架：前半部分对应数据层层级本体重构，后半部分对应模型层欧式——双曲两阶段表征学习。具体而言，图中高层抽象节点构建、层级关系注入与 APT-Hier 输出对应数据层组件；欧式语义编码、指数映射与双曲空间解码对应模型层组件。该图的核心作用在于说明：APT-Hier 并非外部固定数据，而是由本文数据层方法产生并进一步服务于模型层学习的中间结果。




图 3-1 整体方法框架图

3.3 基于 LLM 辅助语义归纳与确定性规则注入的层级本体构建

在展开图谱重构之前，必须首先对原始基础图谱（APT-Flat）在几何与语义层面存在的固有缺陷进行剖析。从底层数据拓扑来看，原始图谱面临三大核心挑战：其一，实体粒度高度异构；其二，层级关系系统性缺失；其三，概念语义边界模糊。上述痛点致使原始图谱难以从数据层面为双曲流形提供充足的“中心-边缘”树状发散信号。针对上述拓扑缺陷，本节提出基于高层语义抽象与确定性规则注入的层级本体重构方案。关于 LLM 在闭集语境下辅助高层语义归纳的预研验证，本文仅在正文中保留其结论性说明，详细样本与分析过程移至附录 A.1。

3.3.1 动机与初步分析

本文首先对前序工作构建的 APT-Flat 图谱^[44]进行分析。该图谱基于 STIX 2.1 (Structured Threat Information Expression) 标准构建基础本体结构^[8]，并在此基础上引入领域特定关系 `hasType`，用于刻画实体类型归属关系。在这一设定下，APT-Flat 形成了包含 21 类细粒度实体类型的知识图谱结构。

为进一步说明原始图谱中实体类型的粒度差异与数量分布情况，本文对 APT-Flat 中各类实体的规模进行统计，结果如表 3-1 所示。

需要指出的是，STIX 2.1 的细粒度分类方案本身具有充分的通用性与合理性。然而，在本文所关注的特定 APT 场景与中小规模数据集约束下，沿用该扁平分类方案会在双曲流形中引发明显的几何拥挤问题。例如，MD5、SHA1、SHA2 等文件指纹在本体语义

表 3-1 APT 知识图谱实体类型与数量统计

实体类型	数量	语义说明
MAL (恶意软件)	308	具体恶意软件家族或变种
TOOL (攻击工具)	175	常被黑客利用的系统良性工具（如 PowerShell）
APT (攻击组织)	154	APT 组织或子组织
FIELD (行业领域)	165	攻击所针对的行业类别
HASH (文件哈希)	110 (48+13+49)	MD5/SHA1/SHA2 合计
ACT (攻击行为)	102	技战法与操作行为
LOC (地理位置)	99	国家、地区等地理信息
FILE (文件)	89	载荷文件、脚本等
TIME (时间戳)	79	事件发生时间记录
IOC (网络指标)	50 (13+10+26+1)	IP/URL/域名/邮件合计
SECTEAM (安全团队)	41	安全厂商或研究团队
VULID (CVE 编号)	36	漏洞的标准编号
VULNAME (漏洞名称)	21	漏洞的通用名称
OS (操作系统)	17	受害主机操作系统
CAMPAIGN (战役)	6	具体攻击行动
PROT (协议)	3	通信协议类型

视角下同属底层观测指标的不同变体，却在图谱中以多个独立叶子节点并列存在。这种“细粒度叶子节点密集、却缺乏上位层级约束”的结构，不利于模型形成稳定的树状层级表示。

此外，部分实体具有明显的多角色语义特征，若直接依赖开放式语义判断将底层实体映射为结构化层级关系，容易引入语义边界不清与关系误配风险。基于这一观察，本文不采用开放域关系生成，而是仅利用 LLM 辅助高层抽象节点的语义归纳与本体框架命名，再通过人工校验后的确定性映射规则完成层级关系注入。这样既能引入高层语义组织能力，又能降低事实幻觉与结构噪声风险。

关于 LLM 在闭集约束和关系语境下的辅助判别能力，本文在附录 A.1 中给出预研验证结果，其结论表明：LLM 可以作为高层语义归纳的辅助工具，但并不直接承担结构化层级关系生成任务。

3.3.2 高层抽象节点的语义归纳与本体框架构建

基于前述预研的信心，本文的应对策略是：引入大语言模型作为语义聚类工具，在保持原有实体集合不变的前提下，对细粒度类型进行重新组织。聚类分析任务沿三个维度展开：

第一维，基于 CyBERT 的高维语义特征提取与相似度度量。为规避开放域生成的不可控性，本文首先采用量化的计算范式。提取每种实体类型在 APTnotes 语料库中的标准上下文描述，输入至在网络安全领域微调的预训练语言模型 CyBERT 中，提取 [CLS] 标记的隐含层向量作为各细粒度类型的全局语义特征表示。基于该特征向量，本文计算了 21 个实体类型之间的成对余弦相似度，构建出类型相似度矩阵 $S \in \mathbb{R}^{21 \times 21}$ （如图 3-2 热力图所示）。矩阵对角线区域的高亮区块表明，同源细粒度实体（如 MD5、SHA1、SHA2）在语义流形上具有较强的内聚特性。

第二维，基于 Ward 最小方差法的无监督层次聚类。依托相似度矩阵 S ，本文进一步采用无监督层次聚类算法（Hierarchical Clustering）对细粒度实体进行自底向上的拓扑聚合。通过设定合理的距离阈值，聚类树状图（如图 3-3 所示）在宏观层面收敛为 7 个结构稳定的簇分支。该过程完全由数据驱动，为后续的高层节点划分提供了量化的数学依据，相较于纯人工分类方案，在可复现性与客观性方面具有明显优势。

第三维，LLM 驱动的语义提炼与专家框架对齐。在获取 7 个聚类簇的拓扑边界后，基于前述预研验证的结论，本文将各簇包含的细粒度标签输入至大语言模型 GPT-4，要求其结合网络安全背景为每个簇生成高层抽象命名。最终归纳为 7 个高层抽象节点类型：

$$\mathcal{C} = \{\text{Strategic_Core}, \text{Context}, \text{Target_System}, \text{Methodology}, \\ \text{Attack_Resource}, \text{IOC_Network}, \text{IOC_Hash}\}$$

其中，Strategic_Core 映射战略核心层，Context 刻画攻击发生的时空与领域背景，Target_System 锚定受害目标的具体技术环境，Methodology 囊括攻击技法与漏洞利用路径，Attack_Resource 涵盖恶意软件、黑客工具及网络协议等攻击资源，而 IOC_Network 与 IOC_Hash 则分别表征网络侧与文件侧的底层观测指标。此种语义聚类方案将原本平行离散的细粒度特征（如 MD5、SHA1、SHA2）统一归敛至 IOC_Hash 抽象节点，并将 IP、URL、域名及电子邮件等网络资产归并至 IOC_Network 抽象节点，有效缓解了同质化叶子节点在原始图谱中造成的扁平冗余问题，为后续构建高阶树状层级拓扑奠定了数据基础。




图 3-2 实体语义相似度热力图




图 3-3 基于 CyBERT 特征的层次聚类树状图

值得注意的是，如图 3-3 的层次聚类树状图所示，目标系统下的 OS 节点与攻击技法下的 ACT 节点，在阈值截断线下方均呈现为独立的原始主干分支（蓝色连线）。这一现象表明 CyBERT 在高维空间中具有较高的语义分辨能力：一方面，OS 作为攻击的物理底座，在底层缺乏可合并的同源实体，故保持独立；另一方面，在 Methodology（攻击

技法) 簇内, 漏洞的通用名称 (VULNAME) 与标准编号 (VULID) 由于指代高度同质而在极低距离处优先合并, 而宏观的攻击战术动作 (ACT) 则保持相对独立, 直到更高的语义距离阈值上方, 才与具体的漏洞簇合并形成完整的技法层级。这种在无监督条件下识别出的宏微观语义隔离, 有力支撑了本文高层抽象节点划分策略的合理性。

为严谨验证大语言模型归纳结果的客观性, 本文将其与 STIX 2.1 及 MITRE ATT&CK 双重权威框架进行了映射交叉验证 (见表 3-2)。该映射关系表明, 提炼得到的高层抽象节点体系自发形成了与主流安全标准相容的层级骨架, 为后续基于双曲空间的偏好预测提供了具备业务可解释性的拓扑基础。

表 3-2 基于双重权威框架的 LLM 聚类结果交叉验证

高层抽象节点	底层实体类型	对齐标准一: STIX 2.1 抽象层	对齐标准二: MITRE ATT&CK 顶层
Strategic_Core	APT, Campaign, Secteam	Threat Actor, Campaign	Groups, Campaigns
Context	Time, Loc, Field	Location, Identity	Impact (业务语境)
Target_System	OS	Infrastructure (SDO)	Platforms
Methodology	ACT, Vulname, Vulid	Attack Pattern, Vulnerability	Tactics & Techniques
Attack_Resource	MAL, TOOL, FILE, PROT	Malware, Tool (SDO)	Software
IOC_Network	IP, Dom, URL, Email	Network Observable	Data Sources: Network
IOC_Hash	MD5, SHA1, SHA2	File Observable	Data Sources: File

区别于一般的数据清洗或类型合并, 本节提出的径向锚定机制是一项面向双曲几何的主动设计决策: 它将实体的语义归属与规模分布解耦, 并据此为高层抽象节点指定其在庞加莱球中的目标几何位置, 从而在数据组织阶段即与下游双曲建模形成结构对齐。在完成基于纯语义特征的层级聚类与抽象节点归纳后, 本文进一步引入实体数量分布作为正交特征维度, 指导高层抽象节点在双曲空间中的径向定位。具体而言, 本文将实体属性严格解耦为‘类别语义’与‘规模热度’两个维度: 语义特征决定了实体在流形上的角度与拓扑归属 (即聚类簇), 而实体在原始图谱中的数量规模 (如表 3-1 所示) 则被用作计算双曲庞加莱球中径向坐标 r 的启发式先验。如表 3-3 所示, 抽象层级较高、涵

盖实例极少的节点（如 CAMPAIGN=6）被锚定于靠近球心的核心区域（ $r < 0.15$ ）；而数量庞大的底层观测指标（如 MAL=308）则被显式推向流形的边缘膨胀区（ $r \rightarrow 1.0$ ）。该“语义-数量”正交解耦映射机制充分利用了双曲空间体积指数膨胀的几何特性，有效缓解了底层叶子节点在原始扁平图谱中所面临的几何拥挤问题。

表 3-3 高层抽象节点在双曲空间中的层级映射设计

高层抽象节点	包含的原始类型	双曲空间定位 (r)	语义说明
Strategic_Core (战略核心)	APT, Campaign, Secteam	$r < 0.15$ (球心区域)	层级结构逻辑起点，连接度最高的根节点，数量少但关联关系最密集
Context (环境维度)	Time, Loc, Field	$r \approx 0.30$ (内层骨架)	定义攻击的时空背景，连接战略核心与受害目标的语境节点
Target_System (目标系统)	OS	$r \approx 0.40$ (中内层)	受害者的具体技术环境，攻击在操作系统层面的落点
Methodology (攻击技法)	ACT, Vulname, Vulid	$r \approx 0.50$ (中层枢纽)	描述攻击的动态过程 (TTPs)，连接“谁发动”与“用什么”
Attack_Resource (攻击资源)	MAL, TOOL, FILE, PROT	$r \approx 0.70$ (指数膨胀区)	数量最大 (572 个)，需利用双曲膨胀容量，避免几何拥挤
IOC_Network (网络指标)	IP, Dom, URL, Email	$r \approx 0.85$ (外层)	攻击基础设施的网络痕迹，层级较低
IOC_Hash (文件指纹)	MD5, SHA1, SHA2	$r \rightarrow 1.0$ (边缘区域)	最细粒度指纹，层级最末端，具有较大的表示容量

实现细节与可复现性说明：为确保上述 APT-Hier 本体构建过程的可复现性，本文对核心实验参数与流程进行了标准化定义。具体而言：(1) 语义特征提取基于 CyBERT 模型，其输入语料来源于 APTnotes 经过预处理后的标准实体上下文描述；(2) 在层次聚类阶段，本文并未采用硬编码的距离阈值，而是通过最大化聚类轮廓系数 (Silhouette Coefficient)

实现自适应截断，从而客观确定 7 个语义簇边界；(3) 针对 GPT-4 生成的初步命名，依据 STIX 2.1 与 MITRE ATT&CK 标准进行规范化核校，具体规则为：若初步命名在上述标准中存在对应或近义术语，则直接替换为标准术语；若两个标准均未收录，则保留 GPT-4 生成结果并依据所在语义簇中高频实体描述进行最小化改写，以保证与本体中同层级节点的命名风格一致；(4) 最终形成的“细粒度类型—高层抽象节点”映射字典已转化为确定性的注入脚本，作为本研究图谱重构阶段的底层先验。

3.3.3 确定性规则映射与层级关系注入

在完成高层抽象节点的语义归纳与本体框架构建后，仍需进一步解决底层实例实体与高层本体结构之间的连接问题。前文已经基于 CyBERT 语义特征、层次聚类结果与 LLM 辅助命名，形成了由 7 个高层抽象节点组成的本体框架；本节进一步关注如何在引入开放域生成噪声的前提下，将底层实体确定性地映射至对应的高层节点，从而构建可用于后续表示学习的层级化图谱。

需要指出的是，APT 知识图谱中的层级关系不仅影响数据层面的组织方式，也会进一步影响后续双曲空间建模中的几何结构质量。由于双曲空间对树状层级关系较为敏感，若新增层级边存在语义误配或方向错误，可能会在图谱拓扑中形成错误的归属路径，并在后续表示学习过程中造成结构噪声的累积。因此，层级关系注入阶段不能简单依赖大语言模型进行开放域关系生成，而需要在语义合理性与结构可控性之间取得平衡。

尽管预研结果表明，大语言模型在语境消歧任务中具有一定的辅助能力，但网络安全知识图谱对事实一致性与拓扑稳定性具有较高要求。若直接依赖大语言模型进行开放域关系生成，可能引入实体幻觉、关系误配或语义漂移等问题，并在后续双曲空间建模中造成拓扑噪声的累积。因此，本文并未采用端到端的开放域关系生成方式，而是采用“LLM 辅助语义抽象 + 确定性规则执行”的层级关系注入策略：LLM 仅参与高层抽象节点的归纳与本体框架设计，具体的 subClassOf 关系则由预定义映射字典确定性生成。该策略在工程层面实现了极高的成本效益：将大模型的调用限制在图谱初始化的离线阶段，而底层的常态化关系注入则由轻量级规则引擎执行，有效避免了全量节点交互产生的大规模 Token 消耗。此外，本文对映射字典的执行结果进行了代码级校验，以确认新增层级三元组均由预定义规则生成，在保障落地可行性的同时，消除了开放域补全带来的不确定性风险。

所有新增的 subClassOf 上下位归属关系边均由人工设计的映射字典驱动：针对任意归属于高层抽象节点 $M_k \in \mathcal{V}_{closed}$ 的底层实例节点 e ，系统通过确定性规则引擎生成三

元组 $(e, \text{subClassOf}, M_k)$ 。其约束体系主要包括以下三方面：

其一，闭集词表约束：所有生成三元组的头、尾实体严格闭合于封闭词表 $\mathcal{V}_{\text{closed}}$ 之内，从机制上保证约束实体集合 $\mathcal{E}$ 在增强前后完全一致，避免引入额外外部新实体。该机制要求所有注入的 subClassOf 三元组，其头尾实体必须严格属于 $\mathcal{V}_{\text{closed}}$ ，从而在机制层面限制外部未登录实体的引入。其约束形式如下：

$$\forall(h, \text{subClassOf}, t) \in \mathcal{T}_{\text{inject}} : h \in \mathcal{V}_{\text{closed}} \wedge t \in \mathcal{V}_{\text{closed}}$$

其二，单向映射原则： subClassOf 上下位归属关系的构建严格遵循“由具体实例指向抽象上位类型”的单向路径，不引入同层节点之间的横向连接。由于新增的 subClassOf 边仅表示由底层实例指向高层抽象节点的单向归属关系，因此该层级边集合本身不引入同层互连或反向映射，有助于降低由关系注入造成的环路与语义混杂风险。

其三，语义一致性约束：正如 2.4 节所述，若采用传统大语言模型进行端到端的开放域关系生成，极易诱发严重的语义漂移与事实幻觉问题。因此，本文将 LLM 的作用限制在高层语义抽象与本体框架设计阶段，而具体的 subClassOf 关系注入由预定义映射字典完成。这种基于确定性字典的硬隔离机制，从源头上切断了开放域发散带来的语义漂移风险，防止了实体幻觉在双曲空间几何建模中的引入与蔓延。

综合上述三条约束原则，本文将作用于数据层的结构先验统一定义为先验本体约束集合：

$$\Omega_{\text{onto}} = \{\mathcal{V}_{\text{closed}}, \mathcal{E}, \mathcal{M}, \mathcal{R}_{\text{hier}}\} \quad (3-1)$$

其中， $\mathcal{V}_{\text{closed}}$ 为封闭词表约束下的有效实体集合； $\mathcal{E}$ 为由 7 个高层抽象节点组成的本体框架； $\mathcal{M}$ 为经人工校验的底层类型到高层节点的确定性映射字典； $\mathcal{R}_{\text{hier}}$ 为由 $\mathcal{M}$ 诱导生成的单向层级关系集合。需要强调的是， Ω_{onto} 主要通过数据重构阶段显式施加于图谱结构，而非在优化目标中引入独立的正则项。

设原始基础图谱为 $G = (\mathcal{E}, \mathcal{R}, \mathcal{T})$ ，经由上述确定性规则注入的层级三元组集合为 $\mathcal{T}_h$ ，重构后的增强图谱 APT-Hier（记为 G' ）可正式定义为：

$$G' = (\mathcal{E}, \mathcal{R} \cup \text{subClassOf}, \mathcal{T} \cup \mathcal{T}_h) \quad (3-2)$$

在实际重构工程中，系统共计注入了 1,253 条高置信度 subClassOf 三元组，图谱规模统计见表 3-4。

为了直观展示层级映射规则所引入的拓扑变化，本文选取数据集中典型的局部关系进行对比可视化，如图 3-4 所示。在原始 APT-Flat 图谱中，不同实体之间主要通过原始

表 3-4 各版本数据集规模统计

数据集版本	实体数	关系数	三元组总数
APT-Flat	1,476	11	4,746
APT-Hier (本文)	1,483	12	5,999

语义关系进行连接，具体攻击行为、攻击资源与网络指示器等实体之间缺乏显式的层级归属结构；而在引入确定性映射后，底层实例通过 `subClassOf` 关系向高层抽象节点聚合，形成“实例—类别”的分层结构。该过程在不改变原始事实三元组的基础上，为图谱补充了显式层级先验。




图 3-4 APT-Hier 中层级拓扑重构演化对比示意图

进一步地，本文对重构前后的图谱进行了 Gromov δ -双曲性测算。结果显示，在执行确定性层级映射后，图谱的平均 δ 值由 0.2566 下降至 0.1957。该指标变化表明，重构后的图谱在整体拓扑上呈现出更明显的树状结构特征，为第 3.4 节引入双曲空间建模提供了一定的数据结构依据。需要说明的是，该拓扑指标仅用于描述图谱结构形态的变化，并不单独作为层级关系质量的充分证明；其有效性仍需结合后续预测实验与消融实验共同分析。

3.3.4 增强拓扑形态分析

为客观评估上述确定性层级重构策略的实际几何效能，本节构建了系统性的量化评估体系。具体而言，本文将从核心几何特征维度出发，对重构前后的图谱拓扑形态演化进行严格的定量比对与深度分析。该量化分析旨在用几何指标刻画图谱的拓扑形态演化，

进而对本文所提本体映射策略的有效性提供定量评估依据。

为了客观衡量结构重构对数据流形的影响，本节首先从数据的几何结构特性（morphology）角度对图谱形态进行定量刻画。作为衡量图谱树状层级特性的核心几何指标，Gromov δ -双曲性的演化能够直观反映图谱层级特征的强弱。为此，本节在随机抽样测算（ $N = 5000$ ）的基础上，特意引入了知识图谱领域两个极具拓扑代表性的公开基准作为“拓扑参考锚点（Topological Reference Anchors）”：以高度网状耦合的 FB15k-237 作为弱层级参考，以具有极端树状分类体系的 WN18RR 作为强层级参考。

表 3-5 数据集几何拓扑度量结果对比（含通用拓扑参考）

数据集	拓扑类型说明	平均	最大
		Gromov δ	Gromov δ
WN18RR	通用极强层级 (拓扑参考)	0.24	2.0
FB15k-237	通用复杂网状 (拓扑参考)	1.34	3.5
APT-Flat (重构前)	网络安全/事实图谱	0.2566	2.0000
APT-Hier (重构后)	网络安全/层级图谱	0.1957	2.0000

如表 3-5 所示，重构后的 APT-Hier 图谱其平均 δ 值由 0.2566 下降至 0.1957。与典型层级数据集 WN18RR（0.24）相比，APT-Hier 的 δ 值处于相近量级，表明其结构呈现出更明显的层级特征。

为探究这一量化指标变化在图拓扑结构上的实际映射，本文在保留核心连接模式的基础上对图谱进行了结构化采样与可视化。




图 3-5 拓扑演化对比图

从图 3-5 可以进一步看出，引入层级关系之后，原本较为分散的局部连接开始围绕高层抽象节点形成更明显的聚合结构。这一视觉变化与表 3-5 中 Gromov δ 值的下降相互印证：前者提供了拓扑演化的直观展示，后者则给出了图谱层级特征增强的定量支撑。因而，图 3-5 不仅是示意图，更是对“APT-Hier 更接近双曲空间适配结构”这一判断的图形化说明。

上述分析从定量与定性两个维度说明了该图谱具有一定的层级特性，为后续在表示学习中引入双曲空间建模提供了动机和合理性依据，但并不构成唯一或充分条件。

3.4 两阶段欧式——双曲表示学习框架

本节构建欧几里得——双曲双流形级联表示学习框架，以响应两类相互关联的几何挑战：其一，欧几里得空间在表达高度树状层级结构时的根本性容量瓶颈；其二，直接在双曲流形上进行随机初始化训练时的优化不稳定性问题。级联机制的核心思想是：以欧几里得空间负责捕捉局部语义与邻域结构特征（第 3.4.1 节），以严格定义的指数映射将欧几里得表示平滑迁移至双曲流形（第 3.4.2 节），最终以庞加莱球上的双曲距离解码器执行全局层级结构的精细化建模（第 3.4.3 节）。

3.4.1 欧式空间表示学习与图结构建模

作为双空间表示学习框架的基础环节，第一阶段的欧几里得空间编码旨在为后续的双曲空间映射提供高质量的先验基础。该阶段的核心任务是提取并融合两大维度的特征：一是实体节点内蕴的深层语义属性，二是图谱局部的拓扑邻域结构。

首先在实体语义初始化层面，为突破传统知识图谱随机初始化所面临的冷启动局限，本文沿用了先期 KLEC 模型^[44]所提出的领域适配策略。具体而言，针对图谱中的每个实体 e ，系统从 APTnotes 威胁情报语料中检索包含该实体名称的上下文句子集合，并将其输入至在网络安全语料上经过领域适配预训练的语言模型 CyBERT（由 SymanicTechnologies 提供）中，提取序列的 [CLS] 字符向量作为全局特征表示，从而获取具备丰富领域语义先验的初始文本向量。

在获取初始语义表示后，本文采用对偶四元数图神经网络（DualQGNN）作为欧式阶段的结构编码器。DualQGNN 由 NoGE^[42]提出，其核心建模思想是将实体与关系节点统一纳入同质图（基于 Levi 图变换），并依据三元组中节点的共现频率构建加权邻接矩阵，使边权能够反映节点间的潜在语义关联强度，从而缓解原始知识图谱结构稀疏带来的信息不足问题。

不同于传统的实值 GCN，DualQGNN 将实体表示映射至对偶四元数空间 $Q = \mathbb{R} +$

$\mathbb{I}i + \mathbb{J}j + \mathbb{K}k$, 利用汉密尔顿乘积 (Hamilton product) 实现节点间的特征聚合。其隐藏层更新公式为:

$$h_v^{(l)} = \tanh \left(\sum_{u \in \mathcal{N}_v \cup \{v\}} a_{v,u} \mathbf{W}^{(l)} \otimes h_u^{(l-1)} \right) \quad (3-3)$$

其中, $a_{v,u}$ 为第 2.2.2 节所定义的共现加权邻接矩阵元素; $\otimes$ 代表四元数汉密尔顿乘积; $\mathbf{W}^{(l)}$ 为对偶四元数形式的可学习权重矩阵。依托对偶四元数代数的非交换乘法性质, 该机制能够在单次前向传播中同时编码旋转与平移两类几何变换, 从而更细粒度地刻画 APT 攻击行为中的非对称演化关系, 显著拓展了欧式阶段的特征拟合容量。

相较于 KLEC 模型^[44], 本文在此阶段完整保留了 NoGE 的准同态图编码特性: KLEC 的核心贡献在于引入 CyBERT 语义初始化以缓解冷启动问题, 而本文进一步以 DualQGNN 替代其图编码模块, 在保留领域语义先验的同时, 增强了模型对图谱局部拓扑结构的感知能力。为控制模型复杂度并缓解稀疏图谱上的过平滑风险, 本文将聚合层数设为 $L = 1$ 。

训练目标: 在欧式空间表示学习阶段, 模型通过图结构信息与语义特征的联合建模, 学习能够反映局部邻域结构的实体表示。为提升表示的判别性, 本文在部分实验设置中引入对比学习机制作为辅助优化手段。

具体而言, 对比学习通过拉近邻居节点 (正样本) 之间的表示距离, 并推远非邻居节点 (负样本), 以增强嵌入空间的结构区分能力。其损失函数可形式化为:

$$\mathcal{L}_{NCE} = -\log \frac{\exp(\text{sim}(h_v, h_u^+)/\tau)}{\exp\left(\frac{\text{sim}(h_v, h_u^+)}{\tau}\right) + \sum_k \exp(\text{sim}(h_v, h_k^-)/\tau)} \quad (3-4)$$

其中, $\text{sim}(\cdot, \cdot)$ 表示余弦相似度, τ 为温度参数。需要说明的是, 该对比学习项作为辅助正则项引入, 其权重由超参数控制, 在不同实验配置中可选择启用或关闭。

训练配置: 训练轮数为 3000, 批大小为 1024, 优化器采用 Adam, 学习率设置为 5×10^{-3} 。在完成欧式阶段训练后, 模型输出的实体表示将作为初始语义先验, 通过指数映射传递至双曲空间, 以支持后续的层级结构建模。

3.4.2 跨空间的指数映射与切空间对齐

经过第一阶段的图神经网络编码后，实体的初始特征表示暂存于平坦的欧几里得空间。然而，欧几里得空间与双曲空间在底层度量与几何性质上存在本质差异，导致分属两类空间的特征向量无法直接进行线性叠加或融合。为实现跨流形的信息传递，本文将欧式空间下的节点输出视作双曲庞加莱球（Poincaré Ball）在原点处的切空间（Tangent Space）向量。

基于黎曼几何理论，本文引入指数映射（Exponential Map）机制，将切空间中的欧式表示严格且平滑地投影至负曲率流形上。以原点为切点的指数映射公式定义如下：

$$\exp_0^c(v) = \tanh(\sqrt{c}\|v\|) \frac{v}{\sqrt{c}\|v\|}$$

其中， v 为上一阶段输出的欧几里得特征向量； c 为控制流形曲率的非负超参数（对应流形曲率为 $-c$ ）； $\|\cdot\|$ 表示标准欧式范数； $\exp_0^c(\cdot)$ 即为完成跨流形转换的指数映射函数。

具体而言，若直接对欧几里得特征 h_E 执行指数映射，长向量极易在双曲空间中坍缩至庞加莱球的绝对边界，而引发数值溢出与梯度爆炸。因此，在跨空间映射前，本文依据底层工程实践引入了基于最大范数限制的特征截断机制（Norm Clipping）。

具体映射过程被严格定义为：

$$\tilde{\mathbf{h}}_E = \begin{cases} \mathbf{h}_E & \text{if } \|\mathbf{h}_E\| \leq 1.0 \\ \mathbf{h}_E \cdot \frac{1.0}{\|\mathbf{h}_E\|} & \text{if } \|\mathbf{h}_E\| > 1.0 \end{cases} \quad (3-5)$$

$$\mathbf{h}_H^{(0)} = \exp_0^c(\tilde{\mathbf{h}}_E) = \tanh(\sqrt{c}\|\tilde{\mathbf{h}}_E\|) \frac{\tilde{\mathbf{h}}_E}{\sqrt{c}\|\tilde{\mathbf{h}}_E\|} \quad (3-6)$$

其中， $\|\cdot\|$ 为欧氏范数，阈值 1.0 为强制截断边界。

基于上述映射机制，本文实现了欧式空间到双曲空间的参数传递，使两阶段表示学习在几何上形成一致的过渡关系，为后续利用双曲空间建模层级结构提供了良好的表示基础。

3.4.3 局部等距性与初始化合理性分析

尽管指数映射已被广泛应用于双曲表示学习中用于实现欧式到双曲空间的映射，其在本方法中的作用不仅体现在空间转换上，还在于为双曲优化提供合理的初始化基础。为进一步分析该初始化策略的合理性，本文从局部几何性质的角度进行讨论。

在黎曼流形理论的框架下，原点处的切空间 $\mathcal{T}_0\mathbb{B}_c^d$ 提供了对庞加莱双曲流形的一阶局部欧几里得近似。在此几何设定下，指数映射 $\exp_0^c(\cdot)$ 的物理本质，即是建立从平坦切空间向负曲率流形本体的参数化投影机制。依据微分几何的拓扑性质，该映射在原点邻域内具备严格的局部等距（Locally Isometric）特性。这意味着在映射发端的无穷小微元内，指数变换能够以极高的保真度维持原欧几里得输入空间中的度量关系。这一理论保证了模型在执行跨空间特征迁移的初期，能够最大程度地避免度量失真，维持特征向量的拓扑一致性。

从微分角度来看，这一性质可通过考察指数映射的雅可比矩阵在零点邻域的行为得到解释。当输入向量范数趋近于零时，映射函数在一阶近似下接近恒等变换，即局部区域内的几何结构变化较小。这意味着，在欧式阶段学习得到的实体表示若分布于该邻域内，其语义结构在映射过程中不会发生显著扭曲。

基于上述性质，欧式空间中形成的语义聚类结构（例如攻击组织与目标之间的偏好关系）在映射至双曲空间后仍能在一定程度上得到保留，为后续双曲空间中的结构优化提供稳定的初始化基础。

此外，该初始化策略对于双曲空间中的优化过程亦具有积极作用。相较于随机初始化，指数映射得到的初始表示通常分布于庞加莱球的中间区域，从而避免节点过早接近边界区域所带来的梯度衰减问题。这使得模型在训练初期能够获得更稳定的梯度信号，有助于提升整体收敛效果。

3.4.4 Poincaré Ball 中的双曲距离解码

在完成向负曲率流形的指数映射后，模型需对知识图谱三元组的合理性进行量化评估。不同于欧几里得空间中常用的向量内积或平移加法，本文在双曲空间中直接以庞加莱球的测地线距离 $d_{\mathbb{B}}(x, y)$ 作为三元组评分的核心测度。在强约束的几何空间内，两节点间的测地线距离越短，表征其在层级树结构中的语义关联越紧密，相应三元组成立的概率即越高。

为驱动模型参数的有效更新，并强化网络对正负样本边界的判别能力，本文引入基于局部负采样的交叉熵损失函数进行端到端优化。

其总体目标损失函数定义为：

$$\mathcal{L} = -\log \sigma(-d(h, t)) + \sum_{t' \in \mathcal{N}^-} \log \sigma(d(h, t')) \quad (3-7)$$

其中， $\sigma(\cdot)$ 表示 Sigmoid 激活函数 $d(h, t)$ 代表真实存在于图谱中的正样本三元组在双曲流形下的几何距离； t' 为通过随机替换头/尾节点所生成的伪造实体， $\mathcal{N}^-$ 则表示针对当前事实构造的负样本集合。该损失函数设计的优化直觉在于：通过梯度下降最小化全局损失 $\mathcal{L}$ ，迫使正样本对在双曲空间中相互聚拢（即距中心更近或节点间距缩小），同时以边缘最大化原则将负样本对推离原点或拉大彼此间距。这一推拉机制最终确保了嵌入表示有助于契合 APT 威胁情报图谱的全局层级拓扑特征。

相比欧几里得距离，双曲测地线距离 $d_c(\mathbf{x}, \mathbf{y})$ 在庞加莱球边界区域增长显著加快，使得边缘区域的叶子节点之间即便在欧几里得坐标上相近，也可以在双曲距离上相互分离，在较大程度上缓解几何拥挤现象。

如图 3-6 所示，Poincaré Ball 模型中，高层节点趋于中心，低层节点分布于边界区域，使其形成层级化的几何结构。




图 3-6 Poincaré Ball 中实体层级分布示意图

为在攻击偏好预测任务中准确刻画 APT 技战术（即关系 r ）的作用机制，本文采用 MuRP^[46] 的评分函数将关系的影响解耦为语义特征加权与层级结构平移两个独立维度。

具体而言, 针对特定攻击偏好关系 r , 模型首先通过对数映射将头实体 h_H 投影回切空间, 并利用关系特异性的特征权重参数 R_r 进行维度缩放 (即实现对特定攻击者特征的语义聚焦), 随后重新映射回庞加莱球得到变换后的头实体 h' ; 同时, 模型对尾实体 t_H 结合关系的层级平移向量 r_r 执行莫比乌斯加法, 以刻画攻击链条上的层级跃迁, 得到变换后的尾实体 t' 。

修正后的偏好打分函数定义为:

$$\mathbf{h}' = \exp_0(\log_0(\mathbf{h}_H) \odot \mathbf{R}_r) \quad (3-8)$$

$$\mathbf{t}' = \mathbf{t}_H \oplus_{\mathcal{M}} \mathbf{r}_r \quad (3-9)$$

$$f_{score}(h, r, t) = -d_{\mathbb{B}}(\mathbf{h}_r', \mathbf{t}_r') + b_h + b_t \quad (3-10)$$

其中, $\odot$ 表示元素级乘法, $d_{\mathbb{B}}(\cdot, \cdot)$ 为庞加莱距离, $\oplus_{\mathcal{M}}$ 为莫比乌斯加法, h'_r 与 t'_r 分别表示头、尾实体在特定关系 r 的驱动下, 映射至双曲空间的变换坐标, b_h, b_t 为实体的标量偏置项。

为确保上述评分机制能够在端到端训练中有效收敛, 本文设计了由二分类交叉熵损失与辅助正则项加权组合而成的联合优化目标:

$$\mathcal{L}_{total} = \mathcal{L}_{BCE} + \lambda \cdot \mathcal{L}_{aux} \quad (3-11)$$

其中, $\mathcal{L}_{BCE}$ 用于区分真实三元组与负采样三元组; $\mathcal{L}_{aux}$ 表示辅助正则项, 在部分实验设置中可采用对比学习损失进行实例化, 用于增强表示的判别性。 λ 为平衡两类损失的权重参数。

值得注意的是, 前文通过大语言模型引入的层级关系三元组集合 $\mathcal{S}_h$, 在训练过程中作为结构约束的正样本参与优化, 引导模型显式建模层级拓扑结构。

在参数更新过程中, 本文采用黎曼 Adam (Riemannian Adam) 优化算法执行梯度更新, 并在每次迭代后将嵌入重新投影至庞加莱球的可行域内, 以保证双曲几何约束的一致性。

3.4.5 两阶段训练流程与预测机制

上述两阶段学习框架通过指数映射实现跨空间的参数传递，无需显式进行欧式与双曲嵌入的融合操作。欧式阶段输出的实体表示作为初始语义先验，经指数映射投影至双曲空间后，双曲阶段在此基础上进一步优化层级结构表示。

整体训练流程如算法 3-1 所示。

算法 3-1 两阶段欧式—双曲表示学习训练流程

输入: 经过 LLM 层级增强的知识图谱 $G = (E, R, T)$

输出: 双曲空间嵌入参数 θ_H

```

1: 阶段 1: 欧式表示学习
2: for 每个实体  $e \in \mathcal{E}$  do
3:    $\mathbf{h}_E \leftarrow \text{TextEncoder}(e)$ 
4: end for
5: for  $l = 1$  到  $L$  do
6:    $\mathbf{h}_v^{(l)} \leftarrow \text{Aggregation}(\mathbf{h}_v^{(l-1)}, \mathcal{N}(v))$ 
7: end for
8: 基于损失函数  $\mathcal{L}_E$  优化参数  $\Theta_E$ 
9:
10: 阶段 2: 双曲空间优化
11: for 每个实体  $e \in \mathcal{E}$  do
12:    $\mathbf{h}_H^{(0)} \leftarrow \exp_0(\mathbf{h}_E)$ 
13: end for
14: 基于联合损失  $\mathcal{L}_{total}$  优化参数  $\Theta_H$ 
15:
16: 预测阶段
17: for 查询  $(h, r, ?)$  do
18:   计算缩放后的头实体:  $h' = \exp_0(\log_0(h_H) \odot R_r)$ 
19:   计算平移后的尾实体:  $t' = t_H \oplus_{\mathcal{H}} r_r$ 
20:    $score(t) = -d_{\mathbb{B}}(h', t') + b_h + b_t$ 
21: end for
22: return  $\arg \max(score)$  {返回得分最高的实体作为预测结果}
    
```

3.4.6 测地线距离驱动的偏好排序计算

在完成双空间表示学习模型的参数优化后，即可将训练所得的高质量特征嵌入应用于下游的链接预测推理。针对本文核心的 APT 攻击偏好预测子任务 $\mathcal{T}_{\text{pref}}$ ，对于任意给定的未知目标查询 $(h, r, ?)$ ——其中攻击组织主体严格限定为 $h \in \mathcal{E}_{\text{APT}}$ ，偏好关系约束为 $r \in \mathcal{R}_{\text{pref}} = \{\text{target}, \text{use}, \text{exploit}\}$ ——模型需对全局候选空间内的每一实体 t 计算偏好匹配度。在此预测推理阶段，偏好概率得分的量化被直接转化为庞加莱球流形上的双曲测地线距离计算，其评分机制无缝沿用训练阶段修正后的双维度变换框架：

$$\text{score}(h, r, t) = -d_{\mathbb{B}}(h', t') + b_h + b_t \quad (3-12)$$

在上述双维度变换的基础上，针对特定攻击偏好关系 $r \in \mathcal{R}_{\text{pref}}$ ，模型需对全局候选空间内的实体计算偏好匹配度。此时，候选目标实体 t 构成真实攻击意图的条件概率 $P(t|h, r)$ ，可形式化为与关系变换后的实体间测地线距离呈负指数比例关系：

$$P(t|h, r) \propto \exp(-d_{\mathbb{B}}(h', t')) \quad (3-13)$$

其中， h' 与 t' 为训练阶段（详见公式 3-7 与 3-8）经过语义加权 R_r 与层级平移 r_r 联合变换后的头尾实体坐标。这一修正严格保证了预测概率 $P(t|h, r)$ 始终受到攻击关系 r 的动态约束：实体在特定偏好关系驱动下的双曲测地线距离越短，其对应的指数衰减惩罚越小，进而在当前实验设定下映射为更高的攻击偏好概率。

进一步地，上述三类核心偏好关系在庞加莱球流形中展现出了截然不同的几何导向性与业务语义。具体而言，当预测关系为 *target* 时，头实体（APT 组织）通常锚定于庞加莱球的球心区域，而尾实体（归属于 Context 抽象节点的受害行业）多分布于中内层。两者间的测地线距离，本质上映射了攻击组织受历史攻击频次驱动，而对特定行业形成的拓扑趋近程度（即路径依赖）；当关系为 *use* 时，尾实体指向 Attack_Resource 抽象节点（分布于中外层），其空间距离量化了攻击组织在战术工具链选择上的依赖惯性与驻留稳定性；而当关系为 *exploit* 时，尾实体对应 Methodology 抽象节点（分布于中层），该距离则精准刻画了攻击者对特定漏洞利用武器库的偏好习惯。

综合上述三类层级分布特征，针对特定的攻击组织 h 与关系 r ，候选尾实体 t 的全局偏好排名（Rank）可严格形式化为：在全局实体空间 $\mathcal{E}$ 中，模型预测得分高于或等于 t 的实体总数：

$$\text{rank}_{h,r}(t) = |\{t' \in \mathcal{E} \mid \text{score}(h, r, t') \geq \text{score}(h, r, t)\}| \quad (3-14)$$

在执行量化评估时,本文严格遵循底层知识图谱补全任务中标准的过滤评估(Filtered Setting)。即在计算全局排名时,系统会主动从候选集中剔除在训练集与验证集中已客观存在的真实事实(三元组),确保模型对未知潜在威胁的预测泛化能力得到公正、无偏的检验。在此严格设置下,核心评价指标 Hits@10 衡量了真实偏好目标跻身模型输出前 10 名候选序列的占比。投射至实际的安全运营场景中,该指标直接等效于安全分析师在系统推送的前 10 条高危预警中,成功命中并拦截真实威胁目标的先验概率,具有极其显著的实战指导价值。

3.4.7 双曲模型及几何选择的合理性分析

本研究在双曲表示学习阶段选用庞加莱球模型与 MuRP 评分函数,主要基于其在层级结构建模任务中的适配性。

关于庞加莱球模型。双曲空间存在多种等价表示形式(如洛伦兹模型、庞加莱上半空间等),其中庞加莱球模型在表示层级结构时具有较好的直观性:靠近球心的位置通常对应较高层级节点,而靠近边界的区域能够容纳数量较多的叶子节点。这一性质与 APT 知识图谱中“少量高层实体—大量底层实例”的结构特征具有一定一致性。此外,庞加莱球模型的有界表示形式使嵌入向量自然约束在有限范围内,有助于提升训练过程的稳定性。同时,以原点为基点的指数映射形式较为简洁,便于实现欧式空间到双曲空间的初始化转换。

关于 MuRP 评分函数。MuRP 模型基于莫比乌斯加法在双曲空间中建模实体与关系之间的交互,能够在保持几何约束的前提下对关系进行变换。相较于部分引入额外结构假设或复杂参数机制的方法,该模型结构相对简洁,在中等规模知识图谱场景下具有较好的参数效率。同时,其基于距离的评分方式能够自然适配知识图谱中常见的非对称关系建模需求。

两阶段学习策略的合理性进一步体现在指数映射的几何性质上。指数映射将切空间中的欧式表示投影至双曲流形,在原点邻域内具有局部等距特性,使欧式阶段学习到的语义相似性能够得到保留;同时,该映射保持向量方向不变,仅对模长进行压缩,使得实体间的相对关系可以迁移至双曲空间。此外,指数映射为单射映射,不同欧式向量对应不同双曲点,从而保证了信息在映射过程中的区分性。基于上述性质,两阶段之间的参数传递在几何上具有良定义性,为后续的层级结构优化提供了稳定基础。

3.5 本章小结

本章围绕 APT 攻击偏好预测任务，从任务定义、数据重构、表示学习与偏好解码四个递进层次完整阐述了所提方法框架。

在任务层（第 3.1 节），本章基于 Gromov δ -双曲性（ $\delta = 0.1957$ ）为双曲几何空间在 APT 知识图谱表示中的应用提供了量化的结构依据，并将攻击偏好预测约束为以 $\mathcal{T}_{pref} \subset \mathcal{T}$ 为评估范围、头实体 $h \in \mathcal{E}_{APT}$ 、关系 $r \in \{target, use, exploit\}$ 的条件排序问题，将开放式的威胁预测需求转化为可形式化评估的几何优化任务。

在数据层面（第 3.3 节），针对前期基础图谱存在的层级关系隐含与拓扑结构扁平化问题，本文提出了面向双曲空间的知识图谱层级化重构方案。首先，结合 CyBERT 语义特征、层次聚类结果以及大语言模型辅助命名，构建由 7 个高层抽象节点组成的本体框架，并为各节点分配双曲半径定位区间，在数据预处理阶段完成语义与几何结构的初步对齐。随后，基于人工校验后的确定性映射规则注入 1,253 条 subClassOf 层级约束三元组。该设计避免了开放域关系生成带来的事实幻觉与语义漂移风险。结果表明，重构后的 APT-Hier 图谱 Gromov δ 值由 APT-Flat 的 0.2566 下降至 0.1957，说明所引入的层级关系有助于改善图谱的整体几何特性，使其更符合双曲嵌入的数据特征。

在模型层（第 3.4 节），提出欧几里得—双曲双流形级联架构：第一阶段以 CyBERT 初始化语义表示，经对偶四元数图神经网络（DualQGNN）完成局部邻域聚合；第二阶段通过以原点为基点的指数映射实现跨流形迁移，以 MuRP 评分函数在庞加莱球中进行层级结构的精细化建模。两阶段学习而非单纯向量叠加的设计思路源于以下考量：不同曲率流形的度量结构存在本质差异，直接在嵌入层面进行线性叠加可能破坏各空间的几何一致性，而通过切空间指数映射实现跨流形参数传递，在理论上具有更清晰的几何意义。

在预测层（第 3.4.6 节），阐明了庞加莱球中实体径向分布与 APT 层级语义之间的几何对应关系，并将双曲测地线距离转化为偏好概率得分，建立了从几何坐标到安全运营可解释预警的完整映射机制。四层设计形成数据与模型的协同体系：LLM 增强为双曲建模提供更强层级信号，双曲建模反过来为层级化数据的结构价值提供了几何兑现渠道；若单独使用其中任一组件，其贡献将因缺乏配套支撑而有所衰减，这一协同依赖关系将在第四章的消融实验中得到定量验证。

综上，本章给出了本文完整方法框架：在数据层，通过层级本体重构将 APT-Flat 转化为具有显式层级先验的 APT-Hier；在模型层，通过欧式—双曲两阶段表示学习充分

利用该层级结构完成攻击偏好预测。因此，后续实验中，APT-Flat 上的结果主要用于分析模型层双空间框架的独立有效性，而 APT-Hier 上的结果则对应本文完整方法的最终任务设定。围绕这一完整方法框架，第四章将进一步从主对比实验和消融实验两个层面，分别验证整体性能与各组件的独立贡献。

4 实验与结果分析

4.1 实验设置

4.1.1 实验数据集与拓扑度量

本研究的实验基础为前期工作构建的 APT-Flat 事实图谱。该图谱通过对开源 APT 攻击报告进行实体抽取与关系增强，形成了包含 11 种客观事实关系的结构化知识库。本实验采用经过二次清洗校验的 APT5K 数据集^[44]，其各关系类型的三元组数量分布如图 4-1 所示。




图 4-1 各关系类型的三元组数量分布

可以观察到，基础事实图谱中的 11 种客观关系呈现出较为明显的长尾分布特征。其中，hasType 属性边（共 1,964 条）占据数量上的绝对主导地位，远超排名第二的 target (314 条)，而关键的攻击行为边（如 exploit、use）则相对稀疏。这种“属性边”显著多于“拓扑边”的数据倾斜现象，在传统欧式空间表示学习中，可能导致模型对高频分类特征产生过度拟合，进而掩盖低频关键攻击关系的特征学习。在此基础上，APT 知识图谱本身固有的“组织 → 战役 → 工具 → 变种”层级结构，亦使欧式空间面临几何拥挤的潜在风险。上述两方面的数据特性，共同构成了本文进行层级化拓扑重构的核心动机。

为缓解上述基础分布带来的表示学习瓶颈，本文通过强类型约束机制引入了单向层

级映射关系，即新增的第 12 种关系 `subClassOf`，由此在 APT-Flat 基础上构建了增强图谱 APT-Hier，旨在为两阶段表示学习的欧式初始化阶段提供结构更加纯净的输入。两个数据集版本的基础统计信息如表 4-1 所示。

表 4-1 实验数据集基础统计信息

数据集	实体	关系	三元组	训练集	验证集	测试集
APT-Flat (前期已有工作)	1476	11	4746	3798	474	474
APT-Hier (本文重构工作)	1483	12	5999	5051	474	474

(注：APT-Hier 新增了 `subClassOf` 关系，故关系总数变更为 12)

所有实验数据按 8:1:1 的比例划分训练集、验证集与测试集。在数据划分设计上，需着重说明以下三点。其一，结构增强的非生成属性：APT-Hier 中新增的层级关系并非通过大语言模型直接生成未知的业务知识，而是基于预定义的本体类型映射规则，将既有实体显式关联至对应的 7 个高层抽象节点，本质上是对原有知识的拓扑重组与层级补全。其二，防止数据泄露的划分原则：大语言模型生成的 1,253 条 `subClassOf` 层级约束三元组仅作为结构正则化信号注入训练集，不参与验证与测试，以保证评估结果的纯净性。同时，考虑到训练集中不同关系类型在分布上存在一定差异（如 `subClassOf` 等结构性关系在训练集中具有一定规模），在训练阶段对相关样本采用了轻量级重采样处理（倍数设为 3），以缓解模型对不同关系关注程度的不均衡问题。该处理仅作用于训练阶段，不改变验证与测试集的原始分布。其三，评估基准的一致性保障：验证集与测试集未包含任何 `subClassOf` 层级增强三元组，模型在测试阶段预测的始终是原始业务语义下的攻击关联事实，从而确保对攻击偏好预测任务泛化能力的评估不受层级先验知识的干扰。具体划分详情如表 4-2 所示。

在完成上述数据集重构与划分后，为客观评估引入第 12 种关系对图谱全局几何形态的影响，本文对重构前后的图谱进行了 Gromov δ -双曲性测算（基于随机抽样， $N = 5000$ 个四元节点组），并引入 FB15k-237 与 WN18RR 作为弱、强层级拓扑参考。测算结果如表 3-5 所示，重构后的 APT-Hier 图谱平均 δ 值由 0.2566 降至 0.1957，表明其结构呈现出更明显的层级特征，与典型层级数据集 WN18RR ($\delta = 0.24$) 处于相近量级。上述几何指标的变化从数据结构角度说明，所引入的层级关系有助于改善图谱的整体几何特性，使其在结构层面更符合双曲嵌入的先验假设，为后续两阶段表示学习实验提供了一定的拓扑基础。需指出的是，该几何指标的改善构成引入双曲空间建模的动机与合理性依据之

表 4-2 APT-Hier 数据集划分详情

数据划分	实体数量	关系种类	三元组数量	占比
训练集 (Train)	1483	12	5051	84.20%
基础事实部分 (Base Facts)	1476	11	3798	63.31%
层级增强部分 (Hierarchy-Enhanced)	7	1	1253	20.89%
验证集 (Valid)	1476	11	474	7.90%
测试集 (Test)	1476	11	474	7.90%
总计 (Total)	1483	12	5999	100.00%

注：实体数量表示该划分中涉及的有效实体集合。训练集中包含新增的 7 个高层抽象节点及 1,253 条 subClassOf 层级关系，仅用于结构建模；验证集与测试集仅保留原始的 1,476 个实体与 11 种事实关系，以保证评估过程的独立性与一致性。

一，但不构成唯一或充分条件，其实际效果仍需结合后续对比实验与消融分析加以验证。

就评估范围而言，为与第 3.1.2 节攻击偏好预测任务定义保持严格一致，本文在第 4 章计算 Hits@k、MRR 等评估指标时，仅针对测试集中关系类型属于偏好子集 $\mathcal{R}_{\text{pref}} = \{\text{target}, \text{use}, \text{exploit}\}$ 的三元组进行排序评估。其余属性类关系（如 hasType、belongsTo 等）在推理过程中作为图网络消息传递的上下文结构特征参与嵌入计算，但不纳入最终指标统计的范围。这一设计旨在使评估结果直接反映模型对核心攻击关联事实的预测能力，而非被任务无关的属性关系所稀释。

4.1.2 评估指标

在量化评估阶段，考虑到 APT 威胁情报分析的真实业务逻辑与通用知识图谱补全任务存在本质差异，本文未采用传统的双向平均评估，而是采用了任务驱动的单向严格过滤评估设定（Task-driven Unidirectional Strict-Filtered Setting）。所有基线模型与本文方法均在此统一设定下进行独立评测，具体细节如下：

（1）单向尾实体预测机制（Unidirectional Tail Prediction）传统模型通常报告头部预测 $(?, r, t)$ 与尾部预测 $(h, r, ?)$ 的平均指标。然而，在 APT 偏好预测任务中， $(?, r, t)$ 属于“已知受害者推断攻击者”的溯源任务，而 $(h, r, ?)$ 属于“已知攻击者预测其潜在目标/工具”的前瞻性偏好预测任务。由于本文的核心目标是偏好预测，因此在测试阶段，针对给定查询 $(h, r, ?)$ ，模型仅执行尾实体检索与排序，不进行双向平均，以确保评估指标能够真实反映模型的前瞻性预警能力。

(2) 全局候选池构造 (Global Candidate Pool) 在为测试三元组 (h, r, t) 构造负样本查询时, 系统采用全量替换策略 (Full-batch evaluation)。即采用图谱中包含的全部实体集合 E ($|E| = 1483$) 作为候选池进行打分排序, 而不局限于特定类型的实体。这一设置模拟了真实防御场景下“大海捞针”的高难度排查过程, 确保了 Hits@k 指标的含金量。

(3) 严格过滤机制 (Strict-Filtered Setting) 为防止已知观测事实对候选排名的干扰, 在对候选集进行降序排列之前, 系统会主动执行严格过滤: 从排序列表中强制剔除所有已客观存在于训练集 T_{train} 、验证集 T_{valid} 以及测试集 T_{test} 中的真实三元组 (除当前测试目标外)。具体而言, 对于查询 $(h, r, ?)$, 实际参与排名的假定尾实体集合 E_{eval} 定义为:

$$E_{eval} = E \setminus \{t' \in E | (h, r, t') \in T_{train} \cup T_{valid} \cup T_{test}\}$$

只有在严格过滤后, 真实尾实体 t 在列表中的排名 $rank_t$ 才被计入最终指标。

(4) 评估指标

平均倒数排名 (Mean Reciprocal Rank, MRR) 衡量模型将正确尾实体排在高位的平均能力, 计算如下:

$$MRR = \frac{1}{|T_{test}|} \sum_{i=1}^{|T_{test}|} \frac{1}{rank_i} \quad (4-1)$$

其中 $rank_i$ 为第 i 条测试三元组正确尾实体的过滤排名, $|T_{test}|$ 为测试集三元组总数。MRR 对排名靠前的正确预测赋予更高权重, 对排名尾部的预测惩罚较小, 适合综合衡量模型的排名质量。

分层命中率 (Hits at k , Hits@ k) 衡量正确尾实体出现在前 k 个候选中的比例:

$$Hits@k = \frac{1}{|T_{test}|} \sum_{i=1}^{|T_{test}|} \mathbb{I}[rank_i \leq k], \quad k \in \{1, 3, 10\} \quad (4-2)$$

其中 $\mathbb{I}[\cdot]$ 为指示函数。Hits@1 衡量精确命中率, 对应确定性推荐场景; Hits@10 对应 Top-10 候选召回, 与安全运营实践中分析师从候选列表中甄别威胁目标或工具的操作流程契合度较高, 因此作为本文的首要比较指标。

平均排名 (Mean Rank, MR) 作为辅助参照指标:

$$MR = \frac{1}{|T_{test}|} \sum_{i=1}^{|T_{test}|} rank_i \quad (4-3)$$

MR 对排名尾部的预测误差线性放大, 对离群预测更为敏感, 与 MRR 和 Hits@k 形成互补参照。

4.1.3 超参数设置与实验环境

模型超参数通过在验证集上进行网格搜索确定，搜索范围如下：嵌入维度 $d \in \{64, 128, 200, 256\}$ ，学习率 $\eta \in \{1 \times 10^{-4}, 5 \times 10^{-4}, 1 \times 10^{-3}, 5 \times 10^{-3}\}$ ，联合损失权重 $\lambda \in \{0.01, 0.05, 0.1, 0.2\}$ ，温度超参数 $\tau \in \{0.05, 0.1, 0.2\}$ 。此外，在双曲阶段中对负采样数量 n_{neg} 进行调节，取值范围为 $\{16, 32, 64, 128\}$ 。

最终选取配置如下：第一阶段（欧式空间 NoGE）：嵌入维度 $d = 256$ ，批大小 $B = 1024$ ，训练轮次 3000，优化器 Adam，学习率 $\eta_1 = 5 \times 10^{-3}$ ，温度超参数 $\tau = 0.1$ ，GNN 层数 $L = 1$ 。该阶段采用基于 1-N 评分机制的全实体预测方式进行训练，不涉及显式负采样。

第二阶段（双曲空间 MuRP）：训练轮次 500，初始学习率 $\eta_2 = 1 \times 10^{-3}$ （余弦退火调度），批大小 $B = 1024$ ，优化器黎曼 Adam（Riemannian Adam），双曲曲率参数 c 初始化为 1.0 并在训练过程中通过梯度下降自适应更新，联合损失权重 $\lambda = 0.1$ ，负采样数量 $n_{neg} = 64$ （均匀采样）。

所有基线模型与本文方法均在相同的数据划分比例、训练环境与固定随机种子下进行训练与评估，以保证不同模型之间的对比条件一致。需要说明的是，当前实验结果主要用于分析各模型在统一设置下的性能趋势，本文不将个别数值差异解释为严格的统计显著结论。为全面考察不同模型在不同图谱结构条件下的表现，本文分别在 APT-Flat 与 APT-Hier 上报告全模型实验结果。

实验在 Google Colab 云环境上完成，操作系统为 Ubuntu 22.04 LTS，编程语言为 Python 3.12，深度学习框架为 PyTorch 2.10（CUDA 12.8）。BERT 特征提取基于 Transformers 5.0.0 库调用 CyBERT 预训练权重。双曲空间相关运算基于 PyTorch 框架实现。

表 4-3 实验环境配置

配置项	参数
操作系统	Ubuntu 22.04 LTS（Google Colab 云环境）
CPU/GPU	Standard CPU / NVIDIA Tesla T4 GPU
内存	System RAM: 12.7 GB GPU VRAM: 15.0 GB
编程语言	Python 3.12.13
开发框架	PyTorch 2.10 (CUDA 12.8)

模型开发与部分预实验在本地 MacOS 环境（Apple M1 芯片，8GB 统一内存）上完成，最终训练与评估统一在 Colab GPU 环境下进行，以保证实验环境的一致性，从而为结果复现提供基础条件。

4.2 对比基线模型

为全面考察本文方法的性能定位，本文选取覆盖欧式嵌入、图神经网络与双曲嵌入三类代表性方法的 7 个基线模型进行对比分析。模型选取遵循以下原则：一是覆盖主流几何空间，形成欧式与双曲的系统性对照；二是在各几何空间内包含参数规模和建模假设各异的多个代表，以避免单一模型的偶然性；三是所有基线模型均有公开代码可供复现。四是在参数规模与过拟合风险之间保持审慎。APT 知识图谱平均节点度数仅约 4.9，属于高稀疏领域图谱。部分结构更复杂的双曲模型（如引入关系旋转矩阵的变体）在此条件下因参数量显著增加而易发生过拟合，反而无法客观反映几何空间的表征极限。本文因此优先选取在参数效率与表达能力之间取得平衡的代表性模型，AttH 的实验结果（见表 4-4）亦从反面印证了这一判断。

4.2.1 欧式空间嵌入模型

TransE 作为平移类模型的开创性工作，结构简洁且计算开销低。该模型将关系建模为头实体到尾实体的平移向量，其评分函数定义为 $f(h, r, t) = -\|\mathbf{h} + \mathbf{r} - \mathbf{t}\|_2$ 。本文将其作为最基础的参照基线，旨在提供一个直观的性能下界，从而清晰地衡量其他复杂双空间融合方法的改进幅度。

ComplEx 同样在复数空间中进行表征，但它采用厄米特内积的实部 $\text{Re}(\langle \mathbf{h}, \mathbf{r}, \mathbf{t} \rangle)$ 作为三元组的合理性评分。该设计巧妙地在建模对称与非对称关系之间取得了平衡。考虑到 ComplEx 的参数规模与 RotatE 相当，但底层的数学建模假设截然不同，将其纳入基线对比，有助于我们横向剖析不同欧式建模范式在高度稀疏的 APT 威胁情报图谱上的适配性差异。

4.2.2 图神经网络模型

CompGCN（Composition-based Multi-Relational GCN）将实体与关系嵌入进行联合更新。作为 R-GCN 等早期图神经网络在多关系场景下的经典拓展，它通过可学习的组合运算（如加法、减法、乘积等）在消息传递中同时建模实体与关系的交互，具有极强的图结构表达灵活性。将其纳入对比，旨在考察在 APT 威胁情报图谱中，引入图结构的邻域聚合机制是否比单纯的欧式平移（如 TransE）带来更显著的性能提升，并为后续评估本文双空间融合机制的结构化建模能力提供参照基准。

NoGE (Node Co-occurrence based Graph Neural Network) 在图神经网络类基线模型中作为对比方法之一, NoGE 面向知识图谱补全任务, 在图结构建模过程中引入实体与关系的共现信息, 以增强嵌入表示的语义表达能力。

与传统基于图神经网络的方法 (如 R-GCN、CompGCN) 主要针对实体节点建模不同, NoGE 将实体与关系统一表示为图中的节点, 并构建包含两者的单一图结构。在此基础上, 通过统计实体与关系在三元组中的共现频率, 构建加权邻接矩阵, 使边权能够反映节点之间的潜在语义关联强度, 从而缓解原始知识图谱结构稀疏带来的信息不足问题。

在编码器设计上, NoGE 提出 Dual Quaternion Graph Neural Network (DualQGNN), 利用对偶四元数空间对节点表示进行更新; 在解码阶段, 结合基于四元数的评分函数对三元组进行打分, 以完成链接预测任务。

基于上述建模方式, NoGE 在结构信息利用方面相较传统 GNN 模型具有一定差异。本文将其作为欧式空间下的图神经网络基线模型之一, 用于与所提出方法进行对比分析。值得说明的是, NoGE 在本文中承担双重角色: 一方面作为欧式空间下的图神经网络基线模型, 用于评估传统结构建模方法在当前数据集上的性能水平; 另一方面作为两阶段表示学习框架的第一阶段编码器, 用于生成欧式空间中的实体初始表示。两种角色共享同一编码逻辑, 可以更为精确地刻画双曲空间建模所带来的结构表达能力提升。

4.2.3 领域语义增强模型

KLEC (Knowledge-enhanced Local Embedding with Contrastive learning) 是面向 APT 威胁情报场景的领域适配方法, 由实验室前期工作提出^[44]。该方法以 CyBERT 对实体进行语义初始化, 结合图结构编码与对比学习机制提升实体表示质量, 在一定程度上缓解了图谱稀疏带来的表示不足问题。

需要强调的是, KLEC 与本文方法在模型定位上存在本质区别。KLEC 的建模仍基于欧式空间, 对图谱中潜在的层级结构刻画相对有限。将其纳入对比的核心目的在于剥离“领域语义预训练”的独立贡献: 本文方法与 KLEC 同样以 CyBERT 进行实体语义初始化, 二者的本质差异在于本文额外引入了离线层级拓扑重构 (数据层) 与双曲测地线解码 (几何层)。若本文方法相较 KLEC 的提升幅度有限, 则说明性能增益主要来自语义预训练而非几何建模; 反之, 则可确认双空间协同设计具有超越领域语义先验的独立贡献。

4.2.4 双曲空间嵌入模型

MuRP (Multi-relational Poincaré Graph Embeddings) 是首个在庞加莱球上进行多关系知识图谱嵌入的代表性方法。该模型将关系建模为双曲空间中的平移操作，其评分函数定义为 $f(h, r, t) = -d_{\mathbb{D}}(\mathbf{h}_H \oplus_{\mathcal{M}} \mathbf{r}_H, \mathbf{t}_H)$ ，其中 $\oplus_{\mathcal{M}}$ 为莫比乌斯加法， $d_{\mathbb{D}}$ 为庞加莱球距离。由于本文的双曲微调阶段采用了相同的底层评分逻辑，MuRP 自然成为了验证本文框架最直接的“纯双曲基线”。通过控制初始化的单一变量（欧式预训练语义初始化 vs 纯双曲随机初始化），可以直接且严格地量化本文所提出的两阶段框架带来的性能增益，代表了纯双曲嵌入在此任务上的性能下界。

AttH (Attention-based Hyperbolic Knowledge Graph Embedding) 在 MuRP 的基础上引入了关系特定的旋转与反射变换，将注意力机制与双曲距离计算结合，理论上能够刻画更丰富的关系模式。本文将其作为双曲基线之一，旨在考察复杂双曲变换机制在高稀疏 APT 图谱场景下的实际表现。如表 4-4 所示，AttH 在本实验设置下的 Hits@10 (0.535) 反而低于结构更简洁的 MuRP (0.621)，印证了第 4.2 节关于“复杂模型在小规模稀疏图谱上易过拟合”的判断：在平均节点度数仅约 4.9 的 APT 图谱中，引入额外的关系变换矩阵不仅无法充分利用邻域信息，反而因参数量增加而加剧了过拟合风险，导致双曲几何的结构优势未能有效转化为预测性能。这一对比结果从反面验证了本文选用 MuRP 作为双曲阶段解码器的合理性——在参数效率与表达能力之间，简洁的距离解码器在中小规模领域图谱上更具鲁棒性。

其中，APT-Flat 上的实验用于分析在不引入层级本体重构条件下，各模型在原始事实图谱上的表示学习与攻击偏好预测能力，重点服务于模型层双空间框架的控制分析；APT-Hier 上的实验则用于分析在引入层级本体重构之后，各类模型对显式层级先验的利用能力。由于本文完整方法由“层级本体重构 + 欧式——双曲两阶段表示学习”共同组成，APT-Hier 上的攻击偏好预测结果对应本文完整方法的主实验设定。

值得注意的是，欧式类模型在 APT-Hier 上的性能表现可作为消融分析中“仅有数据层增强、无双曲建模”配置的参照基准，其结果将在第 4.4 节中进一步分析。此处需要说明的是，传统欧式空间在嵌入具有高度树状层级属性的数据（如 APT-Hier 中大量注入的 subClassOf 关系）时，极易陷入几何拥挤现象，可能导致性能不升反降；这一现象本身亦构成引入双曲空间建模的动机之一，将在后续消融实验中得到定量验证。

4.3 整体性能对比

本节从两个层面评估本文方法的整体性能。第一，在 APT-Flat 上开展全模型对比实验，用于考察在不引入层级本体重构的条件下，各模型在原始事实图谱上的表示学习与攻击偏好预测能力。该组实验主要服务于模型层双空间框架的控制分析。第二，在 APT-Hier 上开展全模型对比实验，用于考察在引入层级本体重构之后，各类模型对显式层级先验的利用能力。由于本文完整方法包含“先进行层级本体重构，再进行欧式——双曲两阶段表示学习”这两个连续步骤，因此，APT-Hier 上的攻击偏好预测结果对应本文完整方法的主对比实验结果。

基于此，本文不将 APT-Flat 上的结果直接视为完整方法的最终主结果，而将其视作模型层独立能力的控制实验；相对应地，APT-Hier 上的攻击偏好预测结果才是本文完整方法在最终任务设定下的主要比较依据。

在以下四组结果中，表 4-4 和表 4-6 对应 APT-Flat 上的控制实验，主要用于分析模型层双空间框架的独立有效性；表 4-5 和表 4-7 对应 APT-Hier 上的完整方法实验，其中表 4-7 的攻击偏好预测结果是本文完整方法的主对比实验结果。所有攻击偏好预测实验的评估范围均严格限定于测试集中关系类型属于 $\mathcal{R}_{\text{pref}} = \{\text{target}, \text{use}, \text{exploit}\}$ 的三元组，候选池为对应数据集的全量实体集合（APT-Flat 中 $|\mathcal{E}| = 1476$ ，APT-Hier 中 $|\mathcal{E}| = 1483$ ）。由于候选池涵盖全量实体且测试三元组仅覆盖三类稀疏关系，任务难度显著高于标准链接预测设定，其绝对指标值不宜与通用 KGC 基准直接比较。

(1) 链路预测结果与基准分析。从表 4-4 可以看出，在未显式引入层级结构的 APT-Flat 图谱上，纯双曲模型 MuRP 在 Hits@10 指标上达到 0.621，略高于表现较好的欧式或图神经网络类基线模型。这一结果表明，即使在未进行层级重构的扁平图谱中，双曲空间仍可能对数据中的长尾分布与潜在弱层级结构具有一定适配性。但需要注意的是，该优势幅度相对有限，说明仅依赖双曲空间本身并不足以充分解决 APT 图谱中的稀疏性与语义不足问题。

(2) 欧式语义初始化的独立增益。在不引入 LLM 层级增强数据的前提下，本文方法仅通过欧式空间的语义初始化与后续双曲建模相结合，在 APT-Flat 上取得 Hits@10 = 0.682 的结果，高于纯双曲模型 MuRP 的 0.621。这说明欧式阶段所学习到的局部语义与邻域结构信息，能够为后续双曲空间训练提供较为稳定的初始表示，从而在一定程度上改善模型的排序性能。这一初始化优势在偏好预测任务中同样成立：在 APT-Flat 偏好预测（表 4-6）中，本文方法取得 Hits@10 = 0.471，高于同等条件下的纯双曲基线 MuRP

表 4-4 APT-Flat 数据集上的通用链接预测结果对比

Model	Hits@10	Hits@3	Hits@1	MRR	MR ↓
<i>Euclidean Models</i>					
TransE	0.462	0.387	0.016	0.208	-
ComplEx	0.466	0.437	0.406	0.427	-
<i>GNN-based Models</i>					
CompGCN	0.542	0.438	0.412	0.443	-
NoGE	0.602	0.535	0.514	0.539	156.82
KLEC	0.606	0.550	0.522	0.546	129.59
<i>Hyperbolic Models</i>					
MuRP	<u>0.621</u>	<u>0.556</u>	<u>0.508</u>	<u>0.546</u>	129.59
AttH	0.535	0.399	0.336	0.398	<u>126.89</u>
<i>Ours w/o Hier.</i>					
MuRP + Euclidean Init	0.682	0.626	0.585	0.577	117.85

注: 表中“-”表示该指标在原实验中未予记录。受框架兼容性所限, 部分 Euclidean 基线模型的 MR 指标暂无法在当前环境下补全, 故保留为空; Hits@k 与 MRR 等核心排序指标完整。

表 4-5 APT-Hier 数据集上的通用链接预测结果对比

Model	Hits@10	Hits@3	Hits@1	MRR	MR ↓
<i>Euclidean Models</i>					
TransE	0.588	0.513	0.481	0.514	272.88
ComplEx	0.590	0.542	0.504	0.533	275.06
<i>GNN-based Models</i>					
CompGCN	0.536	0.454	0.321	0.402	267.93
NoGE	0.604	0.549	0.519	0.544	164.94
KLEC	0.626	0.564	0.287	0.430	209.57
<i>Hyperbolic Models</i>					
MuRP	<u>0.718</u>	<u>0.649</u>	<u>0.592</u>	<u>0.632</u>	126.56
AttH	0.593	0.533	0.500	0.530	280.53
<i>Ours-Full</i>					
MuRP + Euclidean Init	0.731	0.660	0.602	0.643	<u>135.97</u>

表 4-6 APT-Flat 数据集上的攻击偏好预测结果对比

Model	Hits@10	Hits@3	Hits@1	MRR	MR ↓
<i>Euclidean Models</i>					
TransE	0.342	0.302	0.276	0.264	-
ComplEx	0.357	0.328	0.294	0.331	-
<i>GNN-based Models</i>					
CompGCN	0.431	0.402	0.390	0.386	-
NoGE	0.209	0.109	0.100	0.127	398.95
KLEC	0.453	0.417	0.394	0.403	302.74
<i>Hyperbolic Models</i>					
MuRP	<u>0.420</u>	<u>0.336</u>	<u>0.238</u>	<u>0.310</u>	119.89
AttH	0.157	0.113	0.088	0.120	460.43
<i>Ours w/o Hier.</i>					
MuRP + Euclidean Init	0.471	0.377	0.314	0.367	<u>156.06</u>

表 4-7 APT-Hier 数据集上的攻击偏好预测结果对比

Model	Hits@10	Hits@3	Hits@1	MRR	MR ↓
<i>Euclidean Models</i>					
TransE	0.176	0.093	0.044	0.090	413.04
ComplEx	0.176	0.118	0.074	0.111	429.68
<i>GNN-based Models</i>					
CompGCN	0.186	0.147	0.069	0.118	377.14
NoGE	0.196	0.137	0.088	0.127	382.24
KLEC	0.284	0.142	0.082	0.140	380.48
<i>Hyperbolic Models</i>					
MuRP	<u>0.435</u>	<u>0.336</u>	<u>0.252</u>	<u>0.324</u>	146.12
AttH	0.152	0.123	0.098	0.126	442.97
<i>Ours-Full</i>					
MuRP + Euclidean Init	0.514	0.410	0.337	0.428	<u>159.59</u>

(0.420)，说明欧式语义先验对核心任务同样有效。

(3) 整体性能表现与模型差异。从不同类别模型的整体表现来看，传统欧式嵌入方法（如 TransE、ComplEx）在该任务上的性能相对有限；引入图结构建模的 GNN 类方法（如 CompGCN、NoGE）在一定程度上改善了表示能力，但整体提升幅度仍然受限。这可能与 APT 图谱本身的稀疏性有关（平均节点度较低），使得基于局部邻域的聚合机制

难以充分捕获全局结构信息。需要注意的是，NoGE 在通用链接预测与攻击偏好预测两类任务中的表现存在明显差异。在通用链接预测设定下，NoGE 受益于共现结构与整体图连接模式，能够取得较好的表示效果；但在攻击偏好预测任务中，评估范围被严格收缩至 $\mathcal{R}_{pref} = \{target, use, exploit\}$ 这三类相对稀疏的业务关系，而候选池仍为全实体集合。在“关系更稀疏、候选更大、任务更聚焦”的设定下，基于全图共现优势学习到的表示未必能够直接转化为对核心偏好关系的高质量排序，因此其性能下降更为明显。这也说明，面向业务目标的偏好预测与通用链接预测并非完全等价任务。

相比之下，双曲模型在该数据条件下表现出更好的适应性，从结果来看，引入欧式语义初始化后，模型在训练过程中能够获得更为稳定的表示起点，从而在整体性能上取得更优表现。实验结果表明，结合领域语义信息有助于提升双曲空间表示学习的效果。

此外，AttH 模型在 APT-Flat 通用链接预测任务中（表 4-4）的 Hits@10 仅为 0.535。可能的原因在于，其模型结构相对复杂，在当前数据规模与稀疏性条件下未能充分发挥其建模能力。该结果也从侧面反映出，在 APT 组织攻击偏好预测这一任务中，模型结构的复杂度与数据规模之间的匹配关系可能对最终性能产生一定影响。

（4）核心任务偏好预测结果分析。本文在数据层面的核心贡献之一，是构建了面向双曲空间的层级化图谱 APT-Hier。以下对偏好预测结果的分析，同时也是对这一数据构建策略有效性的下游任务验证。比较表 4-6 与表 4-7 可以观察到两点值得关注的现象。

其一，欧式类模型（如 TransE、ComplEx）从 APT-Flat 到 APT-Hier 的偏好预测性能出现下降（Hits@10 分别由 0.342、0.357 降至 0.176、0.176），而本文完整方法在引入层级本体重构后由 0.471 提升至 0.514。该结果说明，在当前实验设置下，数据层层级先验能够为双空间表示学习提供额外结构信号，并对攻击偏好预测性能产生进一步支持作用。与此同时，欧式模型在引入新增 subClassOf 结构后未表现出相同趋势，表明不同几何建模方式对层级结构信号的利用能力存在差异。

其二，在 APT-Hier 偏好预测任务中（表 4-7），双曲基线 MuRP（0.435）相较欧式与 GNN 类基线取得更高的 Hits@10，说明双曲几何在当前层级化 APT 图谱的偏好关系建模中具有较好的适配性；而本文方法（0.514）在 MuRP 基础上进一步提升，说明两阶段欧式——双曲框架相较于纯双曲随机初始化能够提供更稳定的初始化与语义迁移支持。上述结果表明，在当前实验设置下，数据层的 APT-Hier 层级化重构与模型层的两阶段欧式——双曲框架共同促进了攻击偏好预测性能提升；消融结果也显示，去除相关组件后模型在部分关键指标上出现不同程度下降，说明二者之间存在一定协同依赖关系。

需要进一步指出的是,不同指标之间的最优结果并不必然完全一致。在 APT-Hier 攻击偏好预测任务中,完整模型在 Hits@10、Hits@3、Hits@1 与 MRR 上取得了最优或接近最优结果,但 MR 并非最优。这一现象并不与主结论矛盾:MR 对少量尾部极端排名样本高度敏感,而 Hits@10 与 MRR 更能反映模型在前列候选中的检索质量。在本文任务设定下,候选池规模较大 ($|\mathcal{E}| = 1483$)、核心关系 $\mathcal{R}_{pref} = \{target, use, exploit\}$ 相对稀疏,模型即使在大多数样本上实现更好的前列命中,仍可能因少量难样本的长尾误排导致 MR 未同步最优。换言之,完整模型的优势主要体现为前列召回与高位排序质量的改进,而非对全部样本尾部误差的全面压缩。

(5) 核心模型稳定性验证。为进一步观察核心实验结果的稳定性,本文对 APT-Hier 上的代表性模型 MuRP、KLEC 与本文方法分别进行了三次重复实验,并统计链接预测与攻击偏好预测两类任务下 Hits@10 与 MRR 的均值及标准差。Hits@10 用于反映模型在 Top-K 候选推荐场景下的命中能力,MRR 则用于衡量整体排序质量。需要说明的是,受实验资源限制,该稳定性验证尚未覆盖 APT-Flat 控制实验与全部对比基线,因此本文将作为辅助分析,而不作为严格显著性检验依据。结果如表 4-8 所示。

表 4-8 核心模型多随机种子稳定性验证结果

数据集	任务	模型	Hits@10	MRR
APT-Hier	链接预测	KLEC	0.596 ± 0.004	0.542 ± 0.010
APT-Hier	链接预测	MuRP	0.711 ± 0.056	0.631 ± 0.004
APT-Hier	链接预测	Ours	0.727 ± 0.004	0.643 ± 0.001
APT-Hier	偏好预测	KLEC	0.258 ± 0.007	0.151 ± 0.003
APT-Hier	偏好预测	MuRP	0.426 ± 0.034	0.329 ± 0.008
APT-Hier	偏好预测	Ours	0.503 ± 0.018	0.397 ± 0.031

4.4 核心组件有效性与协同分析

本节(表 4-9)从组件移除的角度,系统考察本文完整方法中三个核心组件的独立贡献与协同关系:

- (1) 数据层的层级本体重构;
- (2) 模型层的欧式语义迁移;
- (3) 模型层的双曲空间建模。

通过对完整方法进行分组件消融,本文希望回答以下问题:层级本体重构是否能够提供

稳定的结构收益；欧式语义迁移是否能够改善双曲阶段的优化起点；双曲空间建模是否是将层级结构有效转化为攻击偏好预测能力的关键环节。

表 4-9 核心组件协同分析与消融实验结果

变体配置	几何空间	层级本体重构	欧式初始化	Hits@10	Hits@3	Hits@1	MRR	MR ↓
完整模型 (Ours)	欧式 → 双曲	✓	✓	0.514	0.410	0.337	0.428	159.59
w/o 层级本体重构	欧式 → 双曲	×	✓	0.471	0.377	0.314	0.367	156.06
w/o 语义迁移	纯双曲	✓	×	0.435	0.336	0.252	0.324	146.12
w/o 双曲建模	纯欧式	✓	×	0.284	0.142	0.082	0.140	380.48

注：✓ 表示模型包含该模块，× 表示去除该模块或未使用该数据。其中，“层级本体重构”指通过高层本体框架构建与确定性规则注入得到的 APT-Hier；“欧式初始化”指欧式阶段学习得到的语义表示及其跨空间迁移；“纯欧式”表示保留层级本体重构但不进入双曲空间。

关键发现一：层级本体重构在当前实验设置下提供了稳定的支持性增益。对比完整模型与“w/o 层级本体重构”变体可以看出，在保持欧式——双曲两阶段框架不变的前提下，引入 APT-Hier 后，Hits@10 由 0.471 提升至 0.514，MRR 由 0.367 提升至 0.428。这说明，数据层引入的显式层级先验能够为模型提供额外结构信号，并在当前攻击偏好预测任务中对前列候选排序产生积极影响。

关键发现二：欧式语义迁移能够改善双曲阶段的表示起点。对比完整模型与“w/o 语义迁移”变体可以看出，在均使用 APT-Hier 的前提下，去除欧式初始化后，Hits@10 由 0.514 下降至 0.435，MRR 由 0.428 下降至 0.324。该结果表明，纯双曲模型虽然能够利用层级化图谱中的结构信号，但随机初始化下的双曲优化仍可能受到训练起点不稳定的影响。欧式阶段学习到的局部语义与邻域结构信息能够为双曲空间微调提供更稳定的初始表示，从而提升最终排序性能。

关键发现三：双曲空间建模是层级结构转化为预测能力的关键环节。对比完整模型与“w/o 双曲建模”变体可以看出，在保留层级本体重构的情况下，若仅采用纯欧式建模，Hits@10 下降至 0.284，MRR 下降至 0.140，性能下降幅度最为明显。该结果说明，仅在数据层引入层级结构并不足以保证模型能够有效利用该结构；需要与能够表达层级拓扑的双曲空间建模相结合，才能将 APT-Hier 中的层级先验进一步转化为攻击偏好预测能力。

综合来看，表 4-9 中三类变体的结果表明，数据层层级本体重构、欧式语义迁移与双曲空间建模并非彼此孤立地发挥作用，而是在完整框架中形成了互补关系。层级本体重构提供结构先验，欧式语义迁移提供较稳定的语义初始化，双曲空间建模则承担层级

结构表达与排序优化的主要作用。任一组件缺失均会削弱最终性能，其中去除双曲建模带来的下降最为明显。

此外，表 4-9 中不同指标的变化趋势进一步说明，完整模型的优势主要体现在将正确候选推入前列的能力上，而非在所有样本上严格降低长尾排名误差。特别是在候选空间较大且偏好关系相对稀疏的情况下，少量困难样本可能对 MR 产生较大扰动，但不会改变 Hits@10 与 MRR 所反映出的总体优势。因此，本文将 Hits@10 作为首要指标、MRR 作为综合排序指标、MR 作为辅助参照指标，与攻击偏好预测任务的 Top-K 推荐式应用目标相匹配。

4.5 双曲空间中的实体径向分布与语义解释

前文的全局指标表明，本文方法在整体图谱的链接预测任务上具有一定的性能优势。然而，鉴于本文的核心业务目标被严格约束为“攻击偏好预测”，本节将测试空间收缩至 $\mathcal{R}_{pref} = \{target, use, exploit\}$ 这三大核心意图关系，深入剖析双曲流形在处理不同抽象层级业务语义时的几何聚类特性与收敛边界。

关于核心偏好关系的测地线分布特性，在双曲流形 $\mathbb{B}_c^d$ 中，不同关系的语义平移向量 $\mathbf{r}_H$ 引导实体在特定的径向区间内形成局部聚类。基于本文构建的两阶段模型输出，我们对测试集中三大偏好关系的正确预测对 (h, r, t) 中尾实体的径向位置分布进行了统计，结果如图 4-2 所示。整体来看，target、use、exploit 三类偏好关系的尾实体径向分布较为接近，中位数均集中在 $\square \approx 0.65 \square 0.70$ 区间。这一观察可从两个角度加以解读。

第一，从几何收敛性角度看，三类偏好关系的尾实体均稳定落于庞加莱球的中外层区域，既未塌缩至球心附近（这将削弱不同实体间的可区分性），亦未过度逼近双曲流形边界（该区域梯度衰减剧烈，易引发数值不稳定）。这表明在层级本体重构与两阶段表示学习的共同作用下，模型对偏好关系的几何编码具有较好的稳定性。这一收敛特性与模型在主实验中表现出的稳定排序能力相一致。

第二，从语义层级角度看，三类偏好关系的尾实体在径向维度上的差异并不显著，这一现象与本文层级本体的结构设计内在自洽。三类关系所指向的高层抽象节点——Context(目标行业)、Attack_Resource(攻击工具)与 Methodology(攻击技法)——在本文的层级本体设计中均处于中间抽象层级，既非顶层战略实体（如 APT 组织），亦非底层观测指标（如 Hash 值），因此其下属尾实体在径向维度上接近是合理的。此外，本文采用的 MuRP 评分函数基于双曲距离监督，主要约束正负样本对的相对距离关系，并不显式强制尾实体按关系类型分布到不同径向区间。因此，三类关系的语义分异更多体现在双曲流




图 4-2 不同偏好关系在庞加莱球中的径向距离分布

形的角度维度上,而非径向维度。受限于双曲空间高维投影的可视化复杂度,角度维度的精细分析未在本文中展开,可作为后续研究的延伸方向。

4.6 层级约束注入规模敏感性分析

为考察模型性能对层级约束注入规模的依赖程度及边际效益的变化趋势,本节设计数据缩放实验。在保持模型架构与全部超参数不变的条件下,将注入的 1,253 条 LLM 层级约束三元组按 0%、25%、50%、75%、100% 五个比例依次取子集(子集通过对全量约束按关系类型比例分层抽样获得,以维持各关系类型的分布稳定性),各比例配置下独立训练并在相同测试集上评估。需要指出的是,上述 0% 至 100% 的五组配置均基于本文提出的双空间模型架构,仅在先验层级约束的注入规模上存在差异。

由表 4-10 可见,随着层级约束注入比例由 0% 提高至 100%,模型的 Hits@10 由 0.471 提升至 0.514,累计提升 0.043。虽然该提升幅度并不表现为剧烈增长,但整体趋势表明,在当前实验设置下,逐步引入高层语义约束能够为攻击偏好预测任务提供一定的辅助结构信号。由于这些约束关系建立在前期高层本体框架之上,因此该实验支持的是“数据层层级本体重构结果”的有效性,而非某一单独工具的在线生成能力。

从工程落地与实用角度来看,在仅注入 25% (约 313 条) 高层约束关系时,模型 Hits@10 由基准配置下的 0.471 提升至 0.481,对应累计增益为 0.010,约占最终总增益

表 4-10 层级约束注入规模敏感性实验结果

层级约束 注入比例	约束数量 (条)	Hits@10	MRR	累积增益 $\Delta\text{Hits@10}$	累计增益 占比
0% (无约束基准)	0	0.471	0.367	—	0.0%
25%	313	0.481	0.357	+0.010	23.3%
50%	627	0.485	0.371	+0.014	32.6%
75%	940	0.500	0.406	+0.029	67.4%
100% (全量注入)	1,253	0.514	0.428	+0.043	100.0%

的 23.3%。这表明，即使在约束注入规模较小的情况下，受控层级关系仍能够为攻击偏好预测任务提供一定的辅助结构信号。

随着注入比例进一步提升，模型整体性能继续改善。当注入比例达到 75%（约 940 条）时，Hits@10 提升至 0.500，对应累计增益为 0.029，约占最终总增益的 67.4%；在全量注入 100%（约 1,253 条）时，Hits@10 达到 0.514，MRR 达到 0.428，均为当前实验设置下的最优结果。该结果说明，在本实验范围内，增加 LLM 约束注入比例并未引发明显的性能退化，完整注入配置仍具有更优的预测表现。

值得注意的是，不同注入阶段的增益幅度并不完全均匀，且 MRR 在低比例注入阶段存在一定波动。例如，当注入比例由 0% 提升至 25% 时，Hits@10 略有提升，但 MRR 由 0.367 下降至 0.357。这表明，层级约束注入的早期作用更可能首先体现在提高正确候选进入前 10 名的概率，而未必能同步提升正确候选在前几位的精细排序位置。换言之，在约束数量较少时，模型的收益更偏向”粗粒度召回改善”，而非”细粒度排序优化”。随着注入比例继续增加，层级信号逐渐丰富，模型才在 Hits@10 与 MRR 两个层面同时获得更稳定的改善。

此外，本节所观察到的整体上升趋势，可视为对前文层级重构质量分析与拓扑结构分析的补充支持。前者从增强规模敏感性的角度表明，在当前注入范围内，高层约束关系的逐步加入未造成明显的噪声累积或整体性能退化；后者则从本体映射规则、语义一致性验证与图谱拓扑变化等角度说明，所注入层级关系整体具有一定的结构合规性与语义一致性。二者共同表明，本文采用的 LLM 受控重构策略在当前 APT 图谱规模与实验设置下能够提供一定的有效辅助信息，但其泛化性仍需在更大规模数据集或更多任务场

景中进一步验证。

4.7 本章小结

本章围绕欧式——双曲两阶段表示学习框架，在 APT-Flat 与 APT-Hier 两个数据集上开展了系统性验证。实验结果表明，在当前实验设置及 APT 组织攻击偏好预测任务下，本文完整模型在 APT-Hier 数据集上取得 Hits@10 = 0.514、MRR = 0.428 的结果，整体优于多数对比基线。

总体而言，本章实验从两个层面对完整方法框架进行了验证。一方面，APT-Flat 上的实验表明，欧式——双曲两阶段表示学习在不引入层级本体重构的条件下，已表现出相较部分纯欧式或纯双曲基线的性能优势；另一方面，APT-Hier 上的实验进一步表明，当数据层的层级本体重构与模型层的双空间表示学习共同作用时，完整方法在 Hits@10、Hits@3、Hits@1 与 MRR 等前列排序指标上取得较优表现。消融实验与敏感性分析进一步说明，在当前实验设置下，层级本体重构、欧式语义迁移与双曲建模均对模型性能具有不同程度的支持作用，并呈现出一定协同依赖关系。由此可见，本文提出的并非单独的双曲模型或单独的数据增强策略，而是一个由数据层与模型层共同构成的攻击偏好预测框架。

需要说明的是，上述结论主要基于当前的 APT 垂直领域图谱得出，其在通用大规模知识图谱上的表现仍有待进一步观察。

5 总结与展望

5.1 本文工作总结

本文围绕 APT 组织攻击偏好预测任务，提出了一个由数据层层级本体重构与模型层欧式——双曲两阶段表示学习共同构成的完整方法框架。首先，在数据层通过高层本体框架构建与确定性规则注入，将原始 APT-Flat 重构为具有显式层级先验的 APT-Hier；随后，在模型层利用欧式——双曲两阶段表示学习充分建模该层级结构与攻击偏好关系。实验结果表明，该完整方法在 APT-Hier 上的攻击偏好预测任务中，在 Hits@10、Hits@3、Hits@1 与 MRR 等前列排序指标上取得较优表现，说明层级本体重构与欧式——双曲两阶段表示学习能够提升模型对核心攻击偏好关系的候选排序能力。需要指出的是，该优势主要体现在前列召回与高位排序质量上，而非所有排名指标均取得最优。主要工作总结如下。

(1) 提出了先验本体约束与双曲几何协同的双空间表示学习方法。针对前期基础图谱 APT-Flat 拓扑结构偏扁平化、以及欧式空间在层级扩张拓扑下几何容量受限的问题，本文将面向双曲几何的层级本体重构与欧式——双曲两阶段表示学习统一在同一方法框架内：一方面以 Gromov δ -双曲性为量化判据、以“语义—数量正交解耦”径向锚定机制为设计依据，为图谱注入面向双曲空间的结构归纳偏置（重构后 APT-Hier 的 Gromov δ 值由 0.2566 降至 0.1957，树状拓扑特性得到强化）；另一方面通过指数映射将欧式阶段学习到的局部语义与邻域结构平滑迁移至庞加莱球，以测地线距离完成全局层级结构的精细化建模。消融实验表明，该结构先验只有在与双曲建模协同时才能转化为预测性能，二者构成强耦合而非相互独立的关系。

(2) 构建了面向层级结构的 APT-Hier 基准与任务驱动的评估协议。本文提出一套可复现的层级化重构协议，在不引入外部新实体的前提下，采用人工校验后的确定性映射规则生成 1,253 条 subClassOf 层级三元组，得到包含 1,483 个实体、5,999 条三元组的 APT-Hier 基准；该协议将大语言模型严格限定于高层语义归纳环节，规避了开放域生成的事实幻觉与语义漂移风险。同时，针对攻击偏好预测任务的前瞻性特征，本文设计了任务驱动的单向严格过滤评估协议，使评估结果能够真实反映模型对核心攻击偏好关系的排序能力。

5.2 研究局限性

尽管本文方法在当前实验设置下取得了较好的性能表现，但受限于数据规模、实验资源与任务设定，仍存在以下几方面局限性。

第一，数据规模与图谱来源仍限制了结论的外推范围。本文构建的 APT-Hier 包含 1,483 个实体与 5,999 条三元组，与通用知识图谱基准相比规模仍然偏小，测试集规模也限制了统计结论的外推能力。此外，本文实验主要围绕 APT-Flat 与 APT-Hier 两类图谱展开，虽然能够较清晰地区分数据层重构与模型层建模的贡献，但结论仍主要建立在当前图谱结构与数据分布条件下。后续研究有必要在更大规模 APT 图谱、不同威胁情报来源以及多种层级构造策略下进一步验证方法的泛化性。

第二，实验验证的充分性仍有进一步提升空间。受实验资源与时间限制，本文仅在核心数据集 APT-Hier 上对部分代表性模型进行了三次重复实验与稳定性观察，尚未覆盖 APT-Flat 控制实验、全部对比基线及系统显著性检验。因此，本文更强调方法在当前实验设置下呈现出的性能趋势与结构性差异，而不将个别数值差异解释为严格的统计显著结论。此外，本文基线选取主要覆盖欧式嵌入、图神经网络、领域语义增强与双曲嵌入四类代表性方法，尚未纳入 KG-BERT 类文本增强知识图谱嵌入模型以及 HGCN 等纯双曲图神经网络模型^[55,56]。前者在小规模 APT 图谱上可能面临过拟合与训练成本较高的问题，后者则更依赖较密集的图结构以发挥邻域聚合优势。后续研究可在更充分的数据规模与计算资源条件下进一步扩展基线范围，并补充稳定性检验。

第三，两阶段表示学习框架仍存在进一步联合优化的空间。本文中欧式阶段与双曲阶段的超参数目前相互独立搜索，尚未形成端到端的联合优化机制。尽管指数映射能够实现从欧式空间到双曲空间的平滑投影，但欧式阶段最优的嵌入维度、邻域聚合层数等配置，未必与双曲阶段的层级结构微调目标完全一致，因此仍可能存在一定的次优化风险。未来可进一步探索面向双空间表示学习的联合训练机制与参数协同优化策略。

第四，本文方法目前仍主要面向静态知识图谱场景，在面对动态演化与新型未知威胁时存在一定的应用局限。从模型假设来看，本文所构建的双空间表示学习方法本质上依赖于闭集假设（Closed-world Assumption），即主要针对训练阶段图谱中已存在的实体与关系进行嵌入计算与排序推理。然而，实际威胁情报场景中，APT 组织会随时间更新工具链、攻击策略与目标偏好，图谱中的实体与关系具有明显时效性；更进一步，攻击者还可能不断引入完全新型、图谱中未曾出现过的攻击节点（即 OOV 节点）。由于缺乏此类新型节点在图谱中的先验拓扑信息与历史特征表示，当前框架难以直接将其纳入既

有的欧式——双曲双空间进行计算，从而难以对此类零样本（Zero-shot）攻击行为做出准确的偏好预测。这一问题既是本文方法在动态威胁场景下面临的具体限制，也是现阶段基于结构化图数据的威胁情报分析所面临的普遍技术瓶颈，如何将时序演化信息与开放世界假设共同纳入表示学习框架，仍有待进一步研究。此外，本文在实验中观察到，基于欧式空间假设设计的 InfoNCE 损失在双空间框架中的效果并不稳定，说明现有对比学习目标可能尚未充分适配双曲空间的几何结构。该现象可能与 InfoNCE 损失中的欧式距离假设和双曲空间的层级几何结构不完全一致有关，但仍需后续从测地距离、曲率约束与层级内聚性角度进一步验证。

5.3 未来研究展望

基于上述局限性分析，本文认为以下几个方向值得进一步深入研究。

一是面向动态与开放世界 APT 知识图谱的时序与归纳式表示学习。现实威胁情报不仅具有强烈的时序特征，还具有显著的开放性：攻击组织的工具更替、战术演化以及新型攻击手法的出现均以时间为轴不断发展，且持续伴随完全未见过的实体涌入图谱。未来的研究可在本文两阶段框架的基础上，一方面引入时序双曲嵌入机制，对实体嵌入赋予时间维度的动态分量，使模型能够感知 APT 组织行为模式的演化规律^[57-59]；另一方面，探索面向 OOV 节点的归纳式（Inductive）嵌入与零样本表示学习策略，例如借助文本语义特征、子图结构归纳或邻域聚合机制为新增实体动态生成初始双空间表示，从而突破闭集假设的限制，提升模型对新兴攻击向量的预测与泛化能力。此外，针对本文实验中观察到的 InfoNCE 损失在双空间框架中效果不稳定的问题，未来可进一步探索面向双曲空间的对比学习目标，例如基于测地距离、曲率约束与层级内聚性的正负样本构造方式，以提升对比学习机制与负曲率几何结构之间的适配性。

二是多模态威胁情报的知识图谱融合建模。当前 APT 知识图谱主要依赖文本类威胁情报报告，而实际情报来源还包括网络流量日志、二进制样本的静态特征（如 PE 文件头信息、导入表）与动态行为序列（如系统调用轨迹）等多模态数据。如何设计统一的多模态编码框架，将不同模态的特征有效融入知识图谱的实体表示中，是提升 APT 归因与 APT 组织攻击偏好预测精度的重要路径^[60,61]。

三是更大规模 LLM 辅助本体重构与主动学习的协同。本文将 LLM 的作用限定于知识图谱初始化阶段的高层语义归纳与本体框架设计，后续底层关系注入与攻击偏好预测主要依赖确定性规则和轻量级图表示学习模型完成。随着图谱规模扩大，若进一步引入 LLM 参与新增实体语义归类、复杂歧义样本判断或跨源情报对齐，其调用成本与人工校

验成本仍可能随候选范围增长而上升。未来可引入主动学习框架，优先选择不确定性较高或信息增益较大的实体与关系样本进行 LLM 辅助判断，从而在有限推理预算下提升层级约束的质量与覆盖率。与此同时，随着更强推理能力的开源 LLM 不断涌现，探索本地部署模型替代闭源 API 以降低成本并保障数据安全，亦具有重要的实践意义。

四是跨域知识图谱预训练与域自适应。不同网络安全子领域（如漏洞管理、恶意软件分析、网络入侵检测）的知识图谱在实体语义与关系类型上存在一定共性，但各自的标注数据均较为稀缺。如何基于本文构建的 APT 知识图谱嵌入框架，通过跨域预训练与域自适应微调，将威胁知识适配至其他安全子域任务，是提升安全知识图谱应用广度的重要研究方向^[62]。在更大规模跨域安全知识图谱条件下，也可进一步纳入 KG-BERT^[55]、HGCN^[56] 等模型进行系统对比，以检验不同文本增强与非欧图神经网络方法在安全领域稀疏图谱上的适用边界。

五是可解释性增强与安全运营落地。本文方法目前以链接预测精度作为核心评估指标，但在实际安全运营场景中，分析师通常还需要理解预测结论的推理依据，以判断其可信度并作出响应决策。未来可结合注意力机制可视化、路径推理解释以及证据三元组溯源等技术，为本文框架的预测结果提供可解释的推理链条，从而促进知识图谱链接预测技术在真实威胁情报分析 workflow 中的落地应用^[63,64]。

附录

A.1 LLM 辅助高层语义归纳的预研验证

为探究结合关系语境是否能有效应对实体多义性挑战，本文在正式进行高层语义抽象之前，设计了面向闭集语境的预研验证实验。该实验主要用于评估大语言模型在给定候选类别集合与三元组上下文条件下，对 APT 领域实体语义角色进行辅助判别的能力。

为探究结合关系语境是否能有效应对实体多义性挑战，并在后续重构中引入大语言模型提供客观依据，本文在原始基础图谱的训练集中开展了一项预研验证 (Pilot Study)。我们在训练集中随机抽取了 100 个具有多重语义的实体样本，仅提供其真实三元组语境，要求大语言模型在闭集约束下独立推断其所属的语义角色 (典型案例如表 A-1 所示)。

测试结果如表 A-2 所示，在闭集约束与关系语境辅助下，大语言模型在 100 个多义实体样本上的语境消歧准确率为 81.00%。这一结果表明，LLM 在 APT 语境下的高层语义判别任务中具有一定的辅助价值，可为后续高层抽象节点的语义归纳提供参考。

需要强调的是，上述预研验证的作用在于说明 LLM 适合作为高层语义归纳的辅助工具，而非证明其可以直接稳定地产生结构化事实关系。特别地，该结果不构成对后续 1,253 条 subClassOf 注入关系逐条正确性的直接证明。基于这一认识，本文在正式图谱重构阶段并未采用开放域关系生成，而是采用“LLM 辅助高层抽象 + 人工校验的确定性规则注入”的策略，以在利用语义归纳能力的同时，降低事实幻觉与结构噪声风险。

为进一步说明语境级验证样本的覆盖范围，本文从 7 个高层抽象节点中抽取共 100 个样本进行复核，样本分布如表 A-3 所示。该验证并非用于重新训练模型，而是用于检查 LLM 归纳得到的高层抽象框架在典型 APT 语境下是否存在明显边界混淆。进一步分析发现，尽管语境信息能够提升实体归类的一致性，但部分实体仍然具有多角色语义特征，在开放式语境判断中容易出现边界模糊现象。表 A-4 给出了若干典型歧义案例。可以看到，部分实体在攻击资源、网络指示器、攻击方法、攻击主体与上下文背景之间存在语义交叉。例如，C&C server 既可被理解为攻击基础设施资源，也可被视为网络侧指示器;Base64 与 XOR key 既可能作为工具性资源出现，也可能在攻击过程描述中承担技术方法语义;安全厂商或组织实体则容易在攻击主体、情报来源与上下文背景之间产生角色混淆。

上述现象说明，若直接依赖 LLM 对底层实体进行开放式归类，并将其输出结果作

表 A-1 预研验证：典型多角色实体在不同三元组语境下的消歧测试

测试实体	输入三元组语境 (Context)	LLM 归纳高层抽象节点	判定依据/逻辑
Cobalt Strike	(APT29, use , Cobalt Strike)	Attack_Resource	识别为被调用工具 (use 关系约束)
Cobalt Strike	(Cobalt Strike, hasType , Tool)	Attack_Resource	识别为属性归属 (hasType 属性对齐)
PowerShell	(Lazarus, use , PowerShell)	Attack_Resource	识别为载体资产 (use 尾实体约束)
PowerShell	(PowerShell, hasAlias , possh)	Attack_Resource	识别为实体别名 (hasAlias 实体对齐)
Phishing	(Campaign_A, use , Phishing)	Methodology	识别为攻击动作 (use 关系作用于 ACT)
Phishing	(Phishing, indicate , Malware_X)	Methodology	识别为技战法 (indicate 指标特征)

表 A-2 高层抽象节点语义一致性验证结果

验证类型	样本来源	样本数	正确数	准确率
名称级验证	Valid/Test	100	70	70.00%
语境级验证（本文）	Valid/Test	100	81	81.00%

为事实关系注入图谱，可能会引入语义边界不清的问题。基于此，本文并不采用大语言模型进行端到端的开放域关系生成，而是将其功能限定在高层抽象节点归纳与本体框架设计阶段; 底层实体到高层抽象节点之间的 subClassOf 关系，则由人工校验后的确定性映射规则完成注入。该设计在利用 LLM 语义归纳能力的同时，降低了开放域生成带来的事实幻觉与拓扑噪声风险。

表 A-3 高层抽象节点语境级验证样本分布

高层抽象节点	样本数
Strategic_Core	15
Attack_Resource	22
Methodology	16
Target_System	11
Context	15
IOC_Network	10
IOC_Hash	11

表 A-4 高层抽象节点映射中的典型语义歧义案例

实体	人工校验归属	LLM 语境判断结果	是否一致	歧义说明
C&C server	Attack_Resource	IOC_Network	×	资源与网络指示器语义重叠
Base64	Attack_Resource	Methodology	×	工具与技术手段语义交叉
XOR key	Attack_Resource	Methodology	×	加密工具与攻击方法边界模糊
Cisco Talos	Strategic_Core	Context	×	安全厂商与攻击主体语义区分不明确
gaming studios	Context	Target_System	×	行业背景与攻击目标角色混淆
Border Guard	Context	Target_System	×	组织实体在目标与背景间存在歧义

参考文献

- [1] HUTCHINS E M, CLOPPERT M J, AMIN R M, et al. Intelligence-driven computer network defense informed by analysis of adversary campaigns and intrusion kill chains[J]. Leading Issues in Information Warfare & Security Research, 2011, 1(1): 80.
- [2] 绿盟科技. 高级威胁研究报告 (2025 版) [EB/OL]. (2025-04-03)[2026-04-10]. https://www.nsfocus.com.cn/html/2025/92_0403/226.html.
- [3] ELLINITAKIS R A, FYSARAKIS K, BOUNTAKAS P, et al. Uncovering hidden threats: Automated, machine learning-based discovery & extraction of cyber threat intelligence from online sources[C] // 2024 IEEE International Conference on Cyber Security and Resilience (CSR). 2024: 1 - 6.
- [4] AL-SADA B, SADIGHIAN A, OLIGERI G. MITRE ATT&CK: State of the art and way forward[J]. ACM Computing Surveys, 2024, 57(1): 1 - 37.
- [5] DANH L T K, XUAN C D, VAN N N. Advancing APT detection through transformer-driven feature learning and synthetic data generation[J]. Scientific Reports, 2026.
- [6] 双子座实验室. 2024 年下半年全球主要 APT 攻击活动报告 [R/OL]. [S.l.]: 双子座实验室, 2025. <https://www.tj-un.com/pdf/2024H2APTReport.pdf>.
- [7] HOGAN A, BLOMQVIST E, COCHEZ M, et al. Knowledge graphs[J]. ACM Computing Surveys (Csur), 2021, 54(4): 1 - 37.
- [8] JORDAN B, PIAZZA R, DARLEY T. STIX Version 2.1[R/OL]. [S.l.]: Organization for the Advancement of Structured Information Standards (OASIS), 2021. <https://www.oasis-open.org/standard/6426/>.
- [9] REN Y, XIAO Y, ZHOU Y, et al. CSKG4APT: A cybersecurity knowledge graph for advanced persistent threat organization attribution[J]. IEEE Transactions on Knowledge and Data Engineering, 2022, 35(6): 5695 - 5709.
- [10] SARHAN I, SPRUIT M. Open-cykg: An open cyber threat intelligence knowledge graph[J]. Knowledge-based systems, 2021, 233: 107524.

- [11] RASTOGI N, DUTTA S, ZAKI M J, et al. Malont: An ontology for malware threat intelligence[C] // International workshop on deployable machine learning for security defense. 2020: 28 - 44.
- [12] 高见, 王安. 基于本体的网络威胁情报分析技术研究 [J]. 计算机工程与应用, 2020, 56(11): 112 - 117.
- [13] 亓玉璐, 江荣, 荣星, 等. 基于网络安全知识图谱的天地一体化信息网络攻击研判框架 [J]. 天地一体化信息网络, 2021, 2(3): 57 - 65.
- [14] YANG Y, ZHAO Y. Network security threat intelligence modeling based on knowledge graph[C] // 2024 5th International Conference on Computer, Big Data and Artificial Intelligence (ICCBD+ AI). 2024: 154 - 158.
- [15] MOUICHE I, SAAD S. Entity and relation extractions for threat intelligence knowledge graphs[J]. Computers & Security, 2025, 148: 104120.
- [16] 赖清楠, 金建栋, 周昌令. 基于大语言模型的网络威胁情报知识图谱构建技术研究 [J]. 通信学报, 2024, 45(S2): 33 - 43.
- [17] 许智双, 张昆, 范俊超, 等. 基于本体的网络安全知识图谱构建方法 [J]. 信息网络安全, 2025, 25(03): 451 - 466.
- [18] 黄智勇, 刘昕宇, 林仁明, 等. 基于知识图谱的网络攻击预测方法研究及应用 [J]. 现代电子技术, 2024, 47(09): 91 - 96.
- [19] 辛瑞雯, 高云. 基于知识图谱技术的计算机网络链路漏洞检测研究 [J]. 现代电子技术, 2025, 48(01): 97 - 101.
- [20] BORDES A, USUNIER N, GARCIA-DURAN A, et al. Translating embeddings for modeling multi-relational data[C] // Advances in neural information processing systems: 26. 2013.
- [21] WANG Z, ZHANG J, FENG J, et al. Knowledge graph embedding by translating on hyperplanes[C] // Proceedings of the AAAI conference on artificial intelligence: 28. 2014.
- [22] LIN Y, LIU Z, SUN M, et al. Learning entity and relation embeddings for knowledge graph completion[C] // Proceedings of the Twenty-Ninth AAAI Conference on Artificial Intelligence. 2015: 2181 - 2187.
- [23] SUN Z, DENG Z-H, NIE J-Y, et al. RotatE: Knowledge Graph Embedding by Relational Rotation in Complex Space[C] // International Conference on Learning Representations. 2019.

- [24] ZHANG S, TAY Y, YAO L, et al. Quaternion knowledge graph embeddings[C] // Advances in Neural Information Processing Systems : 32. 2019.
- [25] CAO Z, XU Q, YANG Z, et al. Dual quaternion knowledge graph embeddings[C] // Proceedings of the AAAI conference on artificial intelligence : 35. 2021 : 6894 - 6902.
- [26] SCHLICHTKRULL M, KIPF T N, BLOEM P, et al. Modeling relational data with graph convolutional networks[C] // European semantic web conference. 2018 : 593 - 607.
- [27] VASHISHTH S, SANYAL S, NITIN V, et al. Composition-based Multi-Relational Graph Convolutional Networks[C] // International Conference on Learning Representations. 2020.
- [28] YANG L, YE A, LIU Y, et al. APTREC: APT tactic/technique recognition based on large language model[J]. Computer Networks, 2026, 280 : 112146.
- [29] CHEN S, CHENG H, LIU X, et al. Pre-training transformers for knowledge graph completion[EB/OL]. 2023. <https://arxiv.org/abs/2303.15682>.
- [30] NICKEL M, KIELA D. Poincaré embeddings for learning hierarchical representations[C] // Advances in Neural Information Processing Systems. 2017 : 6338 - 6347.
- [31] YANG M, ZHOU M, YING R, et al. Hyperbolic representation learning: Revisiting and advancing[C] // International conference on machine learning. 2023 : 39639 - 39659.
- [32] WANG S, WEI X, DOS SANTOS C N, et al. Knowledge graph representation via hierarchical hyperbolic neural graph embedding[C] // 2021 IEEE International Conference on Big Data (Big Data). 2021 : 540 - 549.
- [33] 陈兴蜀, 曾雪梅, 王文贤, 等. 基于大数据的网络安全与情报分析 [J]. 工程科学与技术, 2017, 49(03): 1 - 12.
- [34] 甄珍, 高见, 宋佳林. 中文网络安全威胁情报实体关系抽取 [J]. 科学技术与工程, 2025, 25(24): 10344 - 10350.
- [35] YANG B, YIH W-T, HE X, et al. Embedding entities and relations for learning and inference in knowledge bases[EB/OL]. (2014). <http://arxiv.org/abs/1412.6575>.
- [36] TROUILLON T, WELBL J, RIEDEL S, et al. Complex embeddings for simple link prediction[C] // International conference on machine learning. 2016 : 2071 - 2080.
- [37] BALAŽEVIĆ I, ALLEN C, HOSPEDALES T. Tucker: Tensor factorization for knowledge graph completion[C] // Proceedings of the 2019 conference on empirical methods in

- natural language processing and the 9th international joint conference on natural language processing (EMNLP-IJCNLP). 2019 : 5185 - 5194.
- [38] DETTMERS T, MINERVINI P, STENETORP P, et al. Convolutional 2d knowledge graph embeddings[C] // Proceedings of the AAAI conference on artificial intelligence : 32. 2018.
- [39] Van der MAATEN L, HINTON G. Visualizing data using t-SNE.[J]. Journal of machine learning research, 2008, 9(11).
- [40] KIPF T N, WELING M. Semi-Supervised Classification with Graph Convolutional Networks[C] // International Conference on Learning Representations. 2017.
- [41] VELIČKOVIĆ P, CUCURULL G, CASANOVA A, et al. Graph Attention Networks[C/OL] // International Conference on Learning Representations. 2018. <https://openreview.net/forum?id=rJXMfas0W>.
- [42] NGUYEN D Q, TONG V, PHUNG D, et al. Node co-occurrence based graph neural networks for knowledge graph link prediction[C] // Proceedings of the fifteenth acm international conference on web search and data mining. 2022 : 1589 - 1592.
- [43] RANADE P, PIPLAI A, JOSHI A, et al. Cybert: Contextualized embeddings for the cybersecurity domain[C] // 2021 IEEE international conference on big data (Big Data). 2021 : 3334 - 3342.
- [44] 方洁凤. 基于知识图谱的 APT 组织攻击偏好预测 [D]. [S.l.] : 暨南大学, 2023.
- [45] GANEA O, BÉCIGNEUL G, HOFMANN T. Hyperbolic neural networks[C] // Advances in neural information processing systems : 31. 2018.
- [46] BALAZEVIC I, ALLEN C, HOSPEDALES T. Multi-relational poincaré graph embeddings[C] // Advances in neural information processing systems : 32. 2019.
- [47] CHAMI I, WOLF A, JUAN D-C, et al. Low-dimensional hyperbolic knowledge graph embeddings[C] // Proceedings of the 58th annual meeting of the association for computational linguistics. 2020 : 6901 - 6914.
- [48] 郭漩, 张金雪, 魏伊冰, 等. 大语言模型提示学习增强的轨迹知识图谱构建方法 [J]. 地球信息科学学报, 2025, 27(12): 2789 - 2801.
- [49] CHEN X, LU T, WANG Z. Llm-align: Utilizing large language models for entity alignment in knowledge graphs[EB/OL]. 2024. <https://arxiv.org/abs/2412.04690>.

- [50] ZHAO R, ZHAO F, ZHANG H. Correcting on Graph: Faithful Semantic Parsing over Knowledge Graphs with Large Language Models[C] // Findings of the Association for Computational Linguistics: ACL 2025. 2025 : 5364 - 5376.
- [51] WANG X, CHEN Z, WANG H, et al. Large Language Model Enhanced Knowledge Representation Learning: A Survey: X. Wang et al.[J]. Data Science and Engineering, 2025, 10(3): 315 - 338.
- [52] NASEEM T, XU G, SWAMINATHAN S, et al. A grounded preference model for LLM alignment[C] // Findings of the Association for Computational Linguistics: ACL 2024. 2024 : 151 - 162.
- [53] NARAYAN O, SANIEE I. Large-scale curvature of networks[J]. Physical Review E—Statistical, Nonlinear, and Soft Matter Physics, 2011, 84(6): 066108.
- [54] TOUTANOVA K, CHEN D. Observed versus latent features for knowledge base and text inference[C] // Proceedings of the 3rd Workshop on Continuous Vector Space Models and their Compositionality. 2015 : 57 - 66.
- [55] YAO L, MAO C, LUO Y. KG-BERT: BERT for Knowledge Graph Completion[J]. arXiv preprint arXiv:1909.03193, 2019.
- [56] CHAMI I, YING R, RÉ C, et al. Hyperbolic Graph Convolutional Neural Networks[C] // Advances in Neural Information Processing Systems. 2019 : 4869 - 4880.
- [57] MONTELLA S, BARAHONA L M R, HEINECKE J. Hyperbolic temporal knowledge graph embeddings with relational and time curvatures[C] // Findings of the Association for Computational Linguistics: ACL-IJCNLP 2021. 2021 : 3296 - 3308.
- [58] FAN S, YAO Q, NIE H, et al. Bridging Graph Structure and Knowledge-Guided Editing for Interpretable Temporal Knowledge Graph Reasoning[EB/OL]. (2026). <https://arxiv.org/abs/2601.21978>.
- [59] FENG S, YE Z, LIU Q, et al. RPHF-GNN: Recurrent perception of history-future graph neural networks for temporal knowledge graph reasoning[J]. IEEE access, 2025.
- [60] GONG Z, TANG C, HUO X, et al. Hyperbolic multimodal representation learning for biological taxonomies[EB/OL]. 2025. <https://arxiv.org/abs/2508.16744>.
- [61] LIANG K, MENG L, LIU M, et al. A survey of knowledge graph reasoning on graph types: Static, dynamic, and multi-modal[J]. IEEE Transactions on Pattern Analysis and Machine Intelligence, 2024, 46(12): 9456 - 9478.

- [62] NIU G, LI B, LIN Y. A Comprehensive Survey of Knowledge Graph Reasoning: Approaches and Applications[J]. IEEE Transactions on Big Data, 2026.
- [63] XIONG W, HOANG T, WANG W Y. Deeppath: A reinforcement learning method for knowledge graph reasoning[C] // Proceedings of the 2017 conference on empirical methods in natural language processing. 2017: 564 - 573.
- [64] WANG Q, GUO Y, WU J, et al. Query-Guided Graph Neural Networks for Knowledge Graph Reasoning[J], 2025.

在学期间发表论文的清单

本人在攻读硕士学位期间暂无公开发表的学术论文。

致 谢

时光荏苒，硕士阶段的学习与科研工作即将告一段落。回顾这一阶段，从课题选题、实验推进到论文撰写，每一步都离不开师长、同门、家人与朋友的帮助与支持。在论文完成之际，谨向所有关心、指导和帮助过我的人表示诚挚的感谢。

首先，衷心感谢我的导师孙玉霞副教授给予我的悉心指导与包容。回首这段历程，我深知自己在科研上的能力与主动性仍有许多不足，但导师始终没有放弃对我的要求。特别是在论文提交盲审的最后关头，导师不辞辛劳，极其耐心、细致地帮我修改论文，帮助我逐步厘清研究问题、完善方法设计。正是由于导师的严谨把关与不懈指引，我才得以顺利度过盲审。导师治学严谨的态度和对学生的认真负责，将使我受益终生。

其次，感谢实验室各位老师和同门在学习与科研过程中给予的帮助。与大家交流让我在专业方向上获得了许多启发，也帮助我在实验调试和论文修改过程中克服了不少困难。同时，感谢暨南大学以及学院为我的学习和科研提供了良好的平台。也感谢论文评阅专家和答辩委员会老师在百忙之中审阅本文，并提出宝贵意见。

特别感谢我的家人一直以来的理解与支持。在论文写作、答辩与春招求职多重压力交织的阶段，尤其是面临几次面试失利的打击时，是妈妈给予了我强大的精神支撑和无条件的陪伴，让我能够重新振作；爸爸时不时打来的关心电话，也总能适时地宽慰我，让我深切感受到无论面对何种困难，背后始终有最坚实的后盾。此外，还要感谢我家的小猫糯米，虽然平时见不到，但它搞笑的照片总能让我在沉重的重压下露出由衷的幸福微笑。

在这段艰难的日子里，我还要特别感谢我的好朋友君君。由于被论文和各项事务压得焦头烂额，我常常无暇回复消息，甚至几次无奈对她“放鸽子”。对她，我既抱歉又深深感激。谢谢她的耐心、体谅与包容，在跌宕起伏的人生阶段、在最后几个月那些灰暗沉重的日子里，是我生活里的一束光，何其有幸能拥有这份珍贵的友谊。

最后，感谢过去这段时间里坚持完成课题、不断调整状态的自己。硕士阶段并非一帆风顺，但正是在反复试错、修改和坚持中，我逐渐学会以更加务实和稳健的方式面对问题。未来我也将继续保持学习的态度，在新的阶段中不断积累、不断前行。

谨以此文，向所有给予我帮助和支持的人致以诚挚的谢意。