

基于本体的网络安全知识图谱构建方法

许智双¹, 张昆², 范俊超¹, 常晓林¹

(1. 北京交通大学网络空间安全学院, 北京 100044; 2. 国家信息中心, 北京 100045)

摘 要: 随着信息技术的高速发展, 网络空间与现实世界连接越来越紧密。将知识图谱技术应用于网络安全领域, 能够从网络空间海量数据中获取碎片化的有效安全知识进行整合, 为决策提供支持。现有方法存在本体模型缺乏统一标准、知识抽取效果不佳等问题, 因此, 文章提出一种基于本体的网络安全知识图谱构建方法, 该方法包含命名实体识别和关系抽取两个模型, 其中命名实体识别模型结合 BERT 预训练模型、双向长短期记忆网络、多头注意力机制和条件随机场; 关系抽取模型结合 BERT 预训练模型、自注意力机制和卷积神经网络。这两个模型提升了命名实体识别的准确率, 并提升了关系抽取任务的准确率以及自动化程度。文章提出的网络安全知识图谱构建方法可整合并分析网络安全数据, 实现网络安全知识的智能化检索以及知识图谱的自动更新和扩展。

关键词: 网络安全; 知识图谱; 本体; 知识抽取

中图分类号: TP309 **文献标志码:** A **文章编号:** 1671-1122 (2025) 03-0451-16

中文引用格式: 许智双, 张昆, 范俊超, 等. 基于本体的网络安全知识图谱构建方法 [J]. 信息网络安全, 2025, 25 (3): 451-466.

英文引用格式: XU Zhishuang, ZHANG Kun, FAN Junchao, et al. Construction Method of Cybersecurity Knowledge Graph Based on Ontology[J]. Netinfo Security, 2025, 25(3): 451-466.

Construction Method of Cybersecurity Knowledge Graph Based on Ontology

XU Zhishuang¹, ZHANG Kun², FAN Junchao¹, CHANG Xiaolin¹

(1. School of Cyberspace Science and Technology, Beijing Jiaotong University, Beijing 100044, China;

2. State Information Center, Beijing 100045, China)

Abstract: With the rapid development of information technology, the connection between cyberspace and the real world has become increasingly close. Applying knowledge graph technology to the field of cybersecurity allows for the extraction and integration of fragmented, valuable security knowledge from vast amounts of data in cyberspace, providing support for decision-making. Existing methods face issues such as the lack of a unified standard for ontology models and poor knowledge extraction performance. This paper

收稿日期: 2024-12-30

基金项目: 国家自然科学基金 [62272028]

作者简介: 许智双 (1999—), 女, 山东, 硕士研究生, 主要研究方向为网络安全; 张昆 (1976—), 男, 甘肃, 高级工程师, 本科, 主要研究方向为网络安全; 范俊超 (1998—), 男, 湖北, 博士研究生, 主要研究方向为人工智能安全; 常晓林 (1971—), 女, 福建, 教授, 博士, CCF 会员, 主要研究方向为网络安全与隐私保护。

通信作者: 常晓林 xlchang@bjtu.edu.cn

proposed an ontology-based method for constructing a cybersecurity knowledge graph, which included two models: named entity recognition and relation extraction. The named entity recognition model integrated the BERT pre-trained model, bidirectional long short-term memory network, multi-head attention mechanism, and conditional random fields; the relation extraction model combined the BERT pre-trained model, self-attention mechanism and convolutional neural network. These two models improved the accuracy of named entity recognition and enhanced the accuracy and automation of relation extraction tasks. The proposed method for constructing the cybersecurity knowledge graph can integrate and analyze cybersecurity data, enabling intelligent retrieval of cybersecurity knowledge and automatic updates and expansion of the knowledge graph.

Key words: cybersecurity; knowledge graph; ontology; knowledge extraction

0 引言

目前,网络安全越来越受重视,运用知识图谱技术构建网络安全知识图谱,可以将互联网上多源异构的海量网络安全数据整合成语义可理解的知识以供关联分析和深度挖掘,为网络安全态势感知、威胁识别以及预测提供支撑^[1]。然而,目前网络安全知识图谱研究仍面临诸多挑战。具体表现在以下两个方面。

1) 缺乏统一标准。目前,网络安全本体模型主要由不同的研究机构和公司提出,缺乏统一的标准,导致不同图谱之间的兼容性较差,难以在多平台和多领域间实现有效的数据共享和协同分析^[2,3]。例如,一些本体模型侧重于恶意软件的行为分析,另一些侧重于攻击技术的描述,这种差异使得图谱之间难以顺畅整合和互通。

2) 依赖人工提取特征。现有的知识图谱构建方法大多依赖人工提取特征,不仅增加了人工成本,也限制了图谱的更新速度和扩展性^[4,5]。例如,在构建网络安全知识图谱时,许多方法依赖专家手动标注攻击样本,并根据固定规则提取特征,这使得图谱难以及时适应新的攻击模式,导致数据和知识的时效性较差。

因此,如何构建统一标准、如何高效提取特征并形成有效的方案是亟需解决的关键问题。构建网络安全知识图谱的核心过程是本体构建和知识抽取,本文提出了一种新的本体模型,为后续图谱的构建奠定基础,并针对知识抽取环节,提出命名实体识别模型 BERT-BiLSTM-MHA-CRF 和关系抽取模型 BERT-SA-

CNN,这两种模型能够减少人力消耗,从非结构化文本中提取更加复杂的语义信息,提升知识抽取的准确率。本文的主要贡献如下。

1) 基于对已有数据源的分析,研究复用已有的网络安全本体,在综合考虑资产、特征、攻击方和防御方4个不同维度的基础上构建了一个适用于现有数据源且具备更强通用性的网络安全领域本体,为网络安全知识图谱构建提供支撑。

2) 提出一种结合 BERT 预训练模型、双向长短期记忆网络 (Bidirectional Long Short-Term Memory, BiLSTM)、多头注意力机制 (Multi-Head Attention, MHA) 和条件随机场 (Conditional Random Field, CRF) 的命名实体识别模型 BERT-BiLSTM-MHA-CRF,该模型将实体识别任务转化为序列标注问题,充分利用各模块的优势,有效提升命名实体识别的准确率。

3) 提出一种结合 BERT 预训练模型、自注意力机制 (Self-Attention, SA) 和卷积神经网络 (Convolutional Neural Network, CNN) 的关系抽取模型 BERT-SA-CNN,该模型能够利用各模块的优势,提升关系抽取任务的准确率以及自动化程度。

1 相关工作

本体构建和信息抽取是构建网络安全知识图谱的关键环节。本体构建用于定义网络安全领域的概念、属性及其关系,提供统一的语义框架和推理能力。信息抽取从复杂多样的网络安全数据中提取结构化知识,为知识图谱的动态更新和扩展提供支持。这两部分相

辅相成,是构建高质量知识图谱的重要基础。

1.1 本体构建

本体^[6]是一种知识表示的方法,其依据既定的规则,对实体、关系和属性的概念进行规范化,基于本体论创建的知识图谱能够以关系化、结构化和可视化的形式表达领域知识,有效提升知识应用价值。研究者们已经开展面向网络安全领域的本体模型构建方法研究。LI^[7]等人将UCO本体从8个类别扩展到16个类别,开发了适合人工构建的网络安全知识图谱数据集CS13K的新网络安全本体。CHEN^[8]等人采用结构化威胁信息表达作为攻击方的本体,并为防御方设计了一种本体,基于该本体和现有的威胁本体,构建出关键信息基础设施保护知识图谱。PREUVENEERS^[9]等人提出一种本体模型,可对依赖AI的应用、系统和服务所面临的威胁进行建模和管理,然而该本体模型难以表达复杂关系,并难以进行有效的攻击推理。GRANDIN^[10]将基础本体与网络安全领域本体相连接,构建了一个使用OWL编写的操作性本体,但存在不够精确的问题。BUGHIO^[11]等人提出一个将网络安全和医疗相结合的本体模型MIoT,关注医疗物联网中的网络安全,以保护物联网资产免受漏洞和网络攻击。BERNARDINI^[12]等人提出一个集成网络安全特征(如安全措施、漏洞评估和威胁建模)的本体模型,但该本体模型涉及的网络安全特征不够详尽。KOUGIOUMTZIDOU^[13]等人提出一个基于STIX 2.1标准的本体模型,对攻击、威胁和漏洞相关信息进行建模。

尽管上述文献提出了网络安全领域的本体模型,但关注的网络安全要素较少,很难完全适用更广泛的数据源,通用性较差。

1.2 信息抽取

信息抽取^[14]是构建网络安全知识图谱的核心技术之一,其目的是从大规模、公开的非结构化文本中抽取预先设定好的数据类型。信息抽取有命名实体识别和关系抽取两个主要任务。

命名实体识别^[15]的目的是从海量多源异构数据中抽取符合要求的实体类型。针对命名实体识别,目前主要有基于规则的命名实体识别和基于机器学习的命名实体识别两种方法。基于规则的方法是利用专家预先制定好的领域规则模板进行模式匹配完成实体抽取。STUDIAWAN^[16]等人提出基于spaCy库的规则实体识别方法,该方法可以在取证时间轴上标记实体。HU^[17]等人提出一种利用正则表达式进行命名实体识别的方法,以确保实体识别的准确率,该方法在缺乏语义的固定格式短语方面具有良好的性能。基于机器学习的实体抽取方法主要应用传统的机器学习方法结合人工设计的特征进行实体识别。SARHAN^[18]等人使用6种机器学习模型,在网络入侵检测系统数据集上进行实体分类,获得良好的分类效果,但是该方法的通用性较差,无法应用到更多的网络场景中。MUMTAZ^[19]等人使用机器学习算法对数据集进行分析和分类,完成对重大网络事件的实体识别。随着人工智能技术的不断发展,众多学者在研究将深度学习运用到命名实体识别中,深度学习方法逐渐成为主流技术,该方法能够自动识别原始数据中的特征并具有更强的表示知识能力。

关系抽取^[20]从非结构化的文本中识别实体之间的关系,是构建知识图谱的核心任务之一,其分为人工方法和基于深度学习的方法。早期的关系抽取多依赖人工方法,通常使用模板或者规则进行。WANG^[21]等人设计了一种基于规则的多关系抽取模型,根据是否符合预定义的相关规则来判断两个实体之间是否具备某种关系。随着深度学习的兴起,基于深度学习的关系抽取方法得到了广泛关注。AHMED^[22]等人提出了一种基于深度学习的联合抽取技术,该技术能够对网络关系三元组进行有效的抽取,解决了传统管道抽取技术存在的问题。

上述文献中提到的信息抽取方法多依赖人工,面对更大规模数据时,成本较高,在可扩展性和移植性方面存在不足。

2 图谱构建方法设计

网络空间安全知识图谱逻辑上分为模式层和数据层两个层次,如图1所示。本文采用自顶向下的方式构建网络安全知识图谱,依次完成模式层和数据层的构建,然后通过知识融合和知识存储形成最终的网络安全知识图谱。模式层是网络安全知识图谱的核心,其本质是建立网络安全数据的知识模式,模式层构建主要包括本体的设计与构建。数据层负责处理具体的互联网上多源异构的网络安全数据,在已构建的模式层基础上,实现知识图谱的结构化;数据层构建包括数据预处理、知识抽取、知识融合和知识存储4部分。本文提出的网络安全知识图谱构建方法包含模式层和数据层的设计,分别在2.2节和2.3节进行详细介绍。




图1 网络安全知识图谱框架

2.1 构建方法总述

网络安全知识图谱的构建需要依次完成本体构建、数据预处理、知识抽取、知识融合和知识存储5部分内容。首先,设计本体模型对网络安全知识进行梳理。然后,将这些来源不同、类型多样的知识进行预处理,使其能够充分融合。预处理之后得到的数据分为非结构化数据和结构化数据两类,对于非结构化数据,需要对其进行知识抽取,从而从中提取实体、属性、关系等特定类型的信息,知识抽取的过程依赖于命名实

体识别模型和关系抽取模型。对于结构化数据和经过知识抽取的非结构化数据,由于数据结构的不同,两者之间存在着相互重叠的知识,因此,需要对这两部分数据进行融合,以协调来自多个源的关于同一实体或概念的描述信息。实现知识融合的具体方式是局部实体对齐,先计算实体间的权重,然后加权求和后获得实体间的相似度,最后基于实体间的相似度进行对齐。完成知识融合之后,使用图数据库Neo4j对知识进行存储与可视化。

2.2 模式层构建

模式层构建针对海量的网络安全数据,设计本体模型对其进行梳理,首先明确实体和属性的划分,然后确定各实体和属性之间的关系,实现实体、属性和关系三者之间清晰明确的结构。

构建网络安全领域的本体模型,首先需要对互联网中异构的海量网络安全信息进行特点分析和梳理,以识别和提取其中的关键特征和模式。然后,根据这些特征,确定实体类别集合、属性集合以及实体和实体之间、属性和属性之间的对应关系,从而实现本体模型的初步构建。构建过程中,必须对每个实体类别的具体定义和属性进行详细的界定,并明确其相互关系,以确保模型能够准确地反映网络安全领域的复杂知识结构。本体模型构建完成后,需要对其进行评估,以判断该模型是否能够良好地适用于网络安全领域并能实现网络安全知识的有效融合。本文从资产、特征、攻击方和防御方4个维度出发,构建了一个全面的网络安全本体模型。这些维度覆盖了网络安全领域的核心要素和相互关系,具体模型如图2所示。

2.3 数据层构建

本文基于VMware虚拟化软件搭建的内网环境构建网络安全知识图谱,该图谱使用的基础数据主要分为情报信息和拓扑信息两部分,情报信息部分主要来源于开源的网络安全报告,这些报告提供了丰富的网络安全情报,属于非结构化数据。拓扑信息部分通过




图2 网络安全领域本体模型

自动化扫描工具对网络环境中的拓扑结构和主机信息进行探测而获得，具体的网络拓扑如图3所示，其信息属于结构化数据。之后对获取到的数据进行预处理，并对这些数据进行知识抽取，得到形式化的知识，然后对其进行知识融合和知识存储，完成网络安全知识图谱的构建。




图3 网络拓扑

知识抽取是从多个来源、不同结构的数据中使用不同的方法获取知识，然后对获取到的知识进行深入分析，分类抽取实体、关系和属性的过程。本文使用的网络安全数据来源广泛，涵盖了来自互联网的公开非结构化文本数据（如安全公告）和来自网络拓扑的结构化数据。针对非结构化数据，需要进行知识抽取，知识抽取的过程主要分为命名实体识别和关系抽取两部分。知识融合的目的是协调关于同一实体或者概念的多源描述信息。知识存储是将知识融合后的数据有效存储，从而构建完整的知识图谱。

2.3.1 命名实体识别

命名实体识别的目标是从文本中识别和分类出具

有特定意义的命名实体。传统的命名实体识别方法采用统计方法依赖于人工提取特征，存在难以准确识别实体以及命名实体识别效果不佳的问题，因此，本文提出一种结合BERT预训练模型、BiLSTM、MHA和CRF的命名实体识别模型BERT-BiLSTM-MHA-CRF。该模型将实体识别任务转化为序列标注问题，模型的整体结构如图4所示。




图4 BERT-BiLSTM-MHA-CRF模型的整体结构

该模型包括文本输入层、基于BERT的词嵌入层、基于BiLSTM的特征提取层、MHA层、CRF层和输出层6个层次。通过文本输入层输入待标注的序列到BERT层，经过BERT模型的预训练生成包含字符级、词级和句子级的词向量，在某些复杂句子中，BERT难以有效处理句子中的长距离依赖关系和局部顺序信息，因此，在BERT层后面引入BiLSTM层，通过BiLSTM模型的前向和反向传播来解决该问题。然而，BiLSTM模型未能突出某些词语在命名实体识别任务中的重要性。为了解决这一问题，将BiLSTM层的输出结果输入到MHA层，MHA能够通过不同的注意力头为BiLSTM输出的特征分配不同的权重，突出对实体识别至关重要的局部信息，同时抑制与实体识别无关的特征，从而实现更精准的实体识别，提高模型的效果。然后通过CRF层进行标签预测任务，确保标签序列符合特定的规则，并通过全局优化选择最合适的标签序列。最终将得到的结果输入到输出层，输出层输出标

注完成的序列。

1) BERT层

BERT模型处理文本的整体流程如图5所示, BERT模型可以分为输入嵌入层、编码器层和输出层3部分。其中, 当文本序列输入BERT模型时, 首先会在开始处添加[CLS]标志, 然后在每个句子之间添加[SEP]标志, 通过输入嵌入层, 会得到词嵌入、位置嵌入和分段嵌入3部分的嵌入向量。词嵌入表示的是每个词的语义信息, 位置嵌入表示的是每个词在句子中的位置, 分段嵌入则表示的是句子在上下文中的位置。这3种嵌入向量相加, 形成了输入文本序列的综合表示并传递给编码层。编码器层是双层Transform编码器, 能够获取更加丰富的多维度的信息特征。输出层输出每个词的最终表示向量, 作为下游任务的词嵌入向量, 从而帮助模型更好地理解文本中的语义和结构。




图5 BERT模型处理文本的流程

2) BiLSTM层

BiLSTM模型是双向的LSTM模型, 其中, LSTM模型通过在记忆单元中增加细胞状态 c_t 来实现信息的过滤, 细胞状态 c_t 由输入门、遗忘门和输出门来决定。但是LSTM模型是顺序状态传递信息的, 只能捕捉过去的信息, 无法捕捉未来的信息, 因此, BiLSTM增加了逆序运算, 通过前向LSTM和后向LSTM充分获取文本序列的过去和未来的信息。在处理一句话时, 前向LSTM从左到右读取文本, 而反向LSTM则从右到左读取文本。针对词嵌入向量, 使用BiLSTM模型获得正向LSTM和反向LSTM输出隐藏层表示 $\vec{h}_i$ 和 $\overleftarrow{h}_i$, 然后将 $\vec{h}_i$ 和 $\overleftarrow{h}_i$ 进行拼接, 最终得到 i 时刻的双向BiLSTM层输出序列

$H = [\vec{h}_1 \oplus \overleftarrow{h}_1, \vec{h}_2 \oplus \overleftarrow{h}_2, \dots, \vec{h}_t \oplus \overleftarrow{h}_t]$, 其中, $\oplus$ 表示向量拼接操作。

3) MHA层

MHA通过多个独立的注意力头并行计算注意力分数, 每个头能够关注输入序列的不同部分, 从而捕捉到更多样化的上下文信息。对于BiLSTM层的输出 $H = [\vec{h}_1 \oplus \overleftarrow{h}_1, \vec{h}_2 \oplus \overleftarrow{h}_2, \dots, \vec{h}_t \oplus \overleftarrow{h}_t]$, 首先对 H 进行线性变换, 对于每个注意力头 i , 将其变换为查询(Q)、键(K)和值(V)矩阵, 分别表示为 Q_i 、 K_i 和 V_i 。如公式(1)、(2)、(3)所示。

$$Q_i = HW_{Q_i} \quad (1)$$

$$K_i = HW_{K_i} \quad (2)$$

$$V_i = HW_{V_i} \quad (3)$$

其中, W_{Q_i} 、 W_{K_i} 、 W_{V_i} 是可学习的权重矩阵。

然后对于每个注意力头 i , 计算查询和键之间的相似度, 并应用Softmax函数进行归一化, 得到注意力分数, 如公式(4)所示。

$$head_i = Attention(Q_i, K_i, V_i) = Softmax\left(\frac{Q_i K_i^T}{\sqrt{d_k}}\right) V_i \quad (4)$$

其中, d_k 表示键向量的维度。公式(4)是计算不同部分之间的关系, 并将这些关系通过注意力分数调整输入数据的权重, 确保模型能聚焦于重要信息。

最后, 将所有注意力头的输出连接起来, 并通过线性变换得到最终的MHA输出, 如公式(5)所示。

$$MultiHead(Q, K, V) = Concat(head_1, head_2, \dots, head_h) W_O \quad (5)$$

其中, W_O 是输出的线性变换矩阵。通过拼接多个头的输出, 模型能够同时关注多个信息来源, 捕捉到更加丰富的上下文信息。

4) CRF层

CRF模型能够捕获全局信息并预测结果, 该模型保证最终得到的标签正确性的方式是对预测标签增加一些合理的限制。例如, B-attacker之后只能是I-attacker, 不能是其它的标签。模型的输入是 $X = (x_1, x_2, \dots, x_n)$, 其中, x_n 是第 n 个字的输入向量。输入序列 X 对应的标签序列为 $y = \{y_1, y_2, \dots, y_n\}$ 。 X 中的每个字都有其对

应的标签, 这些标签都有相应的分数, 分数越高, 说明对应该标签的可能性越高, 分数最高的标签为最终的预测结果。标签序列 y 的分数如公式 (6) 所示。

$$\text{score}(\mathbf{X}, y) = \sum_{i=1}^m P_{i, y_i} + \sum_{i=0}^{m-1} A_{y_i, y_{i+1}} \quad (6)$$

其中, $\mathbf{M}$ 是上一层的输出矩阵, P_{i, y_i} 代表输入序列 x_i 被标记为 y_i 的概率, A 是特征转移矩阵, $A_{y_i, y_{i+1}}$ 代表从标签 y_i 转移到标签 y_{i+1} 的转移得分。

然后计算标签序列 y 的条件概率 $P(y|\mathbf{X})$, 如公式 (7) 所示。

$$P(y|\mathbf{X}) = \frac{\exp(\text{score}(\mathbf{X}, y))}{Z(\mathbf{X})} \quad (7)$$

其中, $Z(\mathbf{X})$ 为归一化因子, 确保整个标签序列的概率和为 1。该因子是对所有可能的标签序列的得分进行归一化, 用于确保概率分布的合法性, 定义如公式 (8) 所示。

$$Z(\mathbf{X}) = \sum_{y' \in Y(\mathbf{X})} \exp(\text{score}(\mathbf{X}, y')) \quad (8)$$

其中, $Y(\mathbf{X})$ 表示所有可能的标签序列集合。

2.3.2 关系抽取

关系抽取是知识抽取的另一项重要的任务, 旨在从非结构化数据中自动识别出实体之间某种语义关系。通过结合得到的实体, 最终实现将非结构化的文本信息转换成结构化的数据。针对网络安全领域非结构化的威胁情报, 关系抽取任务可以建模成对特定关系的分类问题, 其中两个实体之间的相关性将会被划分到预定义的关系类别中。传统的关系抽取方法对语言学和领域知识非常依赖, 需要大量人工设计语法和语法规则。

因此, 为了更加准确和高效地实现威胁情报中关系的抽取, 本文设计了一种结合 BERT 预训练模型、SA 和 CNN 的关系抽取模型 BERT-SA-CNN。该模型的整体架构如图 6 所示, 该模型包括输入层、BERT 层、SA 层、CNN 层和输出层 5 个层次。输入层负责将原始文本数据输入到模型中, 然后经过 BERT 层中预训练好的 BERT 模型来生成高维词嵌入, 捕捉每个词的上下文信息。BERT 在处理长文本时无法充分捕捉到复杂

的长距离依赖和局部特征, 因此, 在 BERT 层之后引入 SA 层, 帮助模型进一步捕捉语义关联和长距离依赖信息, 从而提高对复杂关系的理解, 同时增强模型对文本序列中重要特征的聚焦能力。CNN 层负责对经过 SA 处理的词向量进行局部特征提取, 最后输出层生成结构化的关系标签, 表明文本中各个实体之间的具体关系类型。




图 6 关系抽取模型整体架构

1) SA 层

在关系抽取任务中, 实体之间的关系可能跨越多个词语甚至句子。SA 能够在整个输入序列范围内建立联系, 捕捉到长距离的依赖关系, 更加准确地识别关系。SA 具体计算步骤分为 4 部分, 首先对输入序列 $\mathbf{X}$, 通过线性变换生成查询向量 $\mathbf{Q}$ 、键向量 $\mathbf{K}$ 和值向量 $\mathbf{V}$, 如公式 (9)~公式 (11) 所示。

$$\mathbf{Q} = \mathbf{X}\mathbf{W}_Q \quad (9)$$

$$\mathbf{K} = \mathbf{X}\mathbf{W}_K \quad (10)$$

$$\mathbf{V} = \mathbf{X}\mathbf{W}_V \quad (11)$$

其中, $\mathbf{W}_Q$ 、 $\mathbf{W}_K$ 和 $\mathbf{W}_V$ 是可训练的权重矩阵。

其次, 对于每个查询向量 $\mathbf{Q}$ 与键向量 $\mathbf{K}$ 的转置 $\mathbf{K}^T$ 进行点积运算, 得到相似性得分矩阵 $\mathbf{S}$, 为了避免数值过大, 将相似性得分矩阵 $\mathbf{S}$ 除以缩放因子 $\sqrt{d_k}$ (d_k 是键向量的维度), 计算过程如公式 (12) 所示。

$$\mathbf{S} = \frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}} \quad (12)$$

然后, 使用 *Softmax* 函数将相似性得分矩阵 $\mathbf{S}$ 转换为注意力权重矩阵 α , 如公式 (13) 所示。

$$\alpha = \text{softmax}\left(\frac{\mathbf{Q}\mathbf{K}^T}{\sqrt{d_k}}\right) \quad (13)$$

最后,使用注意力权重矩阵 α 对值向量 V 进行加权求和,得到输出矩阵 Z ,如公式(14)所示。

$$Z = \alpha V = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (14)$$

2) CNN层

CNN是一种包含卷积计算的前馈神经网络,能够自动提取数据的特征并且实现参数共享,极大提高了模型的训练效率。本文提出的CNN层一共分为卷积层和池化层两部分,卷积层是CNN层的核心部分,卷积过程是对输入矩阵的一个滑动窗口进行乘积求和的过程,这个过程的作用是用来提取特征。使用卷积层提取文本特征信息之后,由于提取的信息数量一般比较多,因此需要池化层对提取到的特征进行选择过滤并将过滤之后得到的特征拼接成新的特征向量,不仅能够减少计算量和参数的数量,还能避免模型出现过拟合现象。

2.3.3 知识融合

本文获取的网络安全相关数据包括结构化数据和非结构化数据两种数据,这两部分数据来源广泛且结构不同,存在着相互重叠的知识,可能面临语义冲突问题。因此,本节主要研究如何将这两部分数据进行融合,以协调来自多个源的关于同一实体或者概念的描述信息。

知识融合过程是进行实体消歧和实体对齐。实体消歧的任务是处理命名实体识别过程中遇到的歧义问题,当一个命名实体在不同的上下文中可能指代不同的实体概念时,就会产生歧义。实体消歧把在命名实体识别过程中有歧义的命名性指称项映射到它的实际所指的概念上去,其目的是解决一个命名实体指称项对应的多个实体概念“一词多义”的现象。实体消歧是根据词语的上下文关系进行该词语的本身歧义上的消除。

在网络安全知识图谱中,一个实体可能有多种称呼,从而引发实体冲突和指向不明的问题。通过实体对齐可以消除异构数据中实体冲突和指向不明的问题,采用局部集体实体对齐的方式,先计算实体间的权重,然后加权求和后获得实体间的相似度,最后基于实体

间的相似度进行实体对齐。

2.3.4 知识存储

网络安全知识图谱作为一种领域知识图谱,数据具有一定的封闭性,目前主流的存储方法主要有3种,分别是关系型数据库存储、图数据库存储和面向RDF的数据库存储。使用关系型数据库的存储方法存在数据模型灵活度较低、深层次关系查询的性能较低的问题,使用面向RDF的数据库的存储方法面临无法进行图形化展示的问题。相比之下,图数据库Neo4j提供了一种更为灵活和直观的存储方案。通过Neo4j,不仅可以灵活地构建复杂的数据结构,还能方便地进行节点和边的增删改查操作,同时其内置的可视化功能可以直观地展示和分析图谱的具体形态。因此,本文使用图数据库Neo4j进行知识存储。

经过知识存储后的知识图谱,需要对其进行动态管理,本文采用基于时间的衰减机制来实现该目标,确保知识图谱的有效性和准确率。该机制为每个实体和关系设置一个时间戳,表示其最后更新时间。随着时间的推移,实体和关系的权重会根据预先设定的衰减规则逐渐降低,当权重降到最小阈值时,这些实体和关系将被标记为过时并从图谱中删除。

3 实验结果及分析

本章首先对论文所设计的图谱构建方法中命名实体识别模型和关系抽取模型的有效性进行实验验证,通过命名实体识别模型,能够有效识别网络安全领域的关键实体,关系抽取模型挖掘了这些实体之间的关系,然后将这些实体及其关系结构化地构建为知识图谱。在3.1.3小节中,对构建好的知识图谱进行展示。该图谱能够为智能化检索任务提供丰富的语义支持。在智能化检索过程中,知识图谱通过对实体及其关系的结构化表示,能够快速响应复杂查询,并进行深度推理。例如,可以通过知识图谱内置的Cypher语言查询与特定攻击方式或者和漏洞相关的所有实体,并基于图谱中的关系推断可能的攻击路径。在3.2节中,进一步验证本文提出的图谱构建方法支持智能化检索。

在3.3节中,证明该方法支持图谱的自动更新。

3.1 图谱构建方法的实例验证

3.1.1 命名实体识别实验

1) 数据集构建

原始数据来源于预处理之后的非结构化情报信息,针对命名实体识别任务,从中筛选出4430条语句,对这些数据进行实体标注。本文针对本体模型中涉及到的16种实体,对文本进行识别。对这16种实体,本文使用BIO标注模式^[23]进行标注,BIO标注法是一种用于标注训练语料的方法,用来训练命名实体识别模型。模型通过学习BIO标注法中的实体开始、内部和外部的模式,能够较好地理解文本中实体的结构和边界。一旦模型经过训练,就可以用于新的未见过的文本。模型根据在训练中学到的知识,尝试识别并对新文本中的命名实体进行分类。B-X表示实体X的开始部分,I-X表示实体X的其余部分,O表示其它非实体的部分。BIO模式命名的标注符号及其含义如表1所示。

将已经完成标注的数据按照70%、20%和10%的比例依次划分成训练集、测试集和验证集。这样的划分比例有助于在模型训练过程中提供足够的数据用于学习,同时保留一部分数据用于验证模型的泛化能力和最终评估模型的性能。各部分数据集所包含的语句数、实体总数以及其各类实体数量如表2所示。

2) 实验环境配置

实验环境配置分为硬件环境配置和软件环境配置两部分,其中,硬件环境为服务器的硬件配置,软件环境包括系统环境和开发环境,具体配置信息如表3所示。

3) 评价指标

本文采用的主要评估指标是精确率、召回率和F1值,定义如下。

(1) 精确率(Precision)表示在模型预测为正样本的样本中,真正正样本所占的比例。它更关注于预测为正样本中的正确预测比例。

(2) 召回率(Recall)表示在所有实际正样本中,

表1 BIO模式命名的标注符号及其含义

符号	含义	符号	含义
B-administrator	管理员实体的开始部分	I-network	网络实体的其余部分
I-administrator	管理员实体的其余部分	B-attacker	攻击者实体的开始部分
B-host	主机实体的开始部分	I-attacker	攻击者实体的其余部分
I-host	主机实体的其余部分	B-attack_mode	攻击方式实体的开始部分
B-system	操作系统实体的开始部分	I-attack_mode	攻击方式实体的其余部分
I-system	操作系统实体的其余部分	B-loophole	漏洞实体的开始部分
B-hardware	硬件实体的开始部分	I-loophole	漏洞实体的其余部分
I-hardware	硬件实体的其余部分	B-malware	恶意软件实体的开始部分
B-software	软件实体的开始部分	I-malware	恶意软件实体的其余部分
I-software	软件实体的其余部分	B-virus	病毒实体的开始部分
B-ip	IP实体的开始部分	I-virus	病毒实体的其余部分
I-ip	IP实体的其余部分	B-defender	防御者实体的开始部分
B-port	端口实体的开始部分	I-defender	防御者实体的其余部分
I-port	端口实体的其余部分	B-defense_mode	防御方式实体的开始部分
B-service	服务实体的开始部分	I-defense_mode	防御方式实体的其余部分
I-service	服务实体的其余部分	O	非实体
B-network	网络实体的开始部分	—	—

表2 数据集划分统计信息

数据集	训练集 / 个	测试集 / 个	验证集 / 个
语句数	3101	886	443
实体总数	2513	718	359
管理员	120	12	8
主机	159	46	20
操作系统	100	53	6
硬件	114	21	25
软件	129	30	32
IP	120	12	8
端口	160	12	8
服务	100	12	9
网络	49	11	9
攻击者	219	66	37
攻击方式	276	58	58
漏洞	185	92	10
恶意软件	294	113	28
病毒	104	97	42
防御者	222	50	28
防御方式	162	33	31

表3 实验环境配置信息

名称	配置信息
CPU	AMD Ryzen Threadripper 3970X 32-Core Processor
内存	251 GB
操作系统	Ubuntu 20.04.5 LTS
开发框架	Python 3.7.16
编程语言	PyTorch 1.13.1

被正确预测为正样本的比例。它强调实际正样本中正确预测的比例。

(3) $F1$ 值是精确率和召回率的调和平均数, 用于平衡这两个指标。

$Precision$ 、 $Recall$ 和 $F1$ 分数的具体计算如公式 (15) ~ 公式 (17) 所示。

$$Precision = \frac{TP}{TP + FP} \quad (15)$$

$$Recall = \frac{TP}{TP + FN} \quad (16)$$

$$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall} \quad (17)$$

其中, TP 表示实际样本为正例, 也被正确预测为正例的情况; TN 表示实际样本为负例, 也被正确预测为负例的情况; FP 表示实际样本为负例, 被错误预测为正例的情况; FN 表示实际样本为正例, 被错误预测为负例的情况。

4) 参数设置

模型的参数设置会影响模型的性能, 因此在实验过程中需要多次进行实验, 对不同参数设置下的实验结果进行评估和比较, 最终采用更合理的模型参数作为最终的参数, 具体的参数设置如表4所示。

表4 参数设置

名称	数值
<i>batch_size</i>	8
<i>num_train_epochs</i>	15
<i>max_seq_length</i>	202
<i>learning_rate</i>	1e-5
<i>dropout</i>	0.5
<i>clip</i>	0.5

5) 实验结果

为验证本文提出的 BERT-BiLSTM-MHA-CRF 模型在网络安全实体识别任务中的效果, 在同一数据集上对比了多个不同的模型。本实验将 BERT-CRF^[24] 模型设置为基线模型, 该模型主要由 BERT 和 CRF 两个主要部分组成, BERT 作为预训练模型负责生成每个词的词向量, CRF 用于对词的标签序列进行全局游湖, 捕捉标签间依赖关系, 并确保输出标签序列符合一定

的规则。该模型作为基线模型, 能够提供一个基础的性能参考, 用来评估后续改进模型的效果。在该基线模型的基础上引入 BERT-BiLSTM-CRF^[25] 模型和 BERT-MHA-CRF 模型。BERT-BiLSTM-CRF 模型在 BERT-CRF 模型的基础上引入了 BiLSTM, 旨在通过 BiLSTM 的双向特性同时考虑前后文信息, 提升模型对长文本的处理能力。BERT-MHA-CRF 模型则是在 BERT-CRF 模型的基础上加入了 MHA, MHA 能够关注不同部分的信息, 增强模型对复杂关系的建模能力。将本文提出的 BERT-BiLSTM-MHA-CRF 模型与引入的两个模型以及基线模型进行对比, 评估 BERT-BiLSTM-MHA-CRF 模型中各个组件的贡献, 并对更换了词嵌入模型的 ALBERT-BiLSTM-CRF^[26] 模型和 Word2vec-BiLSTM-CRF^[27] 模型进行实验, 探索不同词嵌入方法对模型性能的影响。更换的 ALBERT 是 BERT 的轻量化版本, Word2vec 是一种经典的词嵌入模型。命名实体识别实验模型对比结果如表5所示。

表5 命名实体识别实验模型对比结果

模型	<i>Precision</i>	<i>Recall</i>	<i>F1</i> 值
BERT-BiLSTM-MHA-CRF	84.52%	89.29%	86.84%
BERT-BiLSTM-CRF	82.55%	86.49%	84.48%
BERT-CRF	71.68%	82.01%	76.50%
BERT-MHA-CRF	75.28%	81.35%	78.19%
ALBERT-BiLSTM-CRF	84.13%	83.53%	83.83%
Word2vec-BiLSTM-CRF	79.05%	87.83%	83.21%

从表5可以看出, 基础的 BERT-CRF 模型在实验中的表现最差, 其精确率和 $F1$ 值都是最低的, $F1$ 值仅为 76.50%。这表明, 仅依赖 BERT 和 CRF 的组合在实体识别任务中效果有限, 因为 BERT 模型缺乏对长文本的建模能力, 特别是对于长距离依赖的捕捉, CRF 虽然能够对标签序列进行全局约束, 但是没有进一步增强上下文信息的能力。BERT-BiLSTM-CRF 模型在其基础上增加了 BiLSTM, BiLSTM 能够有效补充 BERT 在上下文建模中的不足, 使得模型能够更好的学习上下文的信息, 对前后文的依赖关系进行建模, 从而提升实体识别效果, 精确率和 $F1$ 值分别提升了 7.37% 和 6.71%。

与 BERT-CRF 模型相比, 增加了 MHA 的 BERT-

MHA-CRF模型在 $F1$ 值上提升了1.69%，这说明MHA能够有效捕捉文本中的重要局部信息。通过多个注意力头并行地关注不同部分的信息，使得模型在复杂文本中的实体识别能力得以增强。

当在BERT-BiLSTM-CRF模型的基础上更换词嵌入模型为ALBERT或者Word2vec时，识别效果有所下降。具体来说，ALBERT-BiLSTM-CRF模型和Word2vec-BiLSTM-CRF模型的 $F1$ 值分别降低了0.65%和1.27%。ALBERT-BiLSTM-CRF模型的 $F1$ 值降低的原因是ALBERT模型的网络参数规模较小，导致在处理复杂实体识别任务时无法提供足够丰富的上下文信息，其文本表示能力受到限制，使得实体的识别效果变差。当更换成Word2vec模型时，其经过训练得到的词向量是静态词向量，这使得在面对语义丰富的上下文时，模型无法有效区分上下文和语境的差异，导致很容易混淆相似的实体，因此，Word2vec-BiLSTM-CRF模型对实体的识别效果较差。

本文提出的模型BERT-BiLSTM-MHA-CRF模型的精确率、召回率和 $F1$ 值都最高，分别为84.52%、89.29%和86.84%。这是因为该模型融合了BERT的字符嵌入和文本表示，生成了更加丰富和完整的文本向量，同时利用了BiLSTM的上下文建模能力以及MHA的局部信息捕捉能力。此外，CRF的引入能够有效防止标签的错误匹配，使得实体的识别效果更好。该模型不仅提升了实体识别的效果，还能够为智能化检索任务提供更加准确和全面的实体信息。

本文对上述6种模型在攻击方式、防御者、防御方式、硬件和漏洞5种实体类别上的精确率、召回率和 $F1$ 值进行统计，结果分别如图7~图9所示。通过对不同类别的评估，得出模型在各个类别的实体识别能力表现。

3.1.2 关系抽取实验

1) 数据集构建

与命名实体识别任务类似，当前没有公开发布的通用网络安全领域关系抽取实验数据集，因此，使用收集到的情报信息作为原始数据，情报信息主要来源




图 7 5 种实体类型的精确率对比结果




图 8 5 种实体类型的召回率对比结果




图 9 5 种实体类型的 $F1$ 值对比结果

于360安全^[28]、国家计算机网络应急技术处理协调中心^[29]等平台发布的开源网络安全报告。针对关系抽取任务，筛选出3918条语句，根据本体模型中预定义的关系类型对其进行标注。完成数据标注之后，为能够在数据集上科学合理地评估所提出方法的性能，将已

经标注好的威胁情报语料按照70%、20%和10%的百分比随机划分为训练集、测试集和验证集。数据集中各类型实体关系统计信息如表6所示。

表6 各类型实体关系统计信息

关系类型	训练集 / 个	测试集 / 个	验证集 / 个
管理	200	90	35
存在	212	52	40
拥有	236	65	28
暴露	199	38	33
利用	185	46	17
修复	244	75	55
使用	281	82	42
属于	245	66	23
清除	208	50	21
查杀	272	88	32

2) 实验环境配置

本实验所使用的实验环境配置信息与命名实体识别实验完全相同, 同表3中配置信息。

3) 评价标准

本实验与命名实体识别实验同样采用精确率、召回率和F1值3个指标为评价标准来评估模型的性能。

4) 参数设置

本实验使用的具体参数设置如表7所示。

表7 参数设置

名称	数值
<i>batch_size</i>	16
<i>epochs</i>	30
<i>max_seq_len</i>	128
<i>dropout</i>	0.15

5) 实验结果

为了验证本文提出的BERT-SA-CNN模型的关系抽取效果, 采用不同模型在同一数据集上进行实验, 实验中设置BERT-CNN^[30]模型作为基线模型, 该模型结合了BERT的词嵌入和CNN, 为关系抽取任务提供基础的性能参考, 在该模型基础上, 更换不同的模块, 引入了BERT-FN^[31]模型和BERT-SA-FN模型, 这两种模型分别代表了不同的模块设计和网络架构, 作为对照组进行比较, 以验证所提出模型有效性。BERT-FN模型是将BERT-CNN模型中的CNN更换成全连接网络,

全连接网络是一种将前一层的所有神经元连接到当前层每个神经元的结构。BERT-SA-FN模型在更换成全连接网络的同时, 增加了SA, 可以增强模型对长距离依赖关系的捕捉能力。关系抽取实验模型对比结果如表8所示。

表8 关系抽取实验模型对比结果

模型	<i>Precision</i>	<i>Recall</i>	F1 值
BERT-SA-CNN	86.27%	86.14%	86.20%
BERT-CNN	83.91%	84.19%	84.05%
BERT-FN	81.70%	85.34%	83.48%
BERT-SA-FN	83.85%	85.07%	84.46%

如表8所示, BERT-FN模型的精确率和F1值都最低, 精确率为81.70%, F1值为86.20%。这表明该模型在关系抽取任务中的效果有限。这是因为全连接网络中本身在捕捉特征时存在局限性, 使得模型在处理复杂的关系抽取任务时不能全面考虑文本的语义结构和细节。与其相比, BERT-CNN模型通过将全连接网络更换为CNN, 提高了模型性能。CNN能够有效减少模型的参数数量和计算复杂度, 同时通过卷积操作在不同的窗口大小下对输入的词向量进行过滤和压缩, 增强了特征提取能力, 使得模型的F1值提升了0.57%。这一提升显示了CNN在处理文本数据时的优势, 尤其在提取局部特征方面更具有优势。

BERT-SA-FN模型则是在BERT-FN模型的基础上增加了SA, 精确率和F1值分别提升了2.15%和0.98%, 这是因为SA能够在全局范围内动态地调整不同输入特征的权重, 并且通过计算输入序列中各个位置的关联度来有效捕捉远距离的依赖关系, 从而提升了模型对复杂数据的理解和处理能力, 证明了SA在增强模型性能方面的有效性。

本文提出的模型BERT-SA-CNN的精确率、召回率和F1值都最高, 分别为86.27%、86.14%和86.20%。这是因为该模型融合了BERT的词嵌入提供了丰富的语义信息和上下文知识, 同时利用SA增强对文本的远距离依赖的捕捉能力以及使用CNN对局部特征进行有效提取。这种融合方式使得BERT-SA-CNN模型能够更好

地理解和处理复杂的文本数据,从而在关系抽取任务中取得了最优的效果,同时通过精确识别实体间的关系,促进了知识图谱中关系部分的构建,为智能化检索任务提供了更加精准的关系信息支持。

本文针对上述的4种模型对管理、拥有、暴露、使用和属于5种关系类别上的精确率、召回率和F1值进行详细的统计分析,结果分别如图10~图12所示。通过对每种关系类别的性能进行评估,能够全面了解不同模型在处理特定关系类型时的表现差异。




图 10 5 种关系类型的精确率对比结果




图 11 5 种关系类型的召回率对比结果




图 12 5 种关系类型的 F1 值对比结果

3.1.3 图谱展示

完成命名实体识别和关系抽取过程之后,需要对

知识进行融合以及存储,形成最终的网络安全知识图谱,实现对知识的形式化表示。最终构建的部分网络安全知识图谱如图13所示。




图 13 部分网络安全知识图谱

3.2 图谱智能化检索实验

基于网络安全知识图谱的智能化检索利用知识图谱技术和高级查询语言,相较于传统检索方式,提供更加丰富的语义特征和结构化的表示形式,可以对关键实体进行结构化表示,支持可视化查询和分析。Cypher语言是一种基于Neo4j数据库的描述性图形查询语言,具有较高的效率。在检索过程中,Cypher语言能够将用户的查询请求转换成子图匹配任务,与网络安全知识图谱进行匹配。网络安全知识图谱识别检索式中的实体,并对实体间的结构关系进行查询扩展与推理。最后,对检索处理的结果进行相关性排序,向用户返回图形化知识结构。基于网络安全知识图谱的智能化检索过程如图14所示。针对给定的主机节点“主机1”,利用文本分类模型识别出给定的实体,规范实体名称。通过Cypher语言对已确定的实体名称进行搜索,可以查询出与该节点相关的实体,如软件、硬件和操作系统。智能化检索结果如图15所示。在实际网络安全场景中,基于图谱的智能化检索能够发掘出

```

graph LR
    A[主机名称: 主机1] --> B[Cypher语言]
    A --> C[文本分类模型]
    C --> B
    B --> D[匹配]
    D --> E[硬件]
    D --> F[软件]
    D --> G[操作系统]
    E --> H[主机]
    F --> H
    G --> H
    H --> I[查询返回值]
  
```

图 14 知识图谱的智能化检索过程




图 15 智能化检索结果

3.3 图谱自动更新实验

图 16 更新前的知识图谱




图 17 更新后的知识图谱

在实际网络环境中，知识图谱的自动更新极大增强了网络安全的动态响应能力。通过自动更新机制，系统能够实时提取最新的信息，确保知识图谱始终反映当前的威胁态势。这不仅能提升安全防护的准确率，还能在攻击发生时迅速调整应对策略，减少人工干预，提高应急响应效率。

4 结束语

本文工作主要涉及网络安全知识图谱的设计和构建。本文设计了一个本体模型，系统地完成了实体类型、关系类型和属性类型的划分，确保在知识图谱中能够准确、全面地表示网络安全领域的核心概念及其相互关系，为知识图谱的构建奠定了坚实的理论基础。同时针对知识抽取过程中的非结构化数据，提出了命名实体识别模型BERT-BiLSTM-MHA-CRF和关系抽取

模型BERT-SA-CNN, 并进行相关实验, 这两个模型在实验过程中均取得了最高的F1值, 证明了他们良好的性能。未来将进一步研究如何将本文方法部署并应用在更复杂和多变的实际网络环境中。

参考文献:

- [1] REN Yitong, XIAO Yanjun, ZHOU Yinghai, et al. CSKG4APT: A Cybersecurity Knowledge Graph for Advanced Persistent Threat Organization Attribution[J]. IEEE Transactions on Knowledge and Data Engineering, 2022, 35(6): 5695–5709.
- [2] JIANG Yuning, JEUSFELD M A, DING Jianguo, et al. Model-Based Cybersecurity Analysis: Extending Enterprise Modeling to Critical Infrastructure Cybersecurity[J]. Business & Information Systems Engineering, 2023, 65(6): 643–676.
- [3] SIKOS L F. Cybersecurity Knowledge Graphs[J]. Knowledge and Information Systems, 2023, 65(9): 3511–3531.
- [4] LIU Kai, WANG Fei, DING Zhaoyun, et al. Recent Progress of Using Knowledge Graph for Cybersecurity[J]. Electronics, 2022, 11(15): 2287–2314.
- [5] WANG Gaosheng, LIU Peipei, HUANG Jintao, et al. KnowCTI: Knowledge-Based Cyber Threat Intelligence Entity and Relation Extraction[J]. Computers & Security, 2024, 141(6): 1–12.
- [6] WANG Xiaodi, HUANG Cheng, LIU Jiayong. Research Overview on Knowledge Graphs for Open Source Intelligence in Cybersecurity[J]. Netinfo Security, 2023, 23(6): 11–21.
- 王晓狄, 黄诚, 刘嘉勇. 面向网络安全开源情报的知识图谱研究综述[J]. 信息安全, 2023, 23(6): 11–21.
- [7] LI Hongyi, ZE Shi, PAN Chengwei, et al. Cybersecurity Knowledge Graphs Construction and Quality Assessment[J]. Complex & Intelligent Systems, 2024, 10(1): 5–16.
- [8] CHEN Jiarui, LU Yiqin, ZHANG Yang, et al. A Management Knowledge Graph Approach for Critical Infrastructure Protection: Ontology Design, Information Extraction and Relation Prediction[J]. International Journal of Critical Infrastructure Protection, 2023, 43(4): 3–7.
- [9] PREUVENEERS D, JOOSEN W. An Ontology-Based Cybersecurity Framework for AI-Enabled Systems and Applications[J]. Future Internet, 2024, 16(3): 4–18.
- [10] GRANDIN A. An Ontology of Cyberspace as a Basis for Decision-Making in Cyberoperations[C]//IEEE. International Conference on Cyber Warfare and Security. New York: IEEE, 2024: 84–94.
- [11] BUGHIO K S, COOK D M, SHAH S A A. Developing a Novel Ontology for Cybersecurity in Internet of Medical Things-Enabled Remote Patient Monitoring[J]. Sensors, 2024, 24(9): 5–20.
- [12] BERNARDINI A, D'ALTERIO F, SAGRATELLA L, et al. "Work-in-Progress" Structuring the Complexity: an Ontological Approach to Analyze the Cybersecurity of a 5G Service[C]//IEEE. 2024 IEEE European Symposium on Security and Privacy Workshops (EuroS&PW). New York: IEEE, 2024: 691–700.
- [13] KOUGIOUMTZIDOU A, PAPOUTSIS A, KAVALLIEROS D, et al. An End-to-End Framework for Cybersecurity Taxonomy and Ontology Generation and Updating[C]//IEEE. 2024 IEEE International Conference on Cyber Security and Resilience (CSR). New York: IEEE, 2024: 247–254.
- [14] XU Derong, CHEN Wei, PENG Wenjun, et al. Large Language Models for Generative Information Extraction: A Survey[J]. Frontiers of Computer Science, 2024, 18(6): 2–14.
- [15] WANG Yaxin, ZHANG Jian. Electronic Medical Record Fingerprint Feature Extraction Based on Few-Shot Named Entity Recognition Technology[J]. Netinfo Security, 2024, 24(10): 1537–1543.
- 王亚欣, 张健. 基于少样本命名实体识别技术的电子病历指纹特征提取[J]. 信息安全, 2024, 24(10): 1537–1543.
- [16] STUDIawan H, HASAN M F, PRATOMO B A. Rule-Based Entity Recognition for Forensic Timeline[C]//IEEE. 2023 Conference on Information Communications Technology and Society (ICTAS). New York: IEEE, 2023: 1–6.
- [17] HU Chenxi, WU Tao, LIU Chunsheng, et al. Joint Contrastive Learning and Belief Rule Base for Named Entity Recognition in Cybersecurity[J]. Cybersecurity, 2024, 7(1): 3–12.
- [18] SARHAN M, LAYEGHY S, MOUSTAFA N, et al. Feature Extraction for Machine Learning-Based Intrusion Detection in IoT Networks[J]. Digital Communications and Networks, 2024, 10(1): 205–216.
- [19] MUMTAZ G, AKRAM S, IQBAL M W, et al. Classification and Prediction of Significant Cyber Incidents (SCI) Using Data Mining and Machine Learning (DM-ML)[J]. IEEE Access, 2023, 11: 94486–94496.
- [20] LI Jiao, ZHANG Yuqing, WU Yabiao. Large Language Model Data Augmentation Methods for Relationship Extraction in Cybersecurity[J]. Netinfo Security, 2024, 24(10): 1477–1483.
- 李娇, 张玉清, 吴亚彪. 面向网络安全关系抽取的大语言模型数据增强方法[J]. 信息安全, 2024, 24(10): 1477–1483.
- [21] WANG Fei, DING Zhaoyun, LIU Kai, et al. Multi-Relation Extraction for Cybersecurity Based on Ontology Rule-Enhanced Prompt Learning[J]. Electronics, 2024, 13(12): 1–25.
- [22] AHMED K, KHURSHID S K, HINA S. CyberEntRel: Joint Extraction of Cyber Entities and Relations Using Deep Learning[J]. Computer & Security, 2024, 136(1): 1–11.
- [23] JI Bin, LI Shasha, XU Hao, et al. Span-Based Joint Entity and Relation Extraction Augmented with Sequence Tagging Mechanism[J]. Science China Information Sciences, 2024, 67(5): 1–15.
- [24] CHEN S S, HWANG R H, SUN C Y, et al. Enhancing Cyber Threat Intelligence with Named Entity Recognition Using BERT-CRF[C]//IEEE. IEEE Global Communications Conference 2023. New York: IEEE, 2023: 7532–7537.
- [25] LIU Yafei, WEI Siqi, HUANG Haijun, et al. Naming Entity Recognition of Citrus Pests and Diseases Based on the BERT-BiLSTM-CRF Model[J]. Expert Systems with Applications, 2023, 234(27): 1–10.
- [26] PAN Xuefeng, CAO Yuanyuan, HOU Xiaorui, et al. Named Entity Recognition of TCM Electronic Medical Records Based on the ALBERT-BiLSTM-CRF Model[C]//IEEE. 2022 12th International Conference on Information Technology in Medicine and Education (ITME 2022). New York: IEEE, 2022: 575–582.
- [27] KE Jia, WANG Weiji, CHEN Xiaojun, et al. Medical Entity

Recognition and Knowledge Map Relationship Analysis of Chinese EMRs Based on Improved BiLSTM-CRF[J]. Computers and Electrical Engineering, 2023, 108(4): 1–18.

[28] 360 Total Security. Security Report[EB/OL]. (2024–05–09) [2024–11–14]. <https://cert.360.cn/report>.

360 安全. 安全报告 [EB/OL]. (2024–05–09) [2024–11–14]. <https://cert.360.cn/report>.

[29] National Computer Network Emergency Response Technical Team/Coordination Center of China. Security Report[EB/OL]. (2023–06–28)

[2024–11–20]. <https://www.cert.org.cn/publish/main/17/index.html>.

国家计算机网络应急技术处理协调中心. 安全报告 [EB/OL]. (2023–06–28)[2024–11–20]. <https://www.cert.org.cn/publish/main/17/index.html>.

[30] KAUR K, KAUR P. BERT–CNN: Improving BERT for Requirements Classification Using CNN[J]. Procedia Computer Science, 2023, 218(3): 2604–2611.

[31] BELLO A, NG S C, LEUNG M F. A BERT Framework to Sentiment Analysis of Tweets[J]. Sensors, 2023, 23(1): 1–14.

四川大学网络空间安全学院最新研究成果发表于《Physics Reports》

近日, 四川大学网络空间安全学院助理研究员唐瑞与西南医科大学、重庆医科大学合作, 在国际期刊《Physics Reports》上发表题为“Network Alignment”的长篇综述论文。唐瑞为论文第一作者, 四川大学网络空间安全学院为第一单位。

真实和虚拟世界复杂系统中, 组成元素之间的复杂交互可以建模为复杂网络, 从而借助图论、概率统计和人工智能等理论与技术进行挖掘和研究。当某些元素同时存在于多个系统中时, 揭示这些元素在不同网络中的对应关系(即网络对齐问题)显得尤为重要。这不仅能够加深人类对复杂系统结构和行为的理解, 还能推动相关研究的扩展与验证, 并促进不同领域的实际应用。例如, 在网络空间安全领域, 网络对齐可用于对齐不同社交网络系统, 帮助实现跨平台用户身份关联、匿名账号识别以及虚假信息传播路径的分析; 在生物信息学领域, 网络对齐可用于对齐跨物种的蛋白质-蛋白质交互网络, 帮助识别保守功能模块、同源物并注释蛋白质功能。

不同领域对网络对齐的关注点各有侧重。例如, 在网络空间安全领域, 研究人员更加关注如何提高对齐方法的准确率、效率和普适性, 以应对动态多变的网络环境; 在生物信息学领域, 研究人员更注重如何结合网络拓扑特性、属性信息以及领域知识对齐复杂生物网络; 而在物理学领域, 研究重点则是网络的无标度特性、社区紧密性等因素对齐效果的影响, 以及对齐后复杂系统的动力学问题。此外, 不同领域复杂网络的结构、特性和性质差异显著, 导致网络对齐的研究通常在各领域内孤立开展, 术语和概念缺乏统一性。这些局限不仅阻碍了各领域之间的交流和协作, 也导致相关技术和方法难以快速传播和共享, 增加了重复开发类似解决方案的风险, 限制了对网络对齐问题的全面认识和广泛应用。

论文总结了网络对齐领域的最新研究进展, 首先分析了社交网络分析、生物信息学、计算语言学和隐私保护等多个领域的特点与成果, 并将各领域的方法统一归类为基于结构一致性的方法和基于机器学习的方法。同时, 根据网络的特性, 详细总结了在属性网络、异构网络、有向网络以及动态网络等条件下的对齐策略和实现细节。此外, 还讨论了该领域当前面临的主要挑战与亟待解决的问题。这一成果可以为研究人员快速了解不同领域成果提供便利, 同时也希望吸引更多来自不同学科的研究者, 从各自学科的视角共同探索网络对齐问题的解决方法。通过跨学科协作, 推动网络对齐研究在理论深度和实际应用上的进一步突破。

《Physics Reports》创刊于1971年, 是物理学和交叉学科类久负盛名、最具影响力的国际综述性期刊之一, 期刊最新影响因子23.9。该刊每期只发表一篇论文, 全部由杂志编辑邀约在全球相关领域做出突出贡献的专家学者撰稿, 旨在对当前研究热点进行总结和评述, 引领和展望相关领域的未来发展。

唐瑞: 博士、副研究员, 主要研究方向包括社交网络分析、网络表示学习、人工智能安全等。主持国家自然科学基金青年基金、国家重点研发计划子课题、四川省自然科学基金青年基金等科研项目, 在IEEE TIFS、AAAI、IEEE TCYB、IEEE IoT等国际权威学术期刊和重要学术会议上发表科研论文20余篇, 并授权或申请中国发明专利10余项。(来源: 四川大学网络空间安全学院, <http://ccs.scu.edu.cn/info/1025/3918.htm>)