



DOI:10.12404/j.issn.1671-1815.2405676

引用格式:甄珍,高见,宋佳林.中文网络安全威胁情报实体关系抽取[J].科学技术与工程,2025,25(24):10344-10350.

Zhen Zhen, Gao Jian, Song Jialin. Entity relation extraction of chinese cyber threat intelligence[J]. Science Technology and Engineering, 2025, 25(24): 10344-10350.

中文网络安全威胁情报实体关系抽取

甄珍¹, 高见^{1*}, 宋佳林²

(1. 中国人民公安大学信息网络安全学院, 北京 100038; 2. 公安部第一研究所, 北京 100048)

摘 要 为实现中文网络安全威胁情报知识图谱的构建,探索一种融合改进的 Focal Loss 和多粒度卷积神经网络的多分类方法,对情报中文本的实体关系进行抽取。针对中文网络安全威胁情报多种关系类型中存在的长尾问题,通过改进 Focal Loss 损失函数,增强对难区分样本的学习,提高模型的分类能力;针对情报内中英文词汇混杂以及专业词汇众多导致的关键词汇长度的方差较大,模型学习困难的问题,提出采用多粒度卷积神经网络的方法捕捉不同粒度的语句特征,提升模型在分类任务上的效果。对比实验表明,与在其他领域常用的分类方法相比,所提出的 MCNNFL 模型的 Weighted-F1 值和正确率显著提高,提升了中文网络安全威胁情报文本实体关系抽取的效果。消融实验表明,针对上述两个问题提出的两种方法皆可提升模型性能,且可以同时使用。

关键词 中文网络安全威胁情报; 实体关系抽取; 卷积神经网络(CNN)

中图法分类号 TP391;

文献标志码 A

Entity Relation Extraction of Chinese Cyber Threat Intelligence

ZHEN Zhen¹, GAO Jian^{1*}, SONG Jia-lin²

(1. School of Information and Network Security, People's Public Security University of China, Beijing 100038, China;

2. First Research Institute of the Ministry of Public Security of PRC, Beijing 100048, China)

[Abstract] To achieve the construction of a Chinese cyber threat intelligence knowledge graph, a multi-classification approach was explored that combined an enhanced focal loss with a multi-scale convolutional neural network. This approach was used to extract entity relationships from the text. To address the long-tail problem within Chinese cyber threat intelligence relation extraction, the Focal loss function was improved to enhance the learning of challenging samples. To tackle the problem of significant variance in keyword lengths caused by the mixture of Chinese and English vocabulary and the abundance of specialized terms in intelligence, a multi-granularity convolutional neural network was employed to capture features of statements at different scales. This approach enhanced the model's performance in the task. The comparative experiments demonstrate that the Weighted-F1 score and accuracy of the proposed MCNNFL model are significantly higher compared to the methods commonly used in other fields. Ablation experiments indicate that both proposed methods for the problems mentioned above can improve model performance and boost performance simultaneously.

[Keywords] Chinese cyber threat intelligence; entity relation extraction; convolutional neural network(CNN)

当今世界,信息技术日新月异,网络空间迅速发展,极大改善了人们生产生活环境^[1]。然而随着互联网的普及,网络“生态”环境并没有得到改善,相反,网络安全威胁事件频发,致使中国网络安全环境面临严峻威胁^[2]。网络安全行业为了共同应对猖獗泛滥的网络攻击,提出网络安全威胁情报这一概念,旨在为组织、政府、网络用户、网络安全从业者、研究者等提供关于攻击者、攻击动机、攻击行为等信息,协助他

们快速、数据支持的预防和反应策略^[3]。

虽然为了更好地共享网络安全威胁情报,网络安全界已经规定了如结构化威胁信息表达式(structured threat information expression, STIX)、网络可观察表达式(cyber observable expression, CybOX)等网络安全威胁情报交换格式,但是目前仍存在如网络安全报告、新闻、博客等大量有价值的、非结构化的网络安全威胁情报尚未被利用,如何有效利用这些

收稿日期:2024-07-29; 修订日期:2025-05-18

基金项目:中国人民公安大学中央基本科研业务费项目(2024JKF17)

第一作者:甄珍(2000—),女,汉族,北京人,硕士研究生。研究方向:网络安全威胁情报、自然语言处理。E-mail:2022211476@stu.ppsuc.edu.cn。

*通信作者:高见(1982—),男,汉族,山东菏泽人,博士,副教授,硕士研究生导师。研究方向:网络安全、网络安全威胁情报、恶意软件、僵尸网络等。E-mail:gaojian@ppsuc.edu.cn。

投稿网址:www.stae.com.cn

非结构化的资料已成为网络安全及众多领域研究的热点^[4-5]。

实体关系抽取作为信息抽取、自然语言理解、信息检索等领域的核心任务和重要环节,能够从文本中抽取实体对间的语义关系^[6],是结构化组织网络安全威胁情报的重要环节。然而,目前中文网络安全威胁情报领域为数不多的研究都集中于命名实体识别任务^[7-11],针对实体关系抽取的研究尚鲜见报道。刘晓凯^[12]提出了分层增强的知识聚合网络,从外部知识图谱中迁移知识,解决网络安全领域关系抽取存在的长尾问题,但是该方法较为复杂,且尚未利用中文网络安全威胁情报的文本特征。

针对长尾问题^[12],提出对 Focal Loss 损失函数进行改进,将其运用于多分类任务中。此外,针对中文网络安全威胁情报存在的文本长度方差大的问题(如计算机文件目录“C:\\Users\\Public\\Documents\\”的长度较长,而地区名称“南亚”较短),提出使用多通道、多粒度的卷积神经网络捕捉不同长度文本间更加丰富的语义特征。实验结果表明,上述两种方法均能有效提升模型在该任务上的性能,且两者可以共同使用,为中文网络安全威胁情报的自动关系抽取工作提供参考。

1 相关研究

1.1 网络安全威胁情报关系抽取

近年来,针对网络安全威胁情报的研究越来越多。谢博^[13]提出了 AttacKG,这是从网络安全威胁情报(cyber threat intelligence, CTI)报告中自动提取的结构化攻击行为图,并识别相关的攻击技术。同时汇总了报告中的威胁情报,以收集不同方面的技术,并将攻击行为通过图增强变为技术知识图。Li 等^[14]提出了基于度量学习的三元组损失函数和排序焦点损失函数,以解决数据标签分布不平衡的问题。Hinton 等^[15]为增强对网络威胁情报中的行为和意图理解,引入一种结合主动学习和半监督自我训练的失陷指标(indicator of compromise, IOC)提取半监督框架,通过利用有限的标记数据和丰富的未标记语料库提高了 IOC 提取的准确性和效率。Zhou 等^[16]通过在不同关系级别上具有多粒度约束的标签到句子注意力来增强分类器的标签层次依赖性。Zeng 等^[17]使用双向编码器表示技术(bidirectional encoder representations from transformers, BERT)模型获取动态词向量,然后通过用双向长短期记忆神经网络(bidirectional long short-term memory network, BiLSTM)-条件随机场(conditional random field, CRF)对词序列进行编码,最后利用网络威胁

情报的知识工程来改进识别结果。

目前,针对中文文本的关系抽取研究较少,且多集中于命名实体识别领域。在中文网络安全威胁情报文本的命名实体识别任务中,学者们从不同角度出发利用深度学习方法改进了识别效果^[7-11]。为解决采用正则匹配会存非恶意信息被匹配的问题,史慧洋等^[8]采用基于变换器的 BERT、BiLSTM 和 CRF 加以正则匹配机制的方法实现 IOC 的识别,之后将其规范为对抗战术、技术和通用知识(adversarial tactics, techniques, and common knowledge, ATT&CK)形式并生成知识图谱。该研究虽然构建了知识图谱,但是并未对实体的关系抽取方法进行研究,难以满足复杂关系下知识图谱的构建。为平衡样本分布情况和解决复杂专业词汇问题,郭渊博等^[9]通过引入 Focal Loss 和字符特征实现了威胁情报的实体识别。为解决 IOC 识别领域数据标注成本高的问题,罗琴等^[10]提出了一种结合主动学习的 IOC 识别方法。针对专业词汇多、混杂英文实体问题, Han 等^[11]提出了多任务学习框架,设计辅助任务帮助模型识别英文实体和中文实体,利用卷积神经网络(convolutional neural network, CNN)提取局部信息, BiLSTM 提取全文信息后进行对抗训练。上述研究针对中文网络安全威胁文本命名实体识别领域的各个难点提出了解决方法,但其研究关注的难点较为分散。

目前,中文网络安全威胁情报文本关系抽取领域的研究较少。针对关系抽取中的长尾问题,刘晓凯^[12]提出了分层增强的知识聚合网络,以知识聚合的方式,从外部知识图谱中迁移知识;并通过不同分支的关系知识进行聚合,从而提升模型抽取长尾关系的能力。然而,其使用的为英文数据集 NYT-10,并未关注到中文网络安全威胁情报的文本特征。针对网络威胁文本书写具有随意性,具有关系的实体距离较远的问题,谢博^[13]提出了一种基于语义上下文过滤的网络安全实体关系联合抽取模型,该模型在抽取效果上取得了一定性能,但是训练和解码速度较慢,准确率仍有待提高。

1.2 Focal Loss 损失函数

Focal Loss 函数于 2018 年由 Facebook 人工智能实验室提出^[14],该函数通过降低不平衡样本中模型简单样本的权重达到提高对困难分类的效果。

在二分类问题中, y 为样本的真实标签, y' 为模型对输入样本属于正类($y = 1$)时的预测概率,则常用的交叉熵损失函数可设定为

$$L = \begin{cases} -\ln y', & y = 1 \\ -\ln(1 - y'), & y = 0 \end{cases} \quad (1)$$

Focal Loss 对交叉熵损失函数加入 γ 因子,将

Focal Loss 损失函数 L_{FL} 改进为

$$L_{FL} = \begin{cases} (1 - y')^\gamma \ln y', & y = 1 \\ -y'^\gamma \ln(1 - y'), & y = 0 \end{cases} \quad (2)$$

γ 因子的加入增大了难区分样本和易区分样本之间的损失差距,进而使模型更关注困难分类样本,同时将易分类样本的损失降低。在此基础上,还加入平衡因子 α ,以针对样本本身不平衡性进行调节,可表示为

$$L_{FL} = \begin{cases} -\alpha(1 - y')^\gamma \ln y', & y = 1 \\ -(1 - \alpha)y'^\gamma \ln(1 - y'), & y = 0 \end{cases} \quad (3)$$

通过调节 α 对大类样本以及易分类样本的损失函数值降低,使得模型在训练过程中更加关注小类样本和困难分类样本。

2 研究设计

提出基于改进 Focal Loss 和多粒度 CNN 的中文网络安全情报实体关系抽取分类方法 (multi-granularity CNN and enhanced Focal Loss, MCNNFL),使用 Focal Loss 克服长尾问题,运用多粒度 CNN 捕捉不同长度词汇的特征。对 MCNNFL 模型的文本表示层、多粒度卷积层、标签分类层和损失函数进行阐述,具体如下。

2.1 文本表示层


模型处理的第一步是将文本信息投影至向量空间进行向量化表示,使其能够输入模型进行向量

化运算。如图 1 中文本表示层所示,本文方法首先将样本中的文字在嵌入层直接进行嵌入表示,形成语义嵌入向量 E_{sentence} 。之后,分别对两个实体的位置进行嵌入表示,形成实体位置嵌入向量 E_{pos1} 和 E_{pos2} 。最后,将语义嵌入向量与两个实体的嵌入向量拼接,生成包含实体位置信息的语句嵌入向量 E_{input} 。本文方法使用 Pytorch 中的 $\text{Embedding}(\cdot)$ 函数,采用随机初始化的词向量矩阵和位置向量矩阵,词嵌入向量维度为 128,实体位置嵌入向量维度为 64。

2.2 多粒度卷积层

中文网络安全威胁情报文本具有中英文混杂、专业词汇多的特点,这导致其不可避免的包含大量长短不一的文本,即词语长度的方差较大。

鉴于此,为捕捉文本中不同长度重要词语的语义特征,提出采用多通道、多粒度的卷积神经网络模型捕捉更丰富的语义。具体来说,如图 1 中卷积层所示,多粒度卷积层包含 3 个卷积块,其卷积核大小分别为 1、3、5。在前向传播时,3 个不同大小的卷积核分别提取不同长度词汇的信息,大小为 1 的卷积核能够更好地捕捉短词汇的信息,而大小为 5 的卷积核更擅长捕捉长词汇的含义。当不同大小的卷积和对句子中的词汇提取完毕后,将这 3 个卷积块的输出沿隐藏层所在维度连接起来,生成包含短词汇和长词汇多粒度特征图,为进一步完成分类任



E_{sentence} 为语义嵌入向量; E_{pos1} 和 E_{pos2} 为实体位置嵌入向量; E_{input} 为包含实体位置信息的语句嵌入向量; C 为拼接操作; Conv1d 为一维卷积; kernel size 为卷积核大小; P 为池化操作; dropout 为随机失活技术

图 1 融合改进 Focal Loss 的多粒度 CNN 关系抽取模型

Fig. 1 Multi-grained CNN relationship extraction model for fusion-modified Focal Loss

务提供更加丰富的信息。之后,经过最大池化层将其最后一维池化,选取最大数字代表该句子的某种含义,得到 $32 \times 384 \times 1$ 维向量并将最后一维压缩。最终,将 32×384 维的向量输入最后的标签分类层进行分类。

2.3 标签分类层

在标签分类层,首先使用 dropout^[15] 对输入向量进行处理。之后,送入全连接层,采用 softmax 函数将全连接层的输出转换为概率。经过 softmax 函数计算后,各个类别的概率之和为 1,取概率值最大的类别作为最终的关系抽取结果。

2.4 损失函数

由 2.2 节中 Focal Loss 损失函数可知, γ 因子可以使模型更关注困难分类样本,同时将易分类样本的损失降低;平衡因子 α 可以针对样本本身不平衡性进行调节,但仅适用于二分类的情况。基于此,提出针对多分类的改进 Focal Loss 函数,可表示为

$$L_{FL} = -a_i [1 - p(r_i)]^\gamma \ln p(r_i) \tag{4}$$

式(4)中: i 为第 i 个类别, a_i 为第 i 类对应的平衡因子 a 的值; $p(r_i)$ 为第 i 类经过 softmax 函数后的概率值。

针对训练集中不同的样本数量,设置不同的 α 值,如表 1 所示。数量为 1~10 的实体关系类型属于需要更多重视的小样本类型,因此,将 α 值设置为 1。之后,每样本量每增加 10,则 α 值减少 0.1。当样本量大于 50 个时,则将 α 值设置为 0.5。

表 1 α 值与样本量的关系

Table 1 Relationship between the α value and the sample size

样本量/个	1 ~ 10	11 ~ 20	21 ~ 30	31 ~ 40	41 ~ 50	> 50
α 值	1	0.9	0.8	0.7	0.6	0.5

3 实验与分析

3.1 实验数据集


本实验采用中文威胁情报实体关系抽取数据集 CDTier^[16],该数据集包含 2 600 个样本,其中训练集、验证集与测试集样本数量的比例约为 3:1:1。该数据集共包含 5 个实体,分别为 Attacker、Tools、Region、Industry 和 Campaign,具体情况如表 2 所示。该 5 类实体共涉及 11 种关系类型,如图 2 所示。

这 11 类标签的分布情况如表 3 所示。可以看

表 2 CDTier 实体类别描述

Table 2 CDTier entity category description

实体类型	具体含义	实体举例
Attacker (攻击者)	进行某一恶意攻击的人员、组织或机构	海毒蛇、mnbjoker
Tools (工具)	攻击者针对某一领域使用的恶意软件、合法软件或自行研制的工具	百度网盘、RemcosRAT
Industry (攻击对象)	攻击者在攻击活动中的攻击对象	船舶重工企业、HooToo 路由器
Region (区域)	攻击者的目标区域或攻击者所在区域	加拿大、韩国
Campaign(活动)	攻击者发起的攻击活动	提菩行动、NorthStar



Attacker 为攻击者;Tools 为工具;Industry 为攻击对象;Region 为区域;alias_of 为别称;Campaign 为活动;cooperate_with 为合作;related_to 为相关;uses 为使用;target_at 为针对;originated_from 为源于;launch 为发动;kin 为同源;consist_of 为包含;operating_in 为属于;develop 为研制

图 2 5 类实体对应的 11 种关系

Fig. 2 11 relationships corresponding to the 5 classes of entities

投稿网址:www.stae.com.cn

表3 CDTier数据集分布情况
Table 3 CDTier data set distribution

类别标签	描述	训练集数量	验证集数量	测试集数量	总数量
alias_of(别称)	采用不同描述方式的同一攻击者或工具	214	59	77	350
cooprerate_with(合作)	攻击者之间的合作	19	8	6	33
related_to(相关)	有一定关系,但不能明确具体关系类型	107	29	27	163
uses(使用)	攻击者或活动使用某工具	227	42	58	327
target_at(针对)	攻击者或工具针对某一特定目标	627	157	195	979
originated_from(源于)	攻击者源自某一区域	125	34	34	193
launch(发动)	攻击者发动某一攻击活动	27	9	4	40
kin(同源)	恶意软件属于某一家族	5	4	1	10
consist_of(包含)	某一地区包含某一地区	39	15	12	66
operating_in(属于)	某一被攻击对象属于某一区域	241	50	90	381
develop(研制)	某一攻击者研制了某一工具	33	9	16	58
总数		1 664	416	520	2 600

出,在本任务中各类标签的分布并不均匀,具有长尾问题的特点。如 kin 类型仅有 10 个样本,而 target_at 类型却有 979 个样本。

3.2 评价指标

所解决的关系抽取问题为多分类问题,考虑到本任务中存在的长尾问题,为更公平地评价本方法的整体效果,采用加权平均(Weighted-avg)的方式来评价整体性能,计算公式分别为

$$T_i = \frac{S_i}{S_{all}} \tag{5}$$

$$P = \sum_{i=1}^n T_i P_i \tag{6}$$

$$R = \sum_{i=1}^n T_i R_i \tag{7}$$

$$F_1 = \sum_{i=1}^n T_i F_{1i} \tag{8}$$

$$A = \sum_{i=1}^n T_i A_i \tag{9}$$

式中: S_i 为第 i 类关系的样本数量; S_{all} 为所有样本的数量; T_i 为第 i 类关系样本数量占有所有样本数量的比例; n 为所有关系种类的数量; P_i 为第 i 类关系的精确率; P 为整体的精确率; R_i 为第 i 类关系的召回率; R 为整体的召回率; F_{1i} 为第 i 类关系样本的平衡 F 分数; F_1 为整体的平衡 F 分数; A_i 为第 i 类关系的准确率; A 为整体的准确率。

使用式(6)~式(9)中的精确率 P 、召回率 R 、平衡 F 分数 F_1 、准确率 A 作为评价指标。

3.3 实验环境

实验环境:操作系统为 ubuntu 20.04,采用的处理器是 Intel(R) Xeon(R) Platinum 8255C CPU @ 2.50 GHz,内存大小是 43 GB;采用的 GPU 型号是 RTX 3090,显存大小是 24 GB;所使用的 Python 版本为 3.8,PyTorch 版本为 1.11.0。

3.4 结果与分析

3.4.1 关系抽取实验结果比较

由表 4 可知,相较于其他模型,所提出的 MCNNFL模型因融合了多粒度的卷积核,以及针对多分类的 Focal Loss 损失函数,效果最佳,精确率、召回率和 F_1 值分别为 0.946 9、0.944 2 和 0.940 7。BiLSTM 在本任务中表现最差, F_1 值为 0.686 5,准确率为 0.696 1,原因可能是:中文网络安全威胁情报文本中的一些专业词汇偏长且复杂,而 BiLSTM 难以记忆。以 CNN 为基础的模型普遍取得较好的效果,但是在本领域中,分段卷积神经网络(piecewise convolutional neural network,PCNN)和注意力机制并未有效提升关系提取的效果。虽然全词覆盖的 BERT-CNN 模型(BERT-whole word masking-CNN,BERT-wwm-CNN)在通用数据集上的效果较好,但是在本任务中 F_1 值仅为 0.899 2,准确率仅为 0.901 9,分析原因在于:中文网络安全威胁情报文本中存在大量中英文混杂词汇、专业词汇的原因,导致预训练语言的效力下降。

表4 实验结果对比
Table 4 Comparison of experimental results

模型	精确率	召回率	F_1	准确率
BiLSTM	0.702 4	0.696 2	0.686 5	0.696 1
CNN ^[17-18]	0.931 8	0.928 9	0.923 7	0.928 9
PCNN ^[19]	0.911 6	0.907 7	0.909 2	0.907 7
CNN-ATT	0.906 1	0.900 0	0.898 9	0.900 0
PCNN-ATT ^[20]	0.868 3	0.865 4	0.861 5	0.865 4
BERT-wwm-CNN ^[21]	0.902 8	0.901 9	0.899 2	0.901 9
MCNNFL(本文模型)	0.946 9	0.944 2	0.940 7	0.944 2

3.4.2 消融实验

由表 5 可知,使用 3 个核大小为 3 的 CNN 模型所取得的 F_1 值和准确率分别为 0.747 6 和 0.932 7,其 F_1 值较低的原因是:其召回率仅有 0.702 3,推测是因为其核大小过为单一导致模型能够识别的语

义特征有限;而采用3个不同核大小的多粒度CNN时(卷积核大小分别为1、3、5),其 F_1 值提升至0.937 4,准确率提升至0.942 3,说明多粒度卷积在本任务中的有效性。此外,CNN模型在加入Focal Loss后, F_1 和准确率分别提升至0.933 5和0.938 5,说明Focal Loss可以有效提升本任务的识别效果。在将多粒度CNN和Focal Loss共同使用时,所提出的MCNNFL方法,其效果比单独使用多粒度CNN和单独使用Focal Loss都有所提升,表明在两种方法共同使用时,其效果不会相互抵消。

表6为CDTier数据集上各模型在各类别上分类结果的 F_1 。将多粒度CNN、CNN+Focal Loss和MCNNFL的 F_1 分别与CNN模型进行对比,使用加粗标记效果提升的数据;使用下划线标记效果下降的数据。

在使用多粒度CNN模型后,总体的 F_1 由原来的0.747 6提升至0.937 4,共提升0.189 8。具体来看,related_to类别提升最多,由0.690 9提升至0.800 0,共提升0.109 1。由图2可知,related_to类别经常在实体Attacker、Campaign和Region之间出现,因此其面临的词汇长度的方差较大,通过多粒度CNN可以更好地捕捉文字特征。launch类别由0.888 9降低至0.666 7,降低了0.222 2,但是由于其测试集样本只有4个,存在较大不稳定性因素,参考价值有限。

表5 CDTier数据集消融实验结果

指标	精确率	召回率	F_1	准确率
CNN(3个核大小均为3)	0.948 6	0.702 3	0.747 6	0.932 7
多粒度 CNN	0.944 6	0.942 3	0.937 4	0.942 3
CNN + Focal Loss	0.941 0	0.938 5	0.933 5	0.938 5
MCNNFL	0.950 6	0.946 2	0.943 7	0.946 2

表6 各模型在各类别上分类结果的 F_1

Table 6 F_1 value of the classification results for each model on each category

类别	CNN	Multi-kernels CNN	CNN + Focal Loss	MCNNFL	样本量 (训练集/测试集)
alias_of	0.950 0	0.962 0	0.968 2	0.980 7	214/77
cooperate_with	0.500 0	0.500 0	0.666 7	0.500 0	19/6
related_to	0.690 9	0.800 0	0.727 8	0.784 3	107/27
uses	0.843 0	0.883 7	0.876 0	0.890 6	227/58
target_at	0.969 4	0.974 4	0.967 3	0.974 5	627/195
originated_from	0.971 4	0.985 5	0.923 1	0.956 5	125/34
launch	0.888 9	0.666 7	0.857 1	0.857 1	27/4
kin	0	0	0	0	5/1
consist_of	0.909 1	0.960 0	1.000 0	0.956 5	39/12
operating_in	0.983 2	0.977 5	0.983 2	0.983 2	241/90
develop	0.608 7	0.692 3	0.720 0	0.740 7	33/16
总体	0.747 6	0.937 4	0.933 5	0.943 7	1 664/520

在使用改进的Focal Loss函数作为损失函数后,模型的总体 F_1 由0.747 6提升至0.933 4,共提升0.185 8。其中,作为小样本的cooperate_with、related_to、consist_of、develop类别的效果皆有大幅度提升。此外,部分样本量较大的类别(如alias_of、uses等)在本任务上的效果也有所提升,这说明Focal Loss函数在本任务上的效果。虽然在target_at、originated_from、launch效果有所下降,但是下降幅度较小,不影响本方法在全局效果上的提升。

将多粒度CNN和Focal Loss方法共同使用后,总体的 F_1 由0.747 6提升至0.943 7,共提升0.196 1。相较于单独使用多粒度CNN,提升了0.010 0;相较于单独使用Focal Loss,提升了0.010 2。

4 结论

(1)面向当前网络安全威胁情报领域构建知识图谱的需求,通过深度分析中文网络安全威胁情报的特征,提出使用改进的Focal Loss克服长尾问题,运用多粒度CNN捕捉不同长度词汇的语义特征,构建应用于中文网络安全威胁情报关系抽取任务的MCNNFL模型。实验结果表明,所提出的两种方法均能有效提升模型在该多分类任务上的性能,且两者可以共同使用,为中文网络安全威胁情报的自动关系抽取工作提供了参考。

(2)在未来工作中,将深入研究如何自动化配置模型中的超参数,实现数据的自动化处理。将继续收集中文网络安全威胁情报,扩大数据集的规模,并深入探究在大规模数据集上本模型的表现。将进一步研究、借鉴开放式信息抽取中的相关经验,实现模型的可扩展性。此外,将配合命名实体识别技术完成中文网络安全威胁情报知识图谱的构建,为态势感知、入侵检测、高级持续性威胁检测等网络安全领域中的下游应用提供支持。

参 考 文 献

[1] 杨宇,谷宇恒. 网络安全态势感知综述[J]. 科学技术与工程, 2022, 22(34): 15011-15019.
Yang Yu, Gu Yuheng. Overview of network security situation awareness[J]. Science Technology and Engineering, 2022, 22(34): 15011-15019.

[2] 杨宇,闫钰,申芳,等. 基于机器和深度学习的入侵检测综述[J]. 科学技术与工程, 2023, 23(18): 7607-7621.
Yang Yu, Yan Yu, Shen Fang, et al. Review of intrusion detection based on machine and deep learning[J]. Science Technology and Engineering, 2023, 23(18): 7607-7621.

[3] Sun N, Ding M, Jiang J, et al. Cyber threat intelligence mining for proactive cybersecurity defense: a survey and new perspectives[J]. IEEE Communications Surveys and Tutorials, 2023, 25(3): 1748-1774.

- [4] 杨书鸿, 牛玥, 刘力铭. 融合外部知识和图卷积神经网络的生物医学事件联合识别[J]. 科学技术与工程, 2024, 24(22): 9464-9473.
Yang Shuhong, Niu Yue, Liu Liming. Joint recognition of biomedical events incorporating external knowledge and graph convolutional neural networks[J]. Science Technology and Engineering, 2024, 24(22): 9464-9473.
- [5] 许雅玺, 孟天宇, 王欣, 等. 航空不安全事件知识图谱构建[J]. 科学技术与工程, 2024, 24(32): 13925-13934.
Xu Yaxi, Meng Tianyu, Wang Xin, et al. Construction of knowledge graph for aviation unsafe events[J]. Science Technology and Engineering, 2024, 24(32): 13925-13934.
- [6] Wang H, Lu G, Yin J, et al. Relation extraction: A brief survey on deep neural network-based methods [C]//Proceedings of the 2021 4th International Conference on Software Engineering and Information Management. New York: IEEE, 2021: 220-228.
- [7] 鄂海红, 张文静, 肖思琪, 等. 深度学习实体关系抽取研究综述[J]. 软件学报, 2019, 30(6): 1793-1818.
E Haihong, Zhang Wenjing, Xiao Siqu, et al. Survey of entity relationship extraction based on deep learning[J]. Journal of Software, 2019, 30(6): 1793-1818.
- [8] 史慧洋, 魏靖烜, 蔡兴业, 等. 威胁情报提取与知识图谱构建技术研究[J]. 西安电子科技大学学报, 2023, 50(4): 65-75.
Shi Huiyang, Wei Jingxuan, Cai Xingye, et al. Research on threat intelligence extraction and knowledge graph construction technology [J]. Journal of Xidian University, 2023, 50(4): 65-75.
- [9] 郭渊博, 李勇飞, 陈庆礼, 等. 融合 Focal Loss 的网络威胁情报实体抽取[J]. 通信学报, 2022, 43(7): 85-92.
Guo Yuanbo, Li Yongfei, Chen Qingli, et al. Fusion of Focal Loss's cyber threat intelligence entity extraction [J]. Journal of Communications, 2022, 43(7): 85-92.
- [10] 罗琴, 杨根, 刘智, 等. 结合主动学习的威胁情报 IOC 识别方法[J]. 电子科技大学学报, 2023, 52(1): 108-115.
Luo Qin, Yang Gen, Liu Zhi, et al. ICAL: a threat intelligence IOC identification method combined with active learning[J]. Journal of University of Electronic Technology of China, 2023, 52(1): 108-115.
- [11] Han Y, Lu Z, Jiang B, et al. MTLAT: a multi-task learning framework based on adversarial training for Chinese cybersecurity NER[C]//IFIP International Conference on Network and Parallel Computing. Cham: Springer International Publishing, 2020: 43-54.
- [12] 刘晓凯. 网络安全知识图谱中的长尾关系抽取问题研究[D]. 武汉: 华中科技大学, 2022.
Liu Xiaokai. Research on long-tail relation extraction in cyberspace security knowledge graph [D]. Wuhan: Huazhong University of Science and Technology, 2022.
- [13] 谢博. 基于深度学习的中文网络威胁情报信息抽取技术研究 [D]. 贵阳: 贵州大学, 2022.
Xie Bo. Research on the extraction technology of Chinese cyber threat intelligence information based on deep learning [D]. Guiyang: Guizhou University, 2022.
- [14] Li X, Wang W, Wu L, et al. Generalized focal loss: Learning qualified and distributed bounding boxes for dense object detection [J]. Advances in Neural Information Processing Systems, 2020, 33: 21002-21012.
- [15] Hinton G E, Srivastava N, Krizhevsky A, et al. Improving neural networks by preventing co-adaptation of feature detectors[J]. arXiv Preprint, 2012; arXiv: 1207.0580.
- [16] Zhou Y, Ren Y, Yi M, et al. CDTier: a Chinese dataset of threat intelligence entity relationships [J]. IEEE Transactions on Sustainable Computing, 2023, 8(4): 627-638.
- [17] Zeng D, Liu K, LAI S, et al. Relation classification via convolutional deep neural network [C]//Proceedings of the 25th International Conference on Computational Linguistics. Stroudsburg: ACL, 2014: 2335-2344.
- [18] 高丹, 彭敦陆, 刘丛. 海量法律文书中基于 CNN 的实体关系抽取技术 [J]. 小型微型计算机系统, 2018, 39(5): 1021-1026.
Gao Dan, Peng Dunlu, Liu Cong. Entity relation extraction based on CNN in large-scale text data [J]. Small Microcomputer System, 2018, 39(5): 1021-1026.
- [19] Zeng D, Liu K, Chen Y, et al. Distant supervision for relation extraction via piecewise convolutional neural networks [C]//Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing. Stroudsburg: ACL, 2015: 1753-1762.
- [20] 赵良, 张赵玥, 廖子逸, 等. 用 BERT 和改进 PCNN 模型抽取食品安全领域关系[J]. 农业工程学报, 2022, 38(8): 263-270.
Zhao Liang, Zhang Zhaoyue, Liao Ziyi, et al. Relationship extraction in the field of food safety based on BERT and improved PCNN model [J]. Journal of Agricultural Engineering, 2022, 38(8): 263-270.
- [21] 武小平, 张强, 赵芳, 等. 基于 BERT 的心血管医疗指南实体关系抽取方法[J]. 计算机应用, 2021, 41(1): 145-149.
Wu Xiaoping, Zhang Qiang, Zhao Fang, et al. Entity relation extraction method for guidelines of cardiovascular disease based on bidirectional encoder representation from transformers [J]. Computer Applications, 2021, 41(1): 145-149.