

暨南大学硕士学位论文

题名（中英对照）：

基于知识图谱的 APT 组织攻击偏好预测

Prediction on Attack Preference of APT Groups Based on Knowledge Graph

作者姓名：方洁凤

指导教师姓名

及学位、职称：孙玉霞 副教授

学科、专业名称：计算机科学与技术 计算机应用技术专业

学位类型：学术学位

论文提交日期： 年 月 日

论文答辩日期：2023 年 05 月 26 日

答辩委员会主席：王捍贫

论文评阅人：盲审

学位授予单位和日期：暨南大学 6 月 21 日

独创性声明

本人声明所呈交的学位论文是本人在导师指导下进行的研究工作及取得的研究成果。除了文中特别加以标注和致谢的地方外，论文中不包含其他人已经发表或撰写过的研究成果，也不包含为获得暨南大学或其他教育机构的学位或证书而使用过的材料。与我一同工作的同志对本研究所做的任何贡献均已在论文中作了明确的说明并表示谢意。

学位论文作者签名：

签字日期：

年

月

日

学位论文授权使用授权书

本学位论文作者完全了解暨南大学有关保留、使用学位论文的规定，有权保留并向国家有关部门或机构送交论文的复印件和磁盘，允许论文被查阅和借阅。本人授权暨南大学可以将学位论文的全部或部分内容编入有关数据库进行检索，可以采用影印、缩印或扫描等复制手段保存、汇编学位论文。

（保密的学位论文在解密后适用本授权书）

学位论文作者签名：

导师签名：

签字日期： 年 月 日

签字日期： 年 月 日

学位论文作者毕业后去向：

工作单位：

电话：

通讯地址：

邮编：

摘要

随着信息技术的广泛应用，全世界范围内网络安全事件频发。其中，具有国家或组织背景的高级持续性威胁（APT）的攻击目标明确、隐蔽性强、危害性大，经常造成巨大的负面经济和政治影响。每个 APT 组织在其目标攻击领域和平台、所采用的攻击模式和工具等方面呈现出一定的偏好性。目前，各安全团队所发布的 APT 威胁情报是由专业安全人员对 APT 攻击活动进行分析所得的重要报告。然而，这些报告对于 APT 组织攻击偏好的描述往往并不完整。为了防御 APT 攻击，很有必要深入挖掘 APT 组织的攻击偏好，以揭开 APT 组织的神秘面纱，从而制定具有针对性的主动防御措施。因此，有效预测 APT 组织的攻击偏好对于维护网络安全、降低 APT 攻击损失具有重要意义。

本文通过构建 APT 威胁情报知识图谱来预测 APT 组织的攻击偏好，将上述的偏好预测问题转化为知识图谱中的链接预测问题，主要包括以下研究工作：

（1）基于 APT 威胁情报，构建了面向 APT 组织攻击偏好预测的知识图谱 APT5K：首先基于公开本体库 MALOnt 和开源数据集 APTNER，建立与 APT 组织攻击偏好相关的本体，共包括 21 种细粒度实体类型和 10 种关系类型；然后构建 CyBERT-BiLSTM-CRF 模型以实现自动化的命名实体识别；接着利用开源数据标注平台 doccano 对关系进行人工标注，进而提出融合实体类型信息的数据增强方法，建立了包含约 5 千个三元组的知识图谱 APT5K。实验结果表明，与基于 BERT 的基线模型相比，CyBERT-BiLSTM-CRF 模型能够更好地识别 APT 组织攻击偏好相关实体，所提出的数据增强方法能够有效提升链接预测模型的性能。

（2）建立了一个融合外部信息 and 对比学习的知识图谱链接预测模型 KLEC（Knowledge graph Link prediction model with External information and Contrastive learning）：KLEC 模型用于预测知识图谱 APT5K 中缺失的 APT 组织偏好。此模型将知识图谱转换为包含关系节点的图，利用安全领域的语言模型 CyBERT 生成节点的语义信息，利用对偶四元数图神经网络 DQGNN 融合图节点的邻域信息，并使用基于三元组的对比学习来生成图节点的嵌入表示。在知识图谱 APT5K 上的实验结果表明，与不使用外部信息 or 对比学习的链接预测模型相比，KLEC 模型具有明显更优的 APT 组织攻击偏好预测效果。

关键词：APT 组织，知识图谱，图神经网络，外部信息，对比学习

Abstract

With the widespread application of information technology, network security incidents occur frequently worldwide. Among them, Advanced Persistent Threat (APT) with national or organizational backgrounds have clear targets, strong concealment, and significant harm, often causing significant negative economic and political impacts. Each APT group exhibits certain preferences in terms of its target attack field and platform, as well as the attack patterns and tools used. At present, the APT threat intelligence released by various security teams are important reports obtained from the analysis of APT attack activities by professional security personnel. However, the description of APT groups' attack preferences in these reports is often incomplete. In order to defend against APT attacks, it is necessary to dig deeply into the attack preferences of APT groups to unveil the mystery of APT groups, so as to develop targeted active defense measures. Therefore, effectively predicting the attack preferences of APT groups is significant for maintaining network security and reducing APT attack losses.

This article predicts the attack preferences of APT groups by constructing an APT threat intelligence knowledge graph, transforming the aforementioned preference prediction problem into a link prediction problem in the knowledge graph. The main research work includes the following:

(1) Based on APT threat intelligence, a knowledge graph APT5K for predicting APT groups' attack preferences is constructed. Firstly, this thesis establishes an ontology related to APT groups' attack preferences based on the public ontology MALOnt and the open source dataset APTNER, including 21 fine-grained entity types and 10 relation types. Then a CyBERT-BiLSTM-CRF model is constructed to achieve automated Named Entity Recognition. Subsequently, the open source data annotation platform doccano was used to manually annotate relations. And then propose a data enhancement method that integrates entities' type information to establish a knowledge graph APT5K containing approximately 5,000 triples. The experimental results show that compared with the baseline model based on BERT, CyBERT-BiLSTM-CRF model can better identify entities related to APT groups' attack preferences and the data augmentation method used in this thesis can effectively improve link prediction performance.

(2) We have constructed a knowledge graph link prediction model KLEC (Knowledge Graph Link prediction model with External information and Contrastive learning) that integrates external information and contrastive learning. The KLEC model is used to predict missing APT groups'

preferences in the knowledge graph APT5K. This model converts the knowledge graph into a graph containing relational nodes, uses the language model CyBERT in the security field to generate the semantic information of the nodes, uses the Dual Quaternion Graph Neural Network (DQGNN) to fuse the neighborhood information of the graph nodes, and uses triple-based Contrastive Learning to generate embedding representations of graph nodes. The experimental results on the knowledge graph APT5K show that the KLEC model has a significantly better prediction effect on APT organization attack preference than the link prediction model that does not use external information or contrastive learning.

In a word, in order to predict the attack preference of APT groups, this thesis uses APT threat intelligence as the data source to semi-automatically build the corresponding domain knowledge graph, and establishes a link prediction model that combines external information and contrastive learning to effectively predict the attack preference of APT groups.

Keywords: APT Groups, Knowledge Graph, Graph Neural Network, External Information, Contrastive Learning

目录

摘要.....	I
Abstract.....	II
目录.....	IV
1 绪论	1
1.1 研究背景及意义.....	1
1.2 国内外研究现状.....	3
1.3 本文研究工作.....	9
1.4 论文结构.....	9
2 基础知识	11
2.1 命名实体识别.....	11
2.2 关系模式.....	14
2.3 知识图谱嵌入模型.....	14
2.4 图神经网络.....	20
2.5 对比学习.....	22
3 面向 APT 组织攻击偏好预测的知识图谱构建	24
3.1 知识图谱 APT5K 构建的总体流程	24
3.2 知识图谱 APT5K 构建的子过程	24
3.3 本章小结.....	32
4 融合外部信息和对比学习的链接预测模型 KLEC.....	33
4.1 问题描述.....	33
4.2 KLEC 模型的总体框架	33
4.3 KLEC 模型的子模块.....	34
4.4 本章小结.....	38
5 实验研究	39
5.1 实验设置.....	39
5.2 研究问题一、命名实体识别模型 CyBERT-BiLSTM-CRF 的有效性.....	42
5.3 研究问题二、融合实体类型信息的数据增强方法有效性.....	43
5.4 研究问题三、链接预测模型 KLEC 的有效性	45

5.5 研究问题四、KLEC 模型中语义信息和对比学习模块的必要性	48
5.6 本章小结	51
6 总结展望	52
6.1 工作总结	52
6.2 未来展望	52
参考文献.....	53
在校期间发表的学术论文及科研工作情况.....	59
致谢.....	60

1 绪论

1.1 研究背景及意义

随着信息化时代的到来，人们的生活、工作、学习都离不开网络 and 现代科技设备。信息技术的广泛使用在给人们带来便利的同时，也将各种重要信息暴露于网络中，存在很大的安全风险。近年来，全世界范围内网络安全事件频发，造成了巨大的经济损失。作为当前网络安全面临的重要威胁之一，高级持续性威胁（Advanced Persistent Threat, APT）^[1]是一种过程复杂、持续时间长、隐蔽性强、危害性大的网络攻击，其通常具有国家或者组织背景。此外，APT 攻击还伴随着强烈的政治目的或经济目的，其攻击目标往往是涉及重要商业机密、国家安全数据的企业和单位，一旦被成功攻击将会造成严重后果。奇安信团队发布了《全球高级持续性威胁（APT）2022 年度报告》^[2]，以开源 APT 情报等作为数据来源，对 2022 年全球所披露的 APT 攻击活动中所涉及的行业领域分布情况进行统计，如图 1-1 所示。其中，涉及政府（包括外交、政党、选举相关）的攻击事件占比最多，为 33%；其次，涉及国防军事的攻击事件占比 14%，涉及科技的攻击事件占比 12%。涉及政府、国防军事、科技的 APT 攻击事件总占比为 59%，说明这三者是 APT 攻击的主要目标行业领域。此外，该报告还对 APT 攻击活动中所涉及目标的国家和地区分布情况进行统计，如图 1-2 所示。从图 1-2 可以看出，2022 年全球所披露的 APT 攻击活动主要集中在东欧、南亚、东亚的几个国家或地区。




图 1-1 2022 年 APT 攻击活动所涉及的行业分布情况




图 1-2 2022 年 APT 事件针对的国家和地区

除了以上统计的 APT 攻击活动在目标行业领域、目标地区和国家具有偏好性之外，每个 APT 组织在目标行业领域、目标平台、所采用攻击模式和工具等方面也呈现出一定的偏好性。目前，各安全团队所发布的 APT 威胁情报是由专业安全人员对 APT 攻击活动进行分析得到的重要报告，是了解全球 APT 发展的重要手段之一。然而，这些报告对于 APT 组织攻击偏好的描述往往并不完整。为了更好防御 APT 攻击，很有必要深入挖掘 APT 组织的攻击偏好并实现自动化预测，有助于揭开 APT 组织的神秘面纱，并制定具有针对性的主动防御措施。因此，有效预测 APT 组织的攻击偏好对于维护网络安全、降低 APT 攻击损失具有重要价值。

APT 威胁情报对于提高网络的主动防御能力非常重要，但不同情报之间相互独立、缺少联系，且为非结构化数据。如何有效利用这些情报中的高价值信息成了研究人员关注的重点。网络安全知识图谱（Cyber Security Knowledge Graph, CSKG）可以将众多非结构化 APT 威胁情报中的安全信息构建到同一个图形拓扑结构，方便查询现有知识并对未知知识进行推理，是一种高效的结构化知识管理方式。尽管目前已经出现了一些网络安全知识图谱的研究，但是还不存在一个领域通用的图谱^[3]。当前只有少量针对 APT 组织攻击偏好的网络安全知识图谱，且存在实体类型粗粒度的情况。因此，构建一个面向 APT 组织攻击偏好预测且具有细粒度实体类型的知识图谱对于有效挖掘 APT 组织攻击偏好至关重要。

传统的攻击偏好预测任务常假设攻击者在每个攻击偏好维度上的倾向性是互斥的（如只偏好于攻击一个国家），从而将其转化为分类问题。但这个假设显然不符合 APT 组织攻击偏好的实际情况。因此，本文将 APT 组织攻击偏好预测任务转换为知识图谱中的链接预测（Link Prediction, LP）问题，以适应一个 APT 组织在单一攻击偏好维度上有多种倾向的实际情况（如一个 APT 组织可能偏好于攻击多个目标国家或地区，也可能偏好于攻击多个行业领域如金融、教育等）。因此，提出一个有效的链接预测模型对于自动化预测 APT 组织攻击偏好非常重要。

总之，本文将基于 APT 威胁情报，构建一个面向 APT 组织攻击偏好预测且具有细粒度实体类型的知识图谱。在此基础上，提出一个有效的链接预测模型，并通过实验验证上述模型和技术在 APT 组织攻击偏好自动化预测问题上的有效性。本研究有利于推动对 APT 攻击的主动防御，有助于降低网络攻击所造成的损失，对保障网络空间安全具有重要的理论意义和应用价值。

1.2 国内外研究现状

1.2.1 知识图谱研究现状

知识图谱（Knowledge Graph, KG）^[4]的概念于 2012 年最先由 Google 公司提出，以图的形式来描述现实世界中的概念实体（如：人、事、物等作为节点）以及它们之间的关系（作为边）。最初提出 KG 是为了提高 Google 搜索引擎性能，通过洞察用户查询背后的语义信息来返回更高质量的答案并优化广告服务。知识图谱的前身可以追溯到万维网之父 Time Berners-Lee 在 1998 年提出的语义网（Semantic Web）^[5]，乃至上个世纪五六十年代提出的语义网络（Semantic Network）。自知识图谱提出以来，其高效整合数据中有效信息的能力就受到了人们的广泛关注，已经在语义搜索、问答系统、大数据分析、个性化推荐、辅助决策等方面展现出巨大的应用价值，在金融、医疗等行业中得到了广泛应用。

按照应用领域的不同，可以将知识图谱分为通用知识图谱（General Knowledge Graph）、领域知识图谱（Domain Knowledge Graph）两类^[6]。通用知识图谱不局限于具体的应用领域，一般是描述现实世界中的大量常识性知识，具有比较全面的特点。通用知识图谱又可以细分为百科知识图谱（Encyclopedia Knowledge Graph）、常识知识图谱（Common Sense Knowledge Graph），其中，百科知识图谱是由百科事实构成的确定性知识，更侧重于客观事物，典型的百科知识图谱有 DBpedia^[7]、Freebase^[8]、YAGO^[9]等，而常识知识图谱则集成了概念常识和语言知识，典型的常识知识图谱有 ConceptNet^[10]、Nell^[11]等。领域知识图谱，

也称为行业知识图谱、垂直知识图谱^[12],是面向特定行业、由专业数据构建而成的知识库,如医疗知识图谱、金融知识图谱、网络安全知识图谱等。相较于通用知识图谱,领域知识图谱的构建对相关人员的专业性提出了更高的要求。

1.2.2 网络安全知识图谱研究现状

近些年来,全世界范围内网络安全事件频发,APT 攻击的数量和强度也在不断增加。然而,知识丰富的网络安全人员数量增长速度却远远比不上这些网络安全事件的增长^[13]。为了更好地满足快速增长的网络安全分析需求,引入自动化、智能化技术迫在眉睫,知识图谱技术的兴起为此提供了一个新的解决思路。网络安全知识图谱是知识图谱在网络安全领域的应用,通过整合各种形式的安全信息和数据,可以直观地建模网络安全领域的各种攻防场景,呈现真实、信息丰富的安全世界,方便人员对网络安全信息进行智能分析,提高分析效率和质量。

知识图谱的构建主要依赖于“本体”(Ontology)的指导,“本体”的概念最初来源于哲学,在知识图谱中则代表概念共享模型,用于描述概念以及概念之间的关系,使得概念和关系在共享范围内有一个明确、唯一的定义。按照应用领域的不同,可以分为通用本体和领域本体两类,分别指导通用知识图谱和领域知识图谱的构建。本体的构建方式有自底向上和自顶向下两种,通用本体大多以数据为驱动,采用自底向上的构建方式;而网络安全领域的知识数据相对成熟和完整,可以采用自顶向下的构建方式来构建其领域本体^[3]。目前网络安全领域中的常用公开本体有:STUCCO^[14]、UCO^[15]、MALOnt^[16]等。

网络安全知识图谱的数据来源按照结构化程度不同可以分为三类:结构化数据、非结构化数据和半结构化数据。结构化数据是指已经按照一定格式进行编排和组织的数据,包括国家级漏洞数据库,如美国国家漏洞库(National Vulnerability Database, NVD)、中国国家漏洞库(China National Vulnerability Database, CNVD),还包括企业级情报数据,如通用漏洞披露(Common Vulnerabilities & Exposures, CVE)、通用缺陷枚举(Common Weakness Enumeration, CWE)、通用攻击模式枚举和分类(Common Attack Pattern Enumeration and Classification, CAPEC)等。非结构化数据是指没有明显结构和格式的文本数据,包括安全博客、网络安全威胁情报等。半结构化数据则介于结构化和非结构化数据之间,既有一定的结构化特征,又存在一些自由格式的文本数据,包括日志文件、Web 网页。Keisling 等人^[17]使用 CVE、CWE、CAPEC 等数据构建一个侧重于漏洞、缺陷和攻击模式的知识图谱;Sarhan 等人^[18]使用 APT 报告、网络威胁情报数据作为数据源,从非结构化文本中提取网

络威胁信息；Rastogi 等人^[19]从 CVE 数据库和恶意软件报告数据来源构建知识图谱，融合异构数据来源。一般来说，数据的结构化程度越高，知识抽取更容易，但其时效性也越低。当数据来源是半结构化或者非结构化数据时，经常涉及实体抽取（Entity Extraction, EE）和关系抽取（Relation Extraction, RE）这两种信息抽取技术，其中实体抽取也被称为命名实体识别（Named Entity Recognition, NER）。

1.2.3 攻击偏好研究现状

攻击偏好是指网络攻击或者 APT 攻击在其攻击的目标、方式等方面所呈现出的偏好性。近年来，Mittal 等人^[20]搜集社交媒体 Twitter 上实时更新的开源网络安全情报作为数据源，使用 UCO 等本体构建网络安全知识图谱，基于攻击偏好实现网络安全预警。Rass 等人^[21]从博弈论角度分析攻击偏好，Zhao 等人^[22]搜集安全博客、安全新闻、黑客论坛帖子等作为数据源，提出了一个属性异构信息网络（Attributed Heterogeneous Information Network, AHIN）对数据进行建模，并将攻击偏好预测转化为分类问题，并通过构造元图的方式学习攻击偏好的高阶特征。以上文献大部分都是针对网络攻击偏好展开研究，目前只有少量文献对 APT 组织的攻击偏好展开研究：Moon 等人^[23]搜集设备日志信息作为数据源，对 APT 攻击每个步骤的攻击偏好进行分析，构建一个多层的 APT 防御系统，提高系统防御能力。Ren 等人^[24]基于非结构化的网络威胁情报和 STIX 标准，定义了 12 种实体类型和 11 种关系类型，构建了网络安全知识图谱，并使用钻石模型从四个维度对 APT 组织攻击偏好进行分析，揭露 APT 组织的攻击意图。但是该研究中所定义的 12 种实体类型较为粗粒度，且不能对攻击偏好进行自动化预测。

1.2.4 知识图谱链接预测研究现状

链接预测是知识图谱补全中的子任务之一。即使是目前最完善的知识图谱，也仍然存在信息不完善的情况，需要进行补全。知识图谱是一种采用符号化方式表示的语义网络，通常是以三元组的形式进行存储，即（头实体，关系，尾实体），常写作 (h, r, t) 。这种离散表示方法虽然非常直观、易于人类理解，但对于基于机器学习的链接预测任务并不友好。因此，人们引入了知识图谱嵌入（Knowledge Graph Embedding, KGE）技术，也称知识表示学习（Knowledge Representation Learning, KRL）技术。KGE 通过将现有的事实信息映射到低维空间中，得到实体和关系的连续向量表示（即嵌入表示），从而有利于实现基于机器学习的链接预测。

现有的知识图谱嵌入技术大多数都是基于观察到的事实三元组 (h, r, t) ，首先设计一个评分函数 $f(h, r, t)$ 来评估每个三元组的合理性，以区分正确事实和不正确事实；然后最大化事实三元组的总评分函数来引导实体、关系的嵌入学习，以使得观察到三元组的总合理性最大化。现有的嵌入模型可以大致分为以下几类^[25,26]：

(1) 翻译模型：使用基于距离的评分函数，将关系看作是头实体到尾实体的平移变换，计算经过变换后的头实体和尾实体之间的距离来评估三元组的合理性。TransE 模型是 Bordes 等人^[27]于 2013 年最早提出的翻译模型，主要受到了 Word2Vec^[28]中词向量空间存在平移不变现象的启发。给定事实三元组 (h, r, t) ，TransE 模型将实体和关系映射到同一个 d 维的实数空间 $\mathbb{R}^d$ 中，得到实体向量 h 、 t 和关系向量 r ；把关系向量 r 当作两个实体向量 h 、 t 之间以低误差连接的翻译向量，对头实体进行变换以近似得到尾实体，即 $h + r \approx t$ 。TransE 模型非常简单有效，但仍存在以下缺点：根据向量的加法运算，在给定任意两个向量之后，第三个向量也会被唯一确定。这使得该模型适用于处理一对一的关系，而不适合处理真实世界数据集中存在的一对多、多对一和多对多关系。为了解决以上问题，人们提出了以下 Trans 系列模型：Wang 等人^[29]提出的 TransH 模型引入了超平面的概念，将每个关系向量 r 建模到各自的超平面上，并将头尾实体映射到关系向量 r 所在的超平面上，从而得到每个关系向量 r 对应的头尾实体向量 h' 、 t' ；Lin 等人^[30]提出的 TransR 模型假设实体和关系处于不同的向量空间中，对于不同关系设置不同的投影矩阵，将 d 维实体空间 $\mathbb{R}^d$ 中的实体向量 h 、 t 向 k 维的关系空间 $\mathbb{R}^k$ 中投影，以区分实体空间中相似的头尾实体；Ji 等人^[31]提出的 TransD 模型将投影矩阵分解成为两个投影向量，使得投影矩阵由实体和关系共同决定，从而将矩阵运算转换成了向量间的运算，大大提升了运算速度，解决了 TransR 模型的参数众多问题；考虑到知识图谱的异质性和不平衡性，Ji 等人^[32]还提出了 TranSparse 模型，对投影矩阵上进行稀疏化以简化 TransR。

(2) 旋转模型：除了基于实数空间的平移变换模型之外，人们还提出了基于复数空间的旋转变换模型。Sun 等人^[33]提出的 RotatE 模型将三元组中的实体和关系建模到复数向量空间 $\mathbb{C}^d$ 中，并认为每个关系是在复数空间中头实体到尾实体的旋转变换。给定事实三元组 (h, r, t) 时，假定 $h \circ r = t$ ，其中，符号 $\circ$ 是哈达玛积（Hadamard Product）。该模型可以推断出各种关系模式，如对称、反对称、反转和合成关系，且在时间和空间上都是线性复杂度，适用于大型知识图谱。Zhang 等人^[34]提出的 QuatE 模型，将复数空间扩展到超复数空间 $\mathbb{H}^d$ ，

也叫四元数空间,在该空间中对实体和关系进行建模,并使用哈密顿积(Hamilton Product)替换哈达玛积。QuatE 模型解决了哈达玛积交换律所导致的 RotatE 模型在建模合成关系时的缺陷。此外,QuatE 有两个旋转平面,而 RotatE 只有一个旋转平面,因此 QuatE 模型具有更强的旋转能力。Zhang 等人^[35]提出的 HAKE 模型考虑到实体之间具有语义层次,在极坐标系中对实体和关系进行建模,通过同心圆概念区分实体的语义层级关系。Cao 等人^[36]在 QuatE 的基础上提出了 DualE 模型,使用对偶四元数替换 QuatE 模型中的四元数,融合了 Trans 系列、RotatE 和 QuatE 等模型的优点,使得三元组中的关系兼具了平移和旋转变换操作,具有更强的建模能力。

(3) 语义匹配模型:使用了基于相似度的评分函数,通过匹配向量空间中实体和关系的潜在语义表示来衡量三元组的合理性。相较于翻译模型使用加法算子,语义匹配模型中通常使用乘法算子,因此也被称为乘法模型。Nickel 等人^[37]提出的 RESCAL 模型是最早的语义匹配模型,将知识图谱建模为一个三阶张量,将关系建模成矩阵,从而学习实体潜在因子之间的成对相互关系。Lin 等人^[38]提出的 TuckER 模型将三元组建模为一个三阶张量,并通过三阶张量分解得到核心张量和实体、关系的嵌入向量。Yang 等人^[39]提出的 DistMult 模型在 RESCAL 模型的基础上,将其关系矩阵限制为对角矩阵,以简化 RESCAL 模型的参数量。Trouillon 等人^[40]提出的 ComplEx 模型是对 DistMult 模型的扩展,将实体和关系向量建模为复数空间中的嵌入,可以对反对称关系模型实现更好建模并挖掘潜在的语义关联。Kazemi 等人^[41]提出的 Simple 模型也沿用了 DistMult 模型中将关系矩阵限制为对角阵的处理,该模型基于 CP(CANDECOMP/PARAFAC)分解,在训练时通过联合优化的方式使得头实体和尾实体产生相关性。

(4) 神经网络模型:借助神经网络的强大特征学习能力,模拟输入数据在连续低维向量空间中的投影,自动学习实体和关系的特征表示。Dettmers 等人^[42]提出的 ConvE 模型首次将卷积神经网络(Convolution Neural Network, CNN)应用于知识图谱嵌入,将头实体和关系重构为二维矩阵,并采用二维卷积的方法学习嵌入表示,提高了计算速度和参数效率。Nguyen 等人^[43]提出的 ConvKB 模型融合了 ConvE 和翻译模型的思想,使用一维卷积保留了 TransE 的特点,能够有效捕获实体之间的全局关系。

(5) 引入外部信息:传统的链接预测模型仅仅基于三元组本身所包含的信息,忽略了信息量更大的外部信息(如文本描述、关系路径、实体类型、邻域信息等)。然而,这些外部信息对于学习到更好的实体关系嵌入、提高链接预测效果非常重要^[44]。实验结果表明,

融合外部信息的嵌入技术通常优于传统技术。①大多数知识图谱都涉及对于实体简洁但信息丰富的描述, Xie 等人^[45]提出的 DKRL 模型在 TransE 的基础上进一步考虑了实体描述, 捕获了基于结构的表示和基于描述的表示。②关系路径包含丰富的语义信息, 考虑知识图谱中的关系路径可以更好地利用全局信息, 经典模型有 PTransE^[46]、RTransE^[47]等。③采用实体类型同时有利于捕获知识图谱中的丰富语义信息, Xie 等人^[48]提出的 TKRL 模型采用了层次类型, Jain 等人^[49]提出的 TypeComplex 模型是在 ComplEx 模型的基础上进行修改以考虑实体类型信息, Niu 等人^[50]提出的 AutoETER 则同时使用了类型特定的三元组编码器和实体特定的三元组编码器。④知识图谱本质上也是一种图结构数据, 人们开始将图神经网络 (Graph Neural Network, GNN) 应用到知识图谱嵌入技术中, 以捕获图结构中每个节点的邻域信息^[51]。

图卷积网络 (Graph Convolution Network, GCN)^[52]是重要的图神经网络模型, 最初用于无向单关系图。针对知识图谱这种有向多关系图, 人们设计了多种 GCN 变体: Schlichtkrull 等人^[53]提出的 R-GCN 模型首次将 GCN 扩展到多关系图建模中, 将每种关系看作对邻居节点的不同变换, 即每种关系对应一个权重矩阵; 使用对应的权重矩阵转换邻居节点的特征, 再使用 GCN 聚合邻居信息。但是在关系种类较多时, R-GCN 的参数量也较大。针对该问题, R-GCN 中使用了参数共享和稀疏化矩阵策略对关系矩阵进行约束, 以减少模型参数并防止过拟合。此外, Schlichtkrull 等人还提出了将 GNN 系列模型应用于链接预测任务的 Encoder-Decoder 框架: 用 R-GCN 作为编码器学习实体嵌入, 再将编码器最后一层输出的实体嵌入输入到解码器 DisMult (即评分函数) 中, 以评估三元组的合理性。虽然 R-GCN 考虑了关系类别, 但并未显式学习关系嵌入, 且忽略了关系的方向性和异构图中不同实体类型可能存在不同特征空间的问题。对此, Rui 等人^[54]提出了一种关系向量化的 VR-GCN 模型, 将 TransE 中 $h + r \approx t$ 的思想引入 R-GCN, 在聚合邻居信息之前先将邻居实体转移到中心实体的特征空间中。该模型考虑了关系的类别信息和方向性, 同时学习实体和关系的嵌入, 但需要存储所有节点的历史隐藏嵌入, 无法应用到大规模图上。在 VR-GCN 的基础上, Vashishth 等人^[55]提出了 CompGCN 模型。该模型引入了反向关系类型和自循环关系类型, 并基于语义匹配模型 DisMult 和 HoIE^[56]的思想, 提出新的聚合函数, 解决了以往针对关系的 GCN 模型中所存在的过度参数化问题。为增强图神经网络的表达能力, Nguyen 等人^[57]提出了四元数图神经网络 QGNN (Quaternion Graph Neural Networks)。该模型使用四元数对节点特征进行表示, 可以有效处理实体和关系之间复杂的非线性关系。

与其它 GNN 模型不同, QGNN 使用哈密顿积作为聚合函数, 充分考虑了不同特征之间的交互作用, 可实现对复杂关系的有效建模。

1.3 本文研究工作

APT 组织攻击偏好预测有利于揭开 APT 组织的神秘面纱, 从而制定具有针对性的主动防御措施。本文基于知识图谱, 对 APT 组织的攻击偏好预测展开研究, 并将攻击偏好预测问题转化为知识图谱中的链接预测问题, 主要包括以下工作:

(1) 以 APT 威胁情报为数据源, 采用自顶向下的方式构建面向 APT 组织攻击偏好预测的知识图谱。首先, 构建与 APT 组织攻击偏好相关且具有细粒度实体类型的任务本体: 综合网络安全领域中的公开本体库 MALOnt 和开源数据集 APTNER, 定义了 21 种实体类型和 10 种关系类型。然后, 采用半自动方法构建知识图谱 APT5K: 使用 CyBERT-BiLSTM-CRF 模型自动抽取命名实体, 并使用 doccano 标注平台人工标注实体对之间的关系, 得到 APT2K 知识图谱, 最后使用融合实体类型信息的数据增强方法, 得到 APT5K, 在一定程度上缓解了 APT2K 数据规模小且存在稀疏性的问题。

(2) 为了有效预测知识图谱 APT5K 中缺失的 APT 组织攻击偏好, 提出了一个融合外部信息 and 对比学习的链接预测模型 KLEC (Knowledge graph Link prediction model with External information and Contrastive learning)。该模型首先将知识图谱转化为包含关系节点的图, 然后使用对偶四元数图神经网络融合节点的邻域信息, 并结合网络安全领域中的 CyBERT 语言模型生成节点的语义信息, 进而使用基于三元组的对比学习来生成实体和关系的嵌入表示。

(3) 通过实验表明, 与基于 BERT 的基线模型相比, CyBERT-BiLSTM-CRF 模型能更有效地识别 APT 攻击偏好相关实体; 所提出的数据增强方法能够有效提升链接预测模型的性能; 此外, 与不使用外部信息或者对比学习的模型相比, KLEC 模型具有更好的 APT 组织攻击偏好的预测效果。

1.4 论文结构

本论文共分为 6 个章节, 论文组织如下:

第 1 章为绪论部分。首先介绍本文的研究背景及研究意义, 然后对国内外相关研究现状进行分析, 最后对本文研究内容以及论文组织结构进行概述。

第 2 章为基础知识部分。介绍了与本研究相关的基础理论知识，包括命名实体识别方法、知识图谱中的主要关系模式、知识图谱嵌入模型、图神经网络和对比学习。

第 3 章详细介绍了知识图谱 APT2K 及其增强版 APT5K 的构建过程，包括 APT2K 构建过程中的本体建立、数据获取与处理、自动化命名实体识别、人工关系标注、知识图谱存储及可视化，以及 APT5K 构建过程中融合实体类型信息的数据增强方法。

第 4 章详细介绍了融合外部信息和对比学习的链接预测模型 KLEC，包括图转换模块、语义信息模块、编码器模块 DQGNN、对比学习模块和解码器模块 QuatE。

第 5 章验证了命名实体识别模型 CyBERT-BiLSTM-CRF 的有效性，融合实体类型信息的数据增强方法的有效性，链接预测模型 KLEC 的有效性，并对 KLEC 模型中的语义信息模块和对比学习模块进行消融实验以验证必要性。

第 6 章对全文进行总结和展望。

2 基础知识

2.1 命名实体识别

知识图谱 (KG) 一般以三元组的结构化形式进行表示, 符号描述为: $G = (E, R, T)$, 其中 E 是实体集合, R 是关系集合, T 是三元组集合。对于非结构化或者半结构化数据来说, 从数据中抽取实体往往涉及命名实体识别任务。传统命名实体识别主要基于人工方式, 需要领域专家定制抽取规则并对抽取结果进行检查, 效率较为低下。随着自然语言处理 (Natural Language Processing, NLP) 的发展, 命名实体识别多采用深度学习方法, 基于标注好的语料文本对识别模型进行训练, 以实现实体的自动识别。

2.1.1 BERT 模型

BERT (Bidirectional Encoder Representation from Transformer)^[58] 是 Google 公司在 2019 年提出的预训练模型, 定义了掩码语言模型 (Masked Language Model, MLM) 和下一句预测 (Next Sentence Prediction, NSP) 两种预训练任务, 前者用来训练词的语义理解能力, 后者用来训练句子之间的理解能力, 能够更好支持下游任务。BERT 通过使用大量没有标注的维基百科语料进行预训练得到动态词向量, 即该模型能够在不同上下文中为同一个词生成不同的词向量, 很好地解决了现实中一词多义的问题。

然而, BERT 使用的是通用百科数据, 不包含领域特有数据。如果直接将其应用于特定领域的文本处理任务中, 会有很多局限性。因此, Ranade 等人^[59]提出了针对网络安全领域的预训练模型 CyBERT。该模型是基于大量网络安全文本数据、在 MLM 任务上进行微调后得到的领域 BERT。

2.1.2 序列标注

序列标注 (Sequence Labeling) 是 NLP 中最基础的任务之一, 广泛应用于分词、命名实体识别、词性标注等场景。常见的序列标注方法有 BIO、BMES、BIOES: (1) 在 BIO 标注法中, B 是实体开头, I 是实体内部或者结尾, O 是非实体; (2) 在 BMES 标注法中, B 是实体开头, M 是实体内部, E 是实体结尾, S 是单独字词, O 是非实体; (3) 在 BIOES 标注法中, B 是实体开头, I 是实体内部, O 是非实体, E 是实体结尾, S 代表单独实体。图 2-1 是对同一句子分别使用 BIO、BMES、BIOES 标注法所得到的标注结果:




图 2-1 BIO、BMES、BIOES 标注法

2.1.3 LSTM

长短期记忆网络（Long-Short Term Memory, LSTM）^[60]是循环神经网络（Recurrent Neural Network, RNN）的一种变体。在处理长序列时，RNN 容易出现梯度消失、梯度爆炸问题。为解决这一长期依赖问题，LSTM 引入了门控机制。LSTM 使用了遗忘门、输入门、输出门、记忆细胞和隐藏状态，如图 2-2 所示，其中遗忘门和输入门用于选择性输入长短期记忆。




图 2-2 长短期记忆网络 LSTM

在图 2-2 中， x_t 是 t 时刻的外部输入， C_{t-1} 和 C_t 分别代表 $t-1$ 时刻和 t 时刻的长时记忆单元，也被称作记忆细胞， $\tilde{C}_t$ 是候选记忆单元。 h_{t-1} 和 h_t 分别代表 $t-1$ 时刻和 t 时刻的短时

记忆单元，也被称作隐藏状态。 σ 是 sigmoid 激活函数，在图中分别代表遗忘门、输入门、输出门，经过这三个门处理以后得到 f_t 、 i_t 和 o_t 。相关的计算公式如式（2-1）到式（2-7）所示，其中， W 是权重矩阵， b 是偏差参数。

$$\sigma = \text{sigmoid}(x) = \frac{1}{1 + e^{-x}} \quad (2-1)$$

$$f_t = \sigma(W_f * [h_{t-1}, x_t] + b_f) \quad (2-2)$$

$$i_t = \sigma(W_i \cdot [h_{t-1}, x_t] + b_i) \quad (2-3)$$

$$\tilde{C}_t = \tanh(W_C * [h_{t-1}, x_t] + b_C) \quad (2-4)$$

$$C_t = f_t * C_{t-1} + i_t * \tilde{C}_t \quad (2-5)$$

$$o_t = \sigma(W_o * [h_{t-1}, x_t] + b_o) \quad (2-6)$$

$$h_t = o_t * \tanh(C_t) \quad (2-7)$$

然而，LSTM 无法编码从后往前的信息，即单向 LSTM 无法同时处理上下文信息。因此，Graves 等人^[61]引入了双向长短时记忆网络（Bidirectional Long-Short Term Memory，BiLSTM），BiLSTM 对文本信息的学习能力优于 LSTM。

2.1.4 CRF

Lafferty 等人^[62]提出的条件随机场（Conditional Random Field，CRF）是一种条件概率分布模型，能够通过邻近标签之间的关系获得最优的预测序列，被广泛应用于命名实体识别任务中。给定 token 长度为 n 的文本序列 $X = (x_1, x_2, \dots, x_n)$ 作为输入，CRF 模型输出对应的标签预测序列 $Y = (y_1, y_2, \dots, y_n)$ ，其置信度分数 $s(X, Y)$ 的计算如式（2-8）所示。

$$s(X, Y) = \sum_{i=0}^n A_{y_i, y_{i+1}} + \sum_{i=1}^n P_{i, y_i} \quad (2-8)$$

其中， A 代表 CRF 产生的状态转移矩阵， A_{ij} 代表标签 i 转移为标签 j 的概率。 $P \in \mathbb{R}^{n \times k}$ 是发射矩阵， n 是 token 个数， k 是标签类别数， P_{ij} 代表第 i 个 token 被预测为标签 j 的概率。如果在 BiLSTM 后接一个 CRF 模块，则 P 是 BiLSTM 输出的置信度分数矩阵。预测序列 Y 产生的概率如式（2-9）所示，其中 $\hat{Y}$ 为真实标签序列， Y_X 为所有可能的标签序列。

$$p(Y|X) = \frac{e^{s(X, Y)}}{\sum_{\hat{Y} \in Y_X} s(X, \hat{Y})} \quad (2-9)$$

对式（2-9）两边取对数得到预测序列 Y 的似然函数为：

$$\ln p(Y|X) = s(X, Y) - \ln \sum_{\hat{Y} \in Y_X} s(X, \hat{Y}) \quad (2-10)$$

由式 (2-10)，可求出置信度最高的预测序列 Y^* 如式 (2-11) 所示。

$$Y^* = \operatorname{argmax} s(X, \hat{Y}) \quad (2-11)$$

2.2 关系模式

在知识图谱 $G = (E, R, T)$ 中，实体 E 和关系 R 都是重要组成部分。实体描述了不同概念，关系则描述了不同实体之间的关联。Sun 等人^[33]总结了 KG 中的主要关系模式：对称/反对称、反转、合成等。表 2-1 给出了这些关系模式的定义，其中，实体 $x, y, z \in E$ ，关系 $r, r_1, r_2 \in R$ 。下面分别描述这些关系的含义：

表 2-1 四种关系模式定义

关系模式	定义
对称	$r(x, y) \Rightarrow r(y, x)$
反对称	$r(x, y) \Rightarrow \neg r(y, x)$
反转	$r_1(x, y) \Rightarrow r_2(y, x)$
合成	$r_1(x, y) \wedge r_2(y, z) \Rightarrow r_3(x, z)$

(1) 对称关系：如果实体 x 有一条关系 r 指向实体 y ，则实体 y 也有同一种关系 r 指向实体 x ；如：(A, isClassmateOf, B)，则 (B, isClassmateOf, A)

(2) 反对称关系：如果实体 x 有一条关系 r 指向实体 y ，则实体 y 有一条 r 的反关系指向 x 。如：(A, isTallerThan, B)，则 (B, isNotTallerThan, A)

(3) 反转关系：如果实体 x 有一条关系 r_1 指向实体 y ，则实体 y 有一条关系 r_2 指向实体 x 。如：(A, isFatherOf, B)，则 (B, isSonOf, A)

(4) 合成关系：如果实体 x 有一条关系 r_1 指向实体 y ，且实体 y 有一条关系 r_2 指向实体 z ，则实体 x 有一条关系 r_3 指向实体 z 。如：(A, isMotherOf, B)，且 (B, isFatherOf, C)，则 (A, isGrandmotherOf, C)

2.3 知识图谱嵌入模型

大多数知识图谱嵌入模型都是依据可观察到的事实三元组，将知识图谱中的实体和关系映射为低维连续空间中的嵌入表示。构建嵌入模型的关键步骤包括：定义一个评分函数

以评估每个三元组的合理性（也反映了实体和关系嵌入表示的合理性）；通过最大化可观察到三元组的总合理性来学习实体和关系的嵌入表示。

2.3.1 翻译模型

翻译模型（Translation model），也称平移模型。给定一个三元组（头实体，关系，尾实体），将关系建模为头实体到尾实体的平移变换。该类模型使用基于距离的评分函数，计算经过平移变换后的头实体与尾实体之间的距离。距离越小，说明该三元组中实体和关系的嵌入表示就越合理。

（1）TransE 模型

TransE 模型是最先提出、也是最经典的翻译模型。该模型将实体和关系投影到同一个低维向量空间 $\mathbb{R}^d$ 中（ d 是嵌入向量维度），得到实体向量 h 、 t 和关系向量 r 。把关系向量看作两个实体向量之间以低误差连接的翻译向量，即 $h + r \approx t$ 。TransE 模型的评分函数如式（2-12）所示，其中， l_1 和 l_2 分别是一范数和二范数。

$$f(h, r, t) = -\|h + r - t\|_{l_1/l_2} \quad (2-12)$$

TransE 模型在训练后可生成实体和关系嵌入。理想情况下，如果 $(h, r, t) \in S$ ， S 是事实三元组集合，则 $h + r - t = 0$ ，在二维空间中的表示如图 2-3 所示。




图 2-3 TransE 模型

（2）TransH 模型

TransE 模型只能对 1-1 的关系类型进行描述，无法适用于 1-N、N-1 和 N-N 的复杂关系，TransH 模型的提出在一定程度上解决了该问题。该模型认为即使是同一实体，在不同的关系下也应当有不同的向量表示。将实体 h 、 t 投影到关系 r 特定的超平面，头实体和尾实体在关系特定超平面上的投影 $h_{\perp}$ 和 $t_{\perp}$ 的计算公式如式（2-13）和式（2-14）所示，其中 w_r 是实体投影在超平面上的法向量。

$$h_{\perp} = h - w_r^T h w_r \quad (2-13)$$

$$t_{\perp} = t - w_r^T t w_r \quad (2-14)$$

TransH 模型把关系看作两个实体在超平面上的投影之间以低误差连接的翻译向量, 即 $h_{\perp} + r \approx t_{\perp}$ 。该模型的评分函数如式 (2-15) 所示, 其中 l_1 和 l_2 分别是一范数和二范数。

$$f(h, r, t) = -\|h_{\perp} + r - t_{\perp}\|_{l_1/l_2} \quad (2-15)$$

TransH 模型在训练后可生成实体和关系的嵌入表示。在理想情况下, 如果 $(h, r, t) \in S$, S 是事实三元组的集合, 则 $h_{\perp} + r - t_{\perp} = 0$, 如图 2-4 所示。其中, 实体投影 $h_{\perp}$ 、 $t_{\perp}$ 和关系 r 在同一超平面上可以执行向量加减。




图 2-4 TransH 模型

2.3.2 旋转模型

(1) RotatE 模型

之前的 KG 嵌入模型中, 无法同时对三种关系模式 (对称/反对称、反转、合成) 进行建模。因此, 受欧拉分解 $e^{i\theta} = \cos \theta + i \sin \theta$ 启发, Sun 等人^[33]提出了 RotatE 模型。该模型将每一个复数看作复平面上的旋转变量, 将实体和关系映射到复数向量空间中, 把关系建模为头实体到尾实体的旋转变换。对于给定的事实三元组 (h, r, t) , 经过旋转变换后的头实体如式 (2-16) 所示。

$$h' = h \circ r \quad (2-16)$$

其中, $\circ$ 为哈达玛积, $h, r, t \in \mathbb{C}^k$, $\mathbb{C}^k$ 是 k 维的复数空间, 模长 $|r| = 1$ 。RotatE 模型使用基于距离的评分函数, 其评分函数如式 (2-17) 所示。

$$f(h, r, t) = \|h \circ r - t\| \quad (2-17)$$

RotatE 模型在训练后可生成实体和关系的嵌入表示。在理想情况下, 如果 $(h, r, t) \in S$, S 是事实三元组的集合, 则 $h \circ r - t = 0$, 如图 2-5 所示, 弧线 r 代表头实体到尾实体的旋转变换。




图 2-5 RotatE 模型

(2) QuatE 模型

不同于 RotatE 模型, Zhang 等人^[21]提出的 QuatE 模型中有两个旋转平面, 具有更丰富的语义表达。QuatE 模型将复数空间扩展到 d 维超复数空间 $\mathbb{H}^d$ 中, 在四元数空间中把关系建模为头实体到尾实体的旋转, 对实体和关系使用四元数嵌入向量表示, 并使用哈密顿积替换 RotatE 模型中的哈达玛积, 解决了哈达玛积交换律所导致的建模合成关系缺陷问题。

四元数是一个简单的超复数, 如式 (2-18) 所示, 由一个实部和三个虚部单位组成, 其中 i 、 j 、 k 分别是沿 x 轴、 y 轴、 z 轴的虚部单位, $i^2 = j^2 = k^2 = ijk = -1$, 代表不同旋转的几何意义。

$$Q = a + bi + cj + dk \quad (2-18)$$

QuatE 模型中, 实体和关系属于不同的四元数空间。对关系四元数 $r = a_r + b_r i + c_r j + d_r k$ 进行规范化处理得到单位四元数 $\bar{r}$, 使用单元四元数 $\bar{r}$ 代表头实体到尾实体的旋转变换。规范化公式如式 (2-19) 所示。

$$\bar{r} = \frac{r}{|r|} = \frac{a_r + b_r i + c_r j + d_r k}{\sqrt{a_r^2 + b_r^2 + c_r^2 + d_r^2}} \quad (2-19)$$

QuatE 模型中使用基于相似性的评分函数, 计算经过旋转变换后的头实体与尾实体的相似性, 如式 (2-20) 所示。其中, $h, r, t \in \mathbb{H}^d$, $\otimes$ 代表哈密顿积。

$$f(h, r, t) = h \otimes \bar{r} \cdot t \quad (2-20)$$

对于两个四元数 $h = a_1 + b_1 i + c_1 j + d_1 k$ 和 $\bar{r} = a_2 + b_2 i + c_2 j + d_2 k$, 其四元数乘法, 即哈密顿积的计算公式如式 (2-21) 所示, 其计算结果也是一个四元数。

$$\begin{aligned}
h \otimes \bar{r} = & (a_1 a_2 - b_1 b_2 - c_1 c_2 - d_1 d_2) \\
& + (a_1 b_2 + b_1 a_2 + c_1 d_2 - d_1 c_2) i \\
& + (a_1 c_2 - b_1 d_2 + c_1 a_2 + d_1 b_2) j \\
& + (a_1 d_2 + b_1 c_2 - c_1 b_2 + d_1 a_2) k
\end{aligned} \quad (2-21)$$

对于两个四元数 $Q_1 = a_1 + b_1 i + c_1 j + d_1 k$ 和 $Q_2 = a_2 + b_2 i + c_2 j + d_2 k$ ，其内积计算公式如式（2-22）所示：

$$Q_1 \cdot Q_2 = \langle a_1, a_2 \rangle + \langle b_1, b_2 \rangle + \langle c_1, c_2 \rangle + \langle d_1, d_2 \rangle \quad (2-22)$$

2.3.3 DualE 模型

绝大多数知识图谱嵌入技术只将关系建模成头实体到尾实体的平移变换或旋转变换其中一种，例如翻译模型中的平移变换、旋转模型中的旋转变换。这种单一的变换限制了模型对关系的描述能力。为解决该问题，Cao 等人提出了 DualE^[36]模型。该模型使用对偶四元数，把嵌入空间扩展到超复数空间，可以将 KG 中的关系建模为平移和旋转的组合操作，从而增强模型的表达能力。平移和旋转变换对于各种关系模式的建模能力如表 2-2 所示，其中多重关系是指在一个 KG 中，同一实体对之间同时存在多个关系。

表 2-2 平移和旋转变换对各种关系模式的建模能力

关系模式	平移	旋转	平移+旋转
对称	✗	✓	✓
反对称	✓	✓	✓
反转	✓	✓	✓
合成	✓	✓	✓
多重关系	✓	✗	✓

以下介绍对偶数和对偶四元数的概念：

（1）对偶数 z_d 的定义如式（2-23）所示， a 是 z_d 的实数部分， a_ϵ 是 z_d 的对偶部分。其中， ϵ 是一个对偶单位，且 $\epsilon^2 = 0$ 。

$$z_d = a + \epsilon a_\epsilon \quad (2-23)$$

（2）对偶四元数本质上是一个复杂的四元数 Q ，其实部 a 和对偶部 b 都是一个四元数，如式（2-24）所示。

$$Q = a + \epsilon b \quad (2-24)$$

其中， ϵ 是一个对偶单位，且 $\epsilon^2 = 0$ 。实部 $a = a_0 + a_1 i + a_2 j + a_3 k$ ，对偶部 $b = b_0 + b_1 i + b_2 j + b_3 k$ 。 a_0 和 b_0 分别是四元数 a 和 b 的实部， i 、 j 、 k 分别是沿 x 轴、 y 轴、 z 轴的虚部

单位, $i^2 = j^2 = k^2 = ijk = -1$, 代表不同旋转的几何意义。实际上, 对偶四元数 Q 可看作一个具有 8 个元素的元组:

$$Q = (a_0, a_1, a_2, a_3, b_0, b_1, b_2, b_3) \quad (2-25)$$

在 DualE 模型中, KG 的实体和关系属于不同的对偶四元数空间。该模型通过施密特正交法对关系对偶四元数 W_r 进行规范化处理, 得到单位对偶四元数 $\bar{W}_r$ 。使用单位对偶四元数代表头实体到尾实体的平移和旋转变换, 可将实体和关系统一到同一个对偶四元数空间中, 其方法如下: 将规范化处理前的关系对偶四元数定义为 $W_r = (c, d)$, 其中实部 $c = (c_0, c_1, c_2, c_3)$, 对偶部 $d = (d_0, d_1, d_2, d_3)$, 则规范化后的关系对偶四元数为 $\bar{W}_r = (c', \bar{d})$ 。其中, 实部 c' 和对偶部 $\bar{d}$ 的计算公式分别如式 (2-26) 和式 (2-27) 所示。

$$c' = \frac{c}{\|c\|} = \frac{c_0 + c_1 i + c_2 j + c_3 k}{\sqrt{c_0^2 + c_1^2 + c_2^2 + c_3^2}} \quad (2-26)$$

$$\bar{d} = d - \frac{(d, c)}{(c, c)} c = (\bar{d}_0, \bar{d}_1, \bar{d}_2, \bar{d}_3) \quad (2-27)$$

DualE 模型中使用基于相似性的评分函数, 计算经过平移和旋转变换后的头实体与尾实体的相似性, 如式 (2-28) 所示。

$$f(h, r, t) = h \otimes_d \bar{r} \cdot t \quad (2-28)$$

其中, $\otimes_d$ 代表对偶四元数乘法。对于两个对偶四元数 $h_1 = q_1 + \epsilon p_1$ 和 $h_2 = q_2 + \epsilon p_2$, 对偶四元数乘法的计算公式如式 (2-29) 所示, $\otimes$ 代表四元数乘法。

$$h_1 \otimes_d h_2 = (q_1 \otimes q_2) + \epsilon(q_1 \otimes p_2 + p_1 \otimes q_2) \quad (2-29)$$

假设头实体向量 h 和规范化后的关系向量 $\bar{r}$ 的执行对偶四元数乘法, 得到 $Q'_h = (a'_h, b'_h, c'_h, d'_h)$, 则 Q'_h 和关系对偶四元数 $Q_t = (a_t, b_t, c_t, d_t)$ 内积的计算公式如式 (2-30) 所示。

$$\langle Q'_h, Q_t \rangle = \langle a'_h, a_t \rangle + \langle b'_h, b_t \rangle + \langle c'_h, c_t \rangle + \langle d'_h, d_t \rangle \quad (2-30)$$

训练后的 DualE 模型生成实体和关系的嵌入表示, 在三维空间中如图 2-6 所示。其中, h 、 t 分别是头尾实体的嵌入, 蓝色弧线 r 和蓝色直线 $r+$ 分别是规范化后的关系嵌入对头实体做的旋转变换和平移变换。图例先将头实体旋转变换为 $h-$, 再经过平移变换为 $h+$, 然后计算经过旋转、平移变换后的头实体 $h+$ 与尾实体的相似性。




图 2-6 DualE 模型示意图

2.4 图神经网络

2.4.1 图结构数据

近年来，深度学习快速发展，传统的深度学习模型如卷积神经网络 CNN 和循环神经网络 RNN 在各个领域都得到了广泛应用，如：使用 CNN 对二维结构的图像进行平移卷积以提取图像特征；使用 RNN 获取一维结构的文本序列特征等。对于图像和文本这类欧几里得数据，传统的深度学习方法能够有效抽取其特征，但在非欧几里得数据（如图结构数据）上表现不佳^[63]。然而，图结构数据在现实生活中广泛存在，如通信网络、社交网络、推荐系统等。图结构数据是由节点和边组成的网络结构，每个节点可能有不同数量的邻接节点，其数据结构并不规则且每个节点与邻居节点之间存在复杂的依赖关系，因此传统的深度学习方法并不适用于非欧几里得数据。图 2-7 中展示了欧氏空间中由像素点组成的图像数据和非欧氏空间中图结构数据的不同：




图 2-7 欧氏空间中的图像数据和非欧氏空间中的图结构数据

鉴于传统深度学习方法无法有效处理图结构数据，人们引入了图神经网络（Graph Neural Network, GNN）用于处理这种非欧几里得数据。该方法基于深度学习且能够在图域上运行，已经成为一种广泛应用的图分析方法，可以用于节点、边和图级别任务，如节点分类、链接预测和图分类等。

2.4.2 图卷积网络

给定一个图 $G = (V, E)$ ，其中 V 代表节点， E 代表边。一般用邻接矩阵（Adjacency Matrix） $A \in \mathbb{R}^{N \times N}$ 来表示图的结构， D 为度矩阵（Degree Matrix），节点特征矩阵 $X \in \mathbb{R}^{N \times K}$ 来表示图中每个节点的属性，其中 N 为节点数量， K 为节点的特征向量维度。图卷积网络是最常用的图神经网络之一，将卷积运算从欧氏空间中的图像数据推广到非欧式空间中的图结构数据，通过图卷积将邻居节点的信息进行聚合从而更新节点的特征表示。根据卷积的方式不同，图卷积网络主要可以分为两种：基于谱域（Spectral-based）的图卷积网络和基于空域（Spatial-based）的图卷积网络。

（1）基于谱域的图卷积网络

基于谱域的图卷积网络 GCN^[52]建立在谱图理论的基础上，将图卷积定义为图结构数据上的傅里叶变换，从图信号处理的角度把图卷积看作低通滤波器，可以从图信号中去除噪声。传统傅里叶变换中的基函数使用了拉普拉斯算子，离散的拉普拉斯算子即拉普拉斯矩阵的计算如式（2-31）所示，其中 L 代表拉普拉斯矩阵， D 是度矩阵，也是对角矩阵， A 是邻接矩阵。

$$L = D - A \quad (2-31)$$

对拉普拉斯矩阵进行对称归一化处理，如式（2-32）所示。

$$L_{\text{sys}} = D^{-\frac{1}{2}} L D^{-\frac{1}{2}} = I - D^{-\frac{1}{2}} A D^{-\frac{1}{2}} \quad (2-32)$$

经典 GCN 中使用邻接矩阵 A 和节点特征矩阵 X 作为模型输入，模型输出为 $Z \in \mathbb{R}^{N \times F}$ ，其中 F 是输出的节点特征维度。GCN 可以由多个图卷积层组成，通过聚合邻居节点信息更新特征矩阵，图卷积层之间的特征传播如式（2-33）所示：

$$H^{(l+1)} = \sigma \left(\tilde{D}^{-\frac{1}{2}} \tilde{A} \tilde{D}^{-\frac{1}{2}} H^{(l)} W^{(l)} \right) \quad (2-33)$$

其中， $\tilde{A} = A + I$ ， A 是邻接矩阵， I 是单位矩阵，添加了节点自连接； $\tilde{D}$ 是 $\tilde{A}$ 的度矩阵， $H^{(l)}$ 是第 l 层的特征矩阵， $H^{(0)}$ 是 GCN 模型的输入特征 X ， $W^{(l)}$ 是第 l 层中的可训练权重矩阵， σ 是非线性激活函数。

（2）基于空域的图卷积网络

基于空域的图卷积网络使用了邻居节点采样方法，在图中一部分节点上做卷积运算，而不需要对整张图的所有节点进行卷积，在大型图上能够有效提升效率，经典模型如 GraphSAGE^[64]等。GraphSAGE 模型的训练分为两步：第一步是对邻居节点进行采样，第二步是对邻居节点进行聚合，更新节点的特征表示，其示意图如图 2-8 所示。




图 2-8 GraphSAGE 采样（左）和聚合（右）示意图

其中，左图展示了对中心节点 v 进行邻居节点采样的过程，红色节点代表中心节点以及采样到的多跳邻居节点；右图展示了对中心节点 v 的邻居节点进行聚合的过程，绿色和蓝色箭头分别代表对两跳邻居节点和一跳邻居节点使用不同的聚合方法。常见的聚合方法为平均聚合、LSTM 聚合和池化聚合等。节点 v 的特征更新如式 (2-34) 和式 (2-35) 所示，其中 k 代表采样跳数， $N(v)$ 代表节点 v 的邻居采样节点， $AGGREGATE_k$ 代表第 k 跳的聚合方法， W^k 是第 k 跳的权重， σ 是非线性激活函数。

$$h_{N(v)}^k \leftarrow AGGREGATE_k(\{h_u^{k-1}, \forall u \in N(v)\}) \quad (2-34)$$

$$h_v^k \leftarrow \sigma(W^k \cdot CONCAT(h_v^{k-1}, h_{N(v)}^k)) \quad (2-35)$$

2.5 对比学习

自监督学习（Self-supervised Learning）是近年来的研究热点之一，通过利用数据本身的信息，从一组无标签的数据样本中创建伪标签作为训练目标让模型自己学习有用的特征表示，从而避免对数据集进行大量标注。对比学习（Contrastive Learning）^[65]作为计算机视觉、自然语言处理以及其他领域中重要的自监督学习方法，基于创建的伪标签拉近相同类别样本、拉远不同类别样本之间的距离来训练模型的学习能力。对比学习中使用了代理任

务与下游任务相结合的自监督学习框架，在代理任务中以某一样本为锚点，选择与之相似的样本作为正样本，与之不相似的样本作为负样本，选择合适的代理任务对于下游任务中学习样本的特征表示至关重要。

SimCLR 是对比学习在计算机视觉领域中的成功应用之一，其主要思想是：对图片 x 进行数据增强，通过两次随机变换 t 和 t' 后得到样本 $\tilde{x}_i$ 和 $\tilde{x}_j$ ，将 $\tilde{x}_i$ 和 $\tilde{x}_j$ 分别送入编码器网络 $f(\cdot)$ 和投影头 $g(\cdot)$ 进行训练，得到两个样本的特征表示 z_i 和 z_j 。使用对比损失计算两个样本特征之间的距离，训练模型提取视觉特征的能力。SimCLR 把 $\tilde{x}_i$ 作为锚点， $\tilde{x}_j$ 作为正样本， z_i 和 z_j 分别代表锚点表征和正样本表征，使用的对比损失为 NT-Xent (the Normalized Temperature-scaled cross entropy loss)，如式 (2-36) 所示。

$$L_c = -\log \frac{\exp\left(\frac{\text{sim}(z_i, z_j)}{t}\right)}{\sum_{k=1}^{2N} \text{sgx}(k \neq i) \exp\left(\frac{\text{sim}(z_i, z_k)}{t}\right)} \quad (2-36)$$

其中， N 为一个批次的样本数量，经过数据增强后样本数量变为 $2N$ ， t 为温度超参数； $\text{sgx}(\cdot)$ 为指示函数，如式 (2-37) 所示。对于每一个锚点表征 z_i ，除了 z_j 是正样本表征之外，剩下的 $2N-1$ 个 z_k 是负样本表征。

$$\text{sgx}(x) = \begin{cases} 1, & x \text{ 为真} \\ 0, & x \text{ 为假} \end{cases} \quad (2-37)$$

3 面向 APT 组织攻击偏好预测的知识图谱构建

本节将面向 APT 组织攻击偏好预测任务，以半自动化方式构建适合该任务的知识图谱 APT2K，包括建立具有细粒度实体类型的本体、命名实体识别、人工标注关系等。本节还将针对该图谱数据规模小且稀疏的问题，构建其增强版 APT5K。

3.1 知识图谱 APT5K 构建的总体流程

本章以半自动化的方式，从非结构化数据（APT 威胁情报）中抽取知识。结合了深度学习方法和专家知识，在提高知识抽取效率的同时保证所抽取知识的质量。本文构建面向 APT 攻击偏好网络预测的知识图谱 APT5K 的步骤如图 3-1 所示：




图 3-1 知识图谱 APT5K 的构建流程

（1）本体建立：根据 APT 组织攻击偏好预测的实际需求构建任务本体，共定义 21 种细粒度实体类型和 10 种关系类型。

（2）数据的获取与处理：搜集近五年来 138 篇 PDF 格式的 APT 威胁情报，对其进行文本格式的转换并进行清洗处理，得到 128 篇 TXT 格式的非结构化 APT 威胁情报文本。

（3）自动化命名实体识别：使用数据集 APTNER 对命名实体识别模型 CyBERT-BiLSTM-CRF 进行训练；将训练好的识别模型封装成 API 接口，用于自动识别 128 篇 TXT 文本中的实体。

（4）人工关系标注：在第（3）步的基础上，手工标注实体对之间的关系，再对标注文件进行导出处理，从而抽取出知识三元组，得到知识图谱 APT2K。

（5）数据增强：使用融合实体类型信息的方法对 APT2K 进行数据增强，得到 APT5K。

（6）知识图谱存储及可视化：使用图数据库 Neo4j 对构建的 APT5K 知识图谱进行存储并实现可视化。

3.2 知识图谱 APT5K 构建的子过程

3.2.1 本体建立

本文在领域公开本体库 MALOnt 和网络安全领域开源数据集 APTNER^[66]的基础上，结合 APT 组织攻击偏好预测任务，确定了 21 种实体类型和 10 种关系类型。其中，21 种

实体类型的名称、相关描述和对应例子如表 3-1 所示，相较于其他研究^[24]，本文所构建知识图谱的实体类型更为细粒度、丰富，表中加粗部分为本文新增的实体类型。由于不同情景下可能使用不同哈希值类型，因此本文对哈希值类型进行了细分，增加所构建知识图谱的适用性。10 种关系类型及其含义如表 3-2 所示。

表 3-1 实体类型、相关描述及对应例子

实体类型	实体描述	例子
APT	APT 攻击组织	APT32, OceanLotus
CAMPAIGN	APT 战役名称	Ukraine Power Outage
SECTEAM	安全团队	FireEye
OS	操作系统	Windows, Linux
URL	统一资源定义	http://shwoo.gov.taipei/buyer.asp
PROT	网络协议	HTTP
DOM	域名	globalowa.com
EMAIL	邮件地址	uglygorilla@163.com
IP	IP 地址	109.248.148.42
LOC	国家或地区	Russia
FIELD	行业领域	Telecommunications, Healthcare
TIME	时间	April 2018
FILE	文件	at.exe
MD5	哈希值	11a9f798227be8a53b06d7e8943f8d68
SHA1	哈希值	906dc86cb466c1a22cf847dda27a434d04adf065
SHA2	哈希值	4741c2884d1ca3a40dadd3f3f61cb95a59b11f99a0f980dbadc663b85eb77a2a
VULNAME	漏洞名称	Zero-day, ProxyLogon
VULID	漏洞 ID	CVE-2016-4117
ACT	攻击方式	Spear fishing
MAL	恶意软件	Cobalt Strike
TOOL	良性工具	PowerShell

3-2 关系类型及其含义

关系类型	含义
hasAlias	APT 组织的别名
belongTo	APT 组织属于哪个国家或地区
target	APT 组织的攻击目标，如国家、行业领域等
hasAttackTime	APT 攻击发起的时间
evolveTo	恶意软件的演变
exploit	APT 攻击中利用了哪些攻击方式、恶意软件、漏洞等
use	APT 攻击中使用了哪些良性工具
foundBy	APT 组织被哪个安全团队发现
indicate	攻击指标对应了哪个 APT 组织，如恶意域名
has	漏洞名称对应的漏洞 ID 是什么

3.2.2 数据获取与处理

APTnotes^[67]是 Github 网站上的一个公开存储库，维护了 CSV 和 JSON 两种格式的文件。文件中记录了 2008 年至今与 APT 组织相关的公开威胁情报和网络安全博客的 PDF 文件下载链接及相关年份。这些文件依赖于 BOX 云存储库，并在另一个存储库^[68]中提供了用于批量下载脚本。

本文进行数据获取与处理的流程如图 3-2 所示：首先批量下载 APTnotes 上近五年（2018-2022）的 138 篇 PDF 文件，然后使用 Python 第三方库 PDFPlumber 将这些 PDF 文件的格式转换成 TXT 格式；由于 PDFPlumber 对两栏分布的 PDF 文件转换效果不佳，因此本节进行文件格式转换之后剔除双栏 PDF 文件对应的文本文件，最后得到 128 篇文本文件作为本文图谱的初始数据。



图 3-2 数据获取与处理流程图

3.2.3 自动化命名实体识别

为了自动化地识别出与 APT 组织攻击偏好相关的 21 种命名实体，本文建立一个命名实体识别模型 CyBERT-BiLSTM-CRF。该模型使用编码器-解码器架构，如图 3-3 所示：以网络安全领域预训练模型 CyBERT 作为编码器、以双向长短时记忆网络 BiLSTM 模块作为序列建模器、以条件随机场 CRF 模块作为解码器。




图 3-3 CyBERT-BiLSTM-CRF 模型

以下分别详述该模型的两个模块：

(1) **CyBERT 语言模型模块：**用于对输入文本序列进行编码，学习该序列中单词的向量表示。CyBERT 是一种针对网络安全领域的预训练模型，是基于 MLM 任务和大量网络安全文本对 BERT 进行微调得到的语言模型。在 MLM 任务中，选取句子中 15% 的单词，被选取的单词中 80% 使用 [MASK] 标记替代，10% 使用随机单词替代，10% 使用原始单词，然后训练模型预测句子中 [MASK] 位置的单词。相较于基于维基百科语料训练的通用语言模型 BERT，CyBERT 可以更好学习到网络安全文本的语义表示。

(2) **BiLSTM 序列建模器模块：**对经过 CyBERT 编码的文本序列进行更深层次的特征提取和建模。LSTM 在处理长距离文本信息上有明显优势，但是一个 LSTM 无法同时处理上下文信息。本节使用双向长短时记忆网络 (BiLSTM)，包含两个 LSTM：前向 LSTM

和后向 LSTM，分别处理前向序列和后向序列。通过合并两个 LSTM 在同一时刻对同一个词的输出，使得 BiLSTM 模块的输出同时包含前向和后向信息。

(3) CRF 解码器模块：用于对 BiLSTM 层的输出进行解码。BiLSTM 无法处理标签之间的依赖关系，而 CRF 能够学习邻近标签之间的依赖关系（即标签约束），从而获得一个最优的标签预测序列。

本文使用 APTNER 数据集^[66]来训练 CyBERT-BiLSTM-CRF 模型，以用于自动抽取（识别）命名实体。APTNER 数据集是基于 STIX 2.1 标准构建的开源命名实体识别数据集，是网络安全领域中实体类型最完善的数据集，其实体类型与本文所定义的大部分实体类型相同。该数据集是其建立者使用 Brat 标注工具和 BIOES 标注法对搜集到的网络威胁情报进行手工标注而得到的，总共包括 10984 个句子、260134 个 Tokens 和 39565 个实体。因为 CyBERT 预训练模型是在大量网络安全文本语料的基础上进行微调而得的，因此基于 CyBERT 的 CyBERT-BiLSTM-CRF 模型能为 APTNER 数据学到高质量的向量表示。本文的实验结果表明（详见第 5.2 节），与基于 BERT 的基线命名实体识别模型相比，CyBERT-BiLSTM-CRF 模型能更好地识别 APT 威胁情报中的相关实体。

3.2.4 人工关系标注

本节选用了轻量开源数据标注平台 doccano（document annotation）作为标注工具^[69]，该标注工具采用了前后端分离架构，使用 Python 语言和 Django 框架进行后端开发，前端则使用了 Vue 框架，可以通过在浏览器中输入地址进行访问，对于小型语料库标注任务来说非常便捷。该平台包含了文本分类、序列标注、图片分类、目标检测等标注任务，本文使用了其中的序列标注功能，用来标注实体对之间的关系，即标注出语料文本中的事实三元组。本文使用 doccano 标注工具半自动化构建网络安全知识图谱的步骤如下：

(1) 项目配置：新建一个项目，按照第 3.2 节中定义的实体和关系类型进行标签设置，并导入第 3.2.2 节所得到的 TXT 文件。

(2) 自动标注实体：首先使用 Flask 框架将训练好的 CyBERT-BiLSTM-CRF 模型封装成 API 接口，其接口字段及含义如表 3-3 所示；然后配置 API 接口字段并调用 doccano 工具的自动标注功能，即可对 TXT 文本中的实体进行自动标注。

(3) 人工标注和审核：对第（2）步中自动标注的实体进行人工审核，并在该基础上手工标注实体对之间关系，再进行审核。

(4) 导出标注文件并提取三元组：首先导出标注后的文本为一个 JSON 文件；然后从该文件中提取全部的知识三元组，每个三元组形如（头实体，关系，尾实体）；最后将这些三元组保存为一个文本文件，即知识图谱数据集文件 APT2K。所得的 APT2K 数据集共有 1582（约 2K）个三元组，其中实体数量为 1455，关系数量为 1961，实体类型和关系类型的数量分布分别如表 3-4 和表 3-5 所示。

表 3-3 实体自动标注接口字段

接口字段	含义
label	实体标签
start_offset	实体在第几个字符开始
end_offset	实体在第几个字符结束

表 3-4 APT2K 的实体类型分布

实体类型	数量	实体类型	数量	实体类型	数量
MAL	308	TOOL	175	FIELD	165
APT	154	ACT	102	LOC	99
FILE	89	TIME	79	MD5	49
SHA2	48	SECTEAM	41	VULID	36
DOM	26	VULNAME	21	OS	17
IP	13	SHA1	13	URL	10
CAMPAIGN	6	PROT	3	EMAIL	1

表 3-5 APT2K 的关系类型分布

关系类型	数量	关系类型	数量
exploit	462	target	423
use	259	indicate	240
hasAttackTime	159	hasAlias	133
has	129	foundBy	105
belongTo	42	evolveTo	9

3.2.5 数据增强

本章用半自动化方式所构建的知识图谱 APT2K 包括约 2 千个三元组，数据规模较小且存在稀疏性问题。为了缓解以上问题，本节引入融合实体类型信息的数据增强方法：将 21 种实体类型也作为节点，增加名为 `hasType` 的关系类型。该方法将每个实体与对应的实体类型节点相连接，即增加形如（实体，`hasType`，实体类型）的三元组，如图 3-4 所示：




图 3-4 融合实体类型信息的数据增强方法




图 3-5 增强同一类型实体之间的联系

本文通过以上的数据增强方法增大了知识图谱的数据规模（即三元组数量），并将增强后的知识图谱命名为 APT5K。APT5K 共包含 4746（约 5K）个三元组，其中实体数量为 1476，关系数量为 3416。与 APT2K 相比，APT5K 增强了具有相同实体类型的不同实例节点之间的联系。例如在图 3-5 中，绿色节点代表一个实体类型节点（即“攻击模式”类型），

紫色节点表示具有该实体类型的一组实例节点（即具有“攻击模式”类型一组实例节点，例如“鱼叉攻击”实例、“DDos 攻击”实例等），显然这些紫色实例节点通过共同的绿色类型节点加强了联系，缓解了图谱的稀疏性。可见，此数据增强方法还缓解了图谱的稀疏性问题。

相较于通用知识图谱，领域知识图谱的构建对技术人员提出了更高的专业知识要求，领域知识图谱也往往存在规模较小的问题。此外，稀疏性问题也普遍存在于知识图谱中，因此本节提出的数据增强方法在领域知识图谱中具有普遍适用性。

3.2.6 知识图谱的存储及可视化

知识图谱的存储方式有两种，一种是基于资源描述框架（Resource Description Framework, RDF）的存储，提供了统一的标准进行描述，即形如（头实体，关系，尾实体）的三元组形式，非常简单清晰。另一种则是基于图数据库的存储，将实体作为节点、关系作为边，以图结构存储知识图谱，能够对图进行高效查询和搜索。如果将其存储在传统的关系型数据库中，则查询计算效率很低。




图 3-6 图谱 APT2K 可视化




图 3-7 图谱 APT5K 可视化

Neo4j 是目前主流的图数据库之一。本文首先在本地安装 Neo4j 图数据库，配置环境变量；然后使用 Python 第三方库 py2neo，将 APT2K 数据集保存在 TXT 文件中的三元组导入到该数据库中；最后，在浏览器中输入 URL（Uniform Resource Locator）对本地数据库进行访问，即可按照实体或关系类型进行查询。知识图谱 APT2K、APT5K 在图数据库 Neo4j 中的部分可视化结果分别如图 3-6、图 3-7 所示。图中不同颜色的节点代表不同实体类型的实例，例如黄色节点为 APT 组织，绿色节点为国家或地区，蓝色节点为恶意软件，紫色节点为攻击模式，粉色节点为系统平台，红色节点为行业领域等。

3.3 本章小结

本章以 APT 威胁情报作为数据源，针对 APT 组织攻击偏好预测任务，以半自动化的方式构建了知识图谱 APT5K，包括建立与 APT 组织攻击偏好相关的本体，搜集 APT 威胁情报并进行处理，构建 CyBERT-BiLSTM-CRF 模型实现自动化命名实体识别，利用开源数据标注平台实现人工的关系标注，进而使用了融合实体类型信息的数据增强方法，建立了包含约 5 千个三元组的知识图谱 APT5K。

4 融合外部信息和对比学习的链接预测模型 KLEC

4.1 问题描述

APT 攻击偏好预测是指给定一个 APT 组织, 预测其目标攻击国家或地区、目标攻击行业领域、使用的攻击方式、恶意软件、漏洞以及工具。如果将其转化为传统的分类问题, 一般假设 APT 组织在每个攻击偏好维度上都是互斥的 (如一个 APT 组织的目标攻击国家或地区只能是一种), 显然这并不完全符合实际情况。因此, 本文将 APT 组织攻击偏好预测问题转化为知识图谱中的链接预测问题, 从而符合 APT 组织可能倾向于攻击多个国家或地区、攻击多个行业领域、采用多种攻击方式等情况。

链接预测任务可以分为实体预测 (头实体或者尾实体) 和关系预测两类子问题。本文将 APT 攻击偏好预测问题转化为尾实体预测问题, 即给定头实体 (APT 组织) 和关系 (target、exploit、use), 预测缺失尾实体 (国家或地区、行业领域、攻击方式、恶意软件、漏洞、工具)。本文将构建用于 APT 组织攻击偏好预测的深度学习模型, 其关键在于学习实体和关系的嵌入表示。

4.2 KLEC 模型的总体框架

传统的链接预测模型通常只关注独立的事实三元组, 而忽略了信息量更大的外部信息, 这使得链接预测的性能具有局限性。为克服此局限性, 本文受 Nguyen 和 Luo 等人研究^[70,71]的启发, 提出了一个融合外部信息和对比学习的链接预测模型 KLEC (Knowledge graph Link prediction model with External information and Contrastive learning), 模型框架如图 4-1 所示。

该模型使用了“编码器-解码器”架构, 首先使用图转换模块, 将知识图谱中的实体和关系都作为图中节点, 节点之间根据共现关系进行边的连接, 计算得到新的邻接矩阵。然后借助 CyBERT 语言模型生成节点的语义特征表示, 其节点特征矩阵和邻接矩阵被一同送入编码器 DQGNN 中进行实体关系嵌入表示的学习, 从而融合了节点的邻域信息。接下来根据学习到的节点嵌入表示和基于三元组构造的正负样本对计算对比损失, 同时将实体和关系的嵌入表示送入解码器 QuatE 中, 使用评分函数对预测三元组进行评估得到置信度分数。最后计算二分类交叉熵损失 (Binary Cross Entropy, BCE), 以衡量预测三元组和真实三元组的距离。因此, KLEC 模型的损失函数包括对比损失和二分类交叉熵损失两部分, 最终损失函数如式 (4-1) 所示。

$$L(h, r, t) = L_c(h, r, t) + L_T(h, r, t) \quad (4-1)$$




图 4-1 KLEC 模型框架

4.3 KLEC 模型的子模块

4.3.1 图转换模块

原始 GNN 不能对边的特征进行有效建模，而知识图谱中学习关系的嵌入表示对于三元组的构成至关重要。因此，本文受 Nguyen 和白等人^[70,72]启发，对原来的知识图谱进行图转换，将实体之间的关系也作为图中节点，得到一个包含实体节点和关系节点两类节点的图。本文使用图转换模块，可更好地学习关系的嵌入表示，且可显式地表示实体对之间的多种关系。

此外，不同邻居节点所提供信息的重要性各不相同。本文通过计算两个节点之间共同出现的频率来计算其关联边的权重，并基于不同的边权重来选择性融合邻域信息，从而得到融合后的节点嵌入。本文图转换模块所生成的图对应一个带权邻接矩阵 $\tilde{A}$ ，其矩阵元素的定义如式 (4-2) 所示：

$$\tilde{A}_{ij} = \begin{cases} \frac{p(i,j)}{p(i)}, & i \text{ 和 } j \text{ 都是实体节点且 } p(i,j) > 0 \\ p(i,j), & i \text{ 和 } j \text{ 节点有任一为关系节点且 } p(i,j) > 0 \\ 1, & i \text{ 和 } j \text{ 是同一节点或者具有 hasAlias 关系} \\ 0, & \text{其他} \end{cases} \quad (4-2)$$

其中， $p(i,j)$ 和 $p(i)$ 的定义分别如式 (4-3) 和式 (4-4) 所示，其中， $\#(C)$ 为所有的三元组个数， $\#C(i,j)$ 为节点 i 、 j 共现的三元组个数。

$$p(i, j) = \frac{\#C(i, j)}{\#(C)} \quad (4-3)$$

$$p(i) = \frac{\#C(i)}{\#(C)} \quad (4-4)$$

4.3.2 语义信息模块

本文生成图谱中实体和关系节点的特征表示的过程如图 4-2 所示：



图 4-2 获取实体关系节点特征表示

在使用 CVE 等数据库所构建的网络安全知识图谱中，实体往往包含了简洁但语义丰富的描述信息。然而，本文所构建的知识图谱使用的是从 APT 威胁情报文本中抽取的三元组，其实体和关系只有名称而缺乏其它的文本描述信息。因此，本章使用 CyBERT 来生成图谱中实体和关系的语义表示，从而间接利用了 CyBERT 在预训练时所使用的大量网络安全全文本描述信息。

CyBERT 模型输出的节点特征向量固定为 768 维。然而，知识图谱的节点特征向量通常是低维且可学的。因此，本节使用主成分分析法（Principal Component Analysis, PCA）对 CyBERT 的输出向量进行降维处理；其降维后的维度取决于实验中的超参数输入，可能取值为 50、100、200、400 等。

本文对 CyBERT 的输出向量进行 PCA 降维：将一组相关的变量通过线性变换之后转化为另一组不相关的变量，并将这组新的不相关变量按照方差递减的顺序进行排序，方差越大代表该变量所包含的信息越丰富。对于语义表示矩阵 $X \in \mathbb{R}^{m \times n}$ ， m 代表节点数量， n 代表指标数量，这里 n 为 768 维，元素 x_{ij} 代表第 i 个评价对象在第 j 个指标的取值。本文所采用的 PCA 降维步骤如下：

（1）将特征矩阵 X 中每个指标值按列进行标准化，如式（4-5）所示。

$$\tilde{x}_{ij} = \frac{x_{ij} - \bar{x}_j}{s_j} \quad (4-5)$$

其中， $i = \{1, 2, \dots, m\}$ ， $j = \{1, 2, \dots, n\}$ ， $\bar{x}_j$ 和 s_j 分别代表第 j 个指标的样本均值和样本标准差，计算如式（4-6）和式（4-7）所示。

$$\bar{x}_j = \frac{1}{m} \sum_{i=1}^m x_{ij} \quad (4-6)$$

$$s_j = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_{ij} - \bar{x}_j)^2} \quad (4-7)$$

(2) 得到标准化后的特征矩阵 $\tilde{X}$ ，计算协方差矩阵 C 。

$$C = \frac{1}{m} \tilde{X}^T * \tilde{X} \quad (4-8)$$

(3) 计算协方差矩阵的特征值和对应的特征向量，式(4-9)中， λ 是特征值向量， V 是对应的特征向量矩阵。一般使用奇异值分解进行计算，这里不展开叙述。

$$C * V = \lambda * V \quad (4-9)$$

(4) 根据特征值从大到小的顺序将对应的特征向量按列组合成矩阵 $U \in \mathbb{R}^{n \times n}$ ，如果把样本降到 k 维，则选择矩阵 U 的前 k 列，得到降维矩阵 $U_k \in \mathbb{R}^{n \times k}$ ，再利用该矩阵将样本映射到低维空间 $\mathbb{R}^{m \times k}$ 上，如式(4-10)所示。

$$Z = X * U_k \quad (4-10)$$

4.3.3 编码器模块

KLEC 模型中使用对偶四元数图神经网络 (Dual Quaternion Graph Neural Network, DQGNN) 作为编码器，根据图转换模块输入的邻接矩阵和语义信息模块输入的特征矩阵，对图中的实体节点和关系节点进行编码，**学习节点的嵌入表示**，融合节点的邻域信息。DQGNN 模型可以看作是 GNN 在对偶四元数这一超复数空间的推广，将图中每个节点的特征表示当成对偶四元数向量。DQGNN 层之间的邻域信息聚合函数如式(4-11)所示。

$$h_v^{(l+1),DQ} = g \left(\sum_{u \in N_v \cup \{v\}} a_{v,u} W^{(l),DQ} \otimes_d h_u^{(l),DQ} \right) \quad (4-11)$$

其中， N_v 是节点 v 的邻居节点集合， $a_{v,u}$ 是节点 v 和节点 u 之间边的权重，可以从式(4-8)的 $\tilde{A}_{ij}$ 矩阵中得到， $W^{(l),DQ}$ 是对偶四元数空间中第 l 层的可训练权重矩阵， $\otimes_d$ 是对偶四元数乘法， $h_u^{(l),DQ}$ 是对偶四元数空间中第 l 层中节点 u 的特征表示， g 是非线性激活函数。

4.3.4 对比学习模块

受 Luo 等人启发^[71]，本文在学习实体关系嵌入表示时引入对比学习。本文基于三元组间共享的实体或共享的实体-关系来构造正例对，如图 4-3 到图 4-6 所示，共包含四种类型的正例对。这种对比学习通过对比损失来增强三元组之间的相关实体和相关实体-关系的关联，有利于学习图谱中实体和关系的嵌入表示。




图 4-3 共享关系和尾实体的头实体正例对




图 4-4 共享头实体和关系的尾实体正例对




图 4-5 共享头实体的关系-尾实体正例对




图 4-6 共享尾实体的头实体-关系正例对

本文所使用的对比损失函数如式 (4-12) 所示, 对于图 4-3 至图 4-6 中的四种情况分别计算其对比损失并加权求和, 其中 a_h 、 a_t 、 a_{tr} 、 a_{hr} 均为超参数, 每种情况的对比损失计算公式如式 (4-13) 所示。其中样本表征 z_i 和对应的正负例样本表征 z_i^+ 、 z_i^- 均使用最后一个 DQGNN 层输出的节点嵌入表示, $P(i)$ 为样本 z_i 的正例样本集合, $N(i)$ 为样本 z_i 的负例样本集合, 本文将同一批次内除了正例样本之外的都视为负例, $\text{sim}(z_i, z_i^+)$ 计算正样本对之间的余弦相似度。

$$L_c(h, r, t) = a_h CL(h, h^+) + a_t CL(t, t^+) + a_{tr} CL(tr^T, (tr^T)^+) + a_{hr} CL(hr, (hr)^+) \quad (4-12)$$

$$CL(z_i, z_i^+) = \frac{-\sum_{z_i^+ \in P(i)} \log \frac{e^{\frac{\text{sim}(z_i, z_i^+)}{t}}}{\sum_{z_i^- \in N(i)} e^{\frac{\text{sim}(z_i, z_i^-)}{t}}}}{|P(i)|} \quad (4-13)$$

4.3.5 解码器模块

本文将编码器输出的实体关系嵌入表示送入解码器，使用 QuatE 模型作为评分函数，计算预测三元组的置信度分数。评分函数如式（4-14）所示。

$$f(h, r, t) = (v_h^Q \otimes v_r^{\triangleleft, Q}) \cdot v_t^Q \quad (4-14)$$

其中，上标 Q 代表四元数空间， v_h^Q 是头实体的嵌入表示， $v_r^{\triangleleft, Q}$ 代表对四元数空间中的关系嵌入表示进行规范化处理， v_t^Q 是尾实体的嵌入表示， $\otimes$ 代表四元数乘法， $\cdot$ 代表四元数内积。

本文使用二分类交叉熵损失函数衡量预测三元组和真实三元组之间的差距，如式（4-15）所示。式中的 T 代表三元组 (h, r, t) ， y_T 是预测三元组的标签，判断其是否为有效三元组， y_T 的计算公式如式（4-16）所示。式（4-15）中的 G 代表图谱中的所有三元组（即有效三元组）， G' 代表不存在于图谱中的三元组（即无效三元组）， p_T 是预测三元组的置信度分数， p_T 的计算公式如式（4-17）所示，sigmoid 函数如式（4-18）所示。

$$L_T(h, r, t) = - \sum_{T \in \{G \cup G'\}} y_T \log p_T + (1 - y_T) \log(1 - p_T) \quad (4-15)$$

$$y_{(h, r, t)} = \begin{cases} 1, & (h, r, t) \in G \\ 0, & (h, r, t) \in G' \end{cases} \quad (4-16)$$

$$p_{(h, r, t)} = \text{sigmoid}(f(h, r, t)) \quad (4-17)$$

$$\text{sigmoid}(x) = \frac{1}{1 + e^{-x}} \quad (4-18)$$

4.4 本章小结

本章提出一个融合外部信息 and 对比学习的 KLEC 模型，包括图转换模块、语义信息模块、编码器模块、对比学习模块、解码器模块这五个重要子模块。其中，使用语言模型 CyBERT 融合节点的语义信息，使用 DQGNN 作为解码器，融合节点的邻域信息，并在对比学习模块中构造了四种情况的正例对。KLEC 模型使用对比损失和二分类交叉熵损失函数来引导实体和关系的嵌入表示学习，进而实现图谱的链接预测（包括 APT 组织攻击偏好的预测）。

5 实验研究

针对 APT 组织攻击偏好的预测问题,本文首先构建了用于偏好预测的知识图谱,其关键步骤包括建立命名实体识别模型 CyBERT-BiLSTM-CRF 和使用数据增强技术;进而建立了一个融合外部信息和对比学习的图谱链接预测模型 KLEC。本章将通过实验研究本文方法的效果,回答以下四个研究问题:

(1) 与基于 BERT 的命名实体识别基线模型相比,本文所提出的 CyBERT-BiLSTM-CRF 模型对于 APT 威胁情报是否具有更好的实体识别效果?

(2) 本文所提出的数据增强技术能否缓解知识图谱 APT2K 数据规模小且稀疏的问题?

(3) 与传统的链接预测模型相比,本文所提出的 KLEC 模型是否具有更优的 APT 组织偏好预测性能?

(4) KLEC 模型所使用的语义信息模块和对比学习模块是否都是必要的?

5.1 实验设置

5.1.1 数据集

5.1.1.1 命名实体识别数据集

本文使用 APTNER 数据集来建立和验证 CyBERT-BiLSTM-CRF 模型的有效性。APTNER 数据集是目前网络安全领域中实体类型最为丰富的数据集之一。本文按照训练集:验证集:测试集=7:1.5:1.5 的比例划分该数据集。数据集中句子、Tokens、实体的具体数量分布如表 5-1 所示。

表 5-1 APTNER 数据集

数据集划分	句子数量	Tokens 数量	实体数量
训练集	7727	182363	30921
验证集	1725	38773	4550
测试集	1531	38998	4094

5.1.1.2 链接预测数据集

本文使用 APT2K 和 APT5K 作为链接预测数据集,验证融合实体类型信息的数据增强方法和链接预测模型 KLEC 的有效性。表 5-2 显示了图谱中实体、关系类型和三元组的总数,以及对三元组数据集按训练集:验证集:测试集=8:1:1 的比例分割后的子集元素数量。

表 5-2 APT2K、APT5K 数据集

数据集	实体	关系类型	三元组	训练集	验证集	测试集
APT2K	1455	10	1582	1266	158	158
APT5K	1476	11	4746	3798	474	474

为进一步验证本文提出的数据增强方法和链接预测模型 KLEC 在 APT 组织攻击偏好预测任务上的有效性, 本文从 APT2K (或 APT5K) 的测试集中筛选出“用于测试 APT 组织攻击偏好预测效果”的三元组集合 APTtest: 所筛选出的每个三元组均以 APT 组织为头实体, 以 target、exploit 或 use 为关系。最终, 筛选所得的 APTtest 测试集共包含 55 个三元组。值得注意的是, 无论从 APT2K 或者 APT5K 数据集中筛选上述三元组, 所得的 APTtest 集合都是相同的。这是因为 APT5K 只是在 APT2K 的基础上增加了以 hasType 为关系的三元组, 而这些三元组并不涉及要筛选的三元组。

总之, 本文首先使用 APT2K 或 APT5K 数据集训练链接预测模型 KLEC, 然后使用 APTtest 作为测试集验证 KLEC 模型的链接预测有效性, 这等价于验证该模型对 APT 组织攻击偏好预测任务的有效性。

5.1.2 评价指标

5.1.2.1 命名实体识别任务的评价指标

本文构建模型 CyBERT-BiLSTM-CRF 对 APT 威胁报告进行命名实体识别, 该模型本质上是一个多分类任务模型。本文在训练和评估此模型时, 首先计算模型对每个类别的二分类性能, 然后计算多分类的 macro 性能指标。本文所使用的二分类性能指标包括: 精确率、召回率、F1 分数, 定义如式 (5-1) 至式 (5-3) 所示。其中, TP 是实际为正样本且预测为正样本的数量, FP 是实际为负样本但被预测为正样本的数量, FN 是实际为正样本但被预测为负样本的数量。

(1) 精确率: 也叫查准率, 指所有被预测为正样本中实际为正样本的比例。

$$Precision = \frac{TP}{TP + FP} \quad (5-1)$$

(2) 召回率: 也叫查全率, 指实际正样本中被预测为正样本的比例。

$$Recall = \frac{TP}{TP + FN} \quad (5-2)$$

(3) F1 分数: 精确率和召回率的调和平均值, 同时兼顾了精确率和召回率。

$$F1 = \frac{2 * Precision * Recall}{Precision + Recall} \quad (5-3)$$

本文所使用的多分类 macro 性能指标是分别对每一类别的精确率、召回率、F1 分数分别加和平均而得，其计算公式如式 (5-4) 至式 (5-6) 所示，其中 n 为总类别数。

$$macro - Precision = \sum_{i=1}^n Precision_i \quad (5-4)$$

$$macro - Recall = \sum_{i=1}^n Recall_i \quad (5-5)$$

$$macro - F1 = \sum_{i=1}^n F1_i \quad (5-6)$$

5.1.2.2 链接预测任务的评价指标

本文构建 KLEC 模型对知识图谱 APT5K 进行链接预测。此链接预测任务可描述如下：给定 APT5K 中的一个头实体及其关系，KLEC 模型预测其对应的尾实体并报告相应的预测置信度分数。为评估此模型的链接预测性能，本文将模型的预测尾实体按照其对应的分数从高到低排序，得到每个预测尾实体的分数排名。本文使用所有预测尾实体的平均排名 (Mean Rank, MR)、平均倒数排名 (Mean Reciprocal Rank, MRR)、前 n 个命中率 Hits@ n (n 通常取值为 1、3、10) 等指标来评估模型的链接预测性能，详述如下：

(1) 平均排名 MR：计算准确实体在预测实体集合中的排名，对测试集中 N 个准确实体的排名求平均，如式 (5-7) 所示。该指标值越小代表模型的预测效果越好。

$$MR = \frac{1}{N} \sum_{i=1}^N rank_i = \frac{1}{N} (rank_1 + rank_2 + \dots + rank_N) \quad (5-7)$$

(2) 平均倒数排名：平均排名 MR 的结果容易受单个排名的影响，如果某个排名出现了较大偏差，则会导致该指标值受到较大的影响。因此本文使用“平均倒数排名”来限制单个排名对最终指标值的影响，其计算公式如式 (5-8) 所示。该指标值越大代表模型的预测效果越好。

$$MRR = \frac{1}{N} \sum_{i=1}^N \frac{1}{rank_i} = \frac{1}{N} \left(\frac{1}{rank_1} + \frac{1}{rank_2} + \dots + \frac{1}{rank_N} \right) \quad (5-8)$$

(3) 前 n 个命中率 Hits@ n ：代表排名在 n 以内的三元组占比，其计算公式如式 (5-9) 所示。其中 $sgn(x)$ 是指示函数，其定义如式 (2-37) 所示。Hits@ n 的值越大代表模型的预测效果越好。

$$Hits@n = \frac{1}{N} \sum_{i=1}^N sgn(rank_i < n) \quad (5-9)$$

5.1.3 实验环境

本章的实验在 Linux 操作系统上进行，实验的硬件环境使用 RTX 3090 独立显卡，软件环境使用 Python 编程语言和 Pytorch 开发框架。实验环境的详细配置如表 5-3 所示。

表 5-3 实验环境

配置项	参数
操作系统	Linux Ubuntu 18.04
CPU	Intel Xeon Gold 6330
CPU 内存	25GB
GPU	RTX 3090
GPU 显存	24GB
编程语言	Python 3.8
开发框架	Pytorch 1.8.1

5.2 研究问题一、命名实体识别模型 CyBERT-BiLSTM-CRF 的有效性

为了验证命名实体识别模型 CyBERT-BiLSTM-CRF 的有效性，本节使用数据集 APTNER 进行实验。作为对比的传统 BERT-BiLSTM-CRF^[73]模型使用最基础的 BERT 预训练，而本文的 CyBERT-BiLSTM-CRF 模型使用基于网络安全文本语料的 CyBERT 预训练，以上两种模型对数据集 APTNER 的命名实体识别结果如表 5-4 和图 5-1 所示，其中 BERT-BiLSTM-CRF 模型的结果引用自文献^[66]，同样在 APTNER 数据集基础上开展实验，且数据集划分相同，因此其实验结果具有可比较性。表 5-4 中的加粗部分为更优的实验结果。

表 5-4 APTNER 数据集上的实验结果（单位：%）

模型	macro-Precision	macro-Recall	macro-F1
BERT-BiLSTM-CRF ^[66]	82.99	81.64	82.31
CyBERT-BiLSTM-CRF	83.62	82.95	83.28

从表 5-4 和图 5-1 可看出，相较于传统的 BERT-BiLSTM-CRF 模型，本文的 CyBERT-BiLSTM-CRF 模型能提升命名实体识别的性能，其中精确率提升 0.63%，召回率提升 1.31%，

F1 分数提升 0.97%。这种性能提升的原因在于，CyBERT-BiLSTM-CRF 模型使用了网络安全领域的预训练语言模型 CyBERT，从而为 APT 威胁报告文本学到了更好的特征表示。




图 5-1 数据集 APTNER 的实验结果

5.3 研究问题二、融合实体类型信息的数据增强方法有效性

本文构建的知识图谱 APT2K 存在数据规模较小且稀疏的问题，这些问题会影响链接预测效果。因此，本文引入了一种融合实体类型信息的数据增强方法，增大图谱的数据规模并缓解其稀疏性。为了验证这种数据增强方法的有效性，本节分别在 APT2K 和 APT5K 数据集上运行本文的链接预测模型 KLEC，并将训练好的 KLEC 模型分别称为 KLEC-2K 模型和 KLEC 模型。这两个模型在测试集上的链接预测结果如表 5-5 和图 5-2 所示。在表 5-5 中，加粗部分为最佳实验结果，“↓”代表该指标值越小越好。

表 5-5 KLEC-2K 和 KLEC 模型的链接预测结果

模型	Hits@10	Hits@3	Hits@1	MRR	MR↓
KLEC-2K	0.399	0.320	0.263	0.310	395.60
KLEC	0.669	0.608	0.572	0.601	212.95




图 5-2 KLEC-2K 和 KLEC-5K 模型的链接预测效果对比图

从表 5-5 和图 5-2 可以看出, KLEC-5K 模型在各个评价指标上明显优于 KLEC-2K 模型。其中, Hits@1 指标提升最为明显, 提升了 0.309; Hits@10 指标提升最少, 提升了 0.270。这说明了融合实体类型信息的数据增强方法对于提高链接预测效果有显著作用。

为了验证这种数据增强方法在 APT 组织攻击偏好预测任务上的有效性, 本文分别使用 KLEC-2K、KLEC-5K 模型在同一测试集 APTtest 上进行偏好预测评估, 结果如图 5-3 所示。从表 5-6 和图 5-3 可以看出, 模型 KLEC 在各个评价指标上均优于模型 KLEC-2K。这说明了融合实体类型信息的数据增强方法能够有效提高 APT 组织攻击偏好预测效果。

表 5-6 APT 组织攻击偏好预测结果

模型	Hits@10	Hits@3	Hits@1	MRR	MR↓
KLEC-2K	0.258	0.231	0.169	0.214	451.84
KLEC	0.453	0.417	0.394	0.403	302.74




图 5-3 APT 组织攻击偏好预测结果

为进一步比较训练以上两个模型所用的数据集 APT2K 和 APT5K 在规模和稀疏性上的差异, 本文使用图谱中三元组数量代表数据集的规模, 使用实体节点的平均出度 (Average Out Degree) 表示图谱的稀疏性^[74]。实体节点的平均出度代表图谱中每个节点平均与多少个邻居节点相连, 平均出度越大, 则代表知识图谱的稀疏程度越低, 其计算方式如公式 (5-4) 所示。其中, $\bar{D}_{out}$ 是知识图谱中所有实体的平均出度, N 是实体数量, ent_i 是第 i 个实体, D_{out} 计算某个实体的出度。

$$\bar{D}_{out} = \frac{1}{N} \sum_{i=1}^N D_{out}(ent_i) \quad (5-4)$$

表 5-7 和图 5-4 显示了 APT2K 和 APT5K 数据集的规模和平均出度。由表 5-6 和图 5-4 可以看出,与 APT2K 相比,APT5K 的三元组数量从 1582 增长到 4746,共增长 3164 个,明显了增大图谱的数据规模。此外,关系数量从 1941 增长为 3416,共增长 1475 条;实体数量从 1455 增长到 1476,共增长 21 个,APT5K 的节点平均出度从 1.35 增长到 2.31,共增长 0.96,在一定程度上缓解了知识图谱的稀疏性问题。

表 5-7 数据集 APT2K 和 APT5K 的数据规模和平均出度

数据集	三元组数量	关系数量	实体数量	平均出度
APT2K	1582	1961	1455	1.35
APT5K	4746	3416	1476	2.31




图 5-4 两个训练集规模和平均出度的对比

5.4 研究问题三、链接预测模型 KLEC 的有效性

为了验证 KLEC 模型的有效性,本文将 KLEC 模型与 6 种基线链接预测模型在 APT5K 数据集上进行对比实验,包括传统链接预测模型(TransE^[27]、ComplEx^[40]、ConvE^[42]、DualE^[36])和融合外部信息的链接预测模型(CompGCN^[55]、AutoETER^[50])。其中,KLEC 模型在 APT5K 数据集上实验的最优超参数如下:语义信息模块中 tokenizer 的截断长度为 16;批量大小为 1024,学习率为 1e-4,节点嵌入维度为 200;对比学习模块中,对比损失函数的超参数权重为 $a_h=0$, $a_t=2$, $a_{tr}=0$, $a_{hr}=0$, 温度超参数 $t=0.9$ 。为方便得到各个基线模型的预测结果,本文使用 NeuralKG 框架^[75]复现部分基线模型(TransE^[27]、ComplEx^[40]、ConvE^[42]、DualE^[36]和 CompGCN^[55]),而 AutoETER 模型^[50]则基于其源码复现。NeuralKG 框架不提供 MR 指标值,本文在表 5-8 中列出比 MR 指标更加鲁棒的 MRR 指标值。以上各模型的链接预测

结果如表 5-8 和图 5-5 所示，加粗部分为最优实验结果，下划线部分为次优实验结果，“↓”代表该指标越小越好。

表 5-8 各模型在 APT5K 数据集上的实验效果

模型	Hits@10	Hits@3	Hits@1	MRR	MR↓
TransE ^[27]	0.462	0.387	0.016	0.208	-
ComplEx ^[40]	0.466	0.437	0.406	0.427	-
ConvE ^[42]	0.522	0.437	0.392	0.432	-
DualE ^[42]	0.534	0.441	0.408	0.450	-
CompGCN ^[42]	0.542	0.438	0.412	0.443	-
AutoETER ^[42]	<u>0.611</u>	<u>0.532</u>	<u>0.442</u>	<u>0.499</u>	137.75
KLEC(Ours)	0.669	0.608	0.572	0.601	212.95




图 5-5 各模型在数据集 APT5K 上的实验结果

从表 5-8 和图 5-5 可以看出，在对图谱 APT5K 的链接预测任务上，融合外部信息的链接预测模型的性能优于传统的链接预测模型。相较于只关注独立三元组的传统链接预测模型，融合外部信息的链接预测模型可以获得更全面的特征信息，包括邻域信息、实体类型信息等，因此具有更好的预测准确度。相较于基线模型，本文所提出的 KLEC 模型在各个

评价指标上都有所提升。相较于次优结果，KLEC 模型在 Hits@10 指标上提升了 0.054，在 Hits@3 指标上提升了 0.076，在 Hits@1 指标上提升了 0.130，在 MRR 指标上提升了 0.102。这说明本文提出的 KLEC 模型可以有效提升链接预测效果。

表 5-9 各模型的 APT 组织攻击偏好预测效果

模型	Hits@10	Hits@3	Hits@1	MRR	MR↓
TransE ^[27]	0.342	0.302	0.276	0.264	-
ComplEx ^[27]	0.357	0.328	0.294	0.331	-
ConvE ^[27]	0.391	0.316	0.304	0.347	-
DualE ^[27]	0.412	0.403	0.384	0.392	-
CompGCN ^[27]	0.431	0.402	<u>0.390</u>	0.386	-
AutoETER ^[27]	<u>0.449</u>	<u>0.408</u>	0.381	<u>0.395</u>	369.29
KLEC(Ours)	0.453	0.417	0.394	0.403	302.74




图 5-6 各模型的 APT 组织攻击偏好预测效果

为了进一步验证 KLEC 模型在 APT 组织攻击偏好预测任务上的有效性，本文在使用 APT5K 数据集训练好的各模型基础上，使用攻击偏好预测任务的测试集 APTtest 进行预测评估，其结果如表 5-9 和图 5-6 所示，加粗部分为最优实验结果，下划线部分为次优实验

结果，“↓”代表该指标越小越好。从表 5-9 和图 5-6 可以看出，在 APT 组织攻击偏好预测任务上，相较于次优结果，KLEC 模型在 Hits@10 指标上提升了 0.004，在 Hits@3 指标上提升了 0.009，在 Hits@1 指标上提升了 0.004，在 MRR 指标上提升了 0.008。可见，与基线模型相比，本文提出的链接预测模型 KLEC 能够有效提高 APT 组织攻击偏好预测效果。

5.5 研究问题四、KLEC 模型中语义信息和对比学习模块的必要性

为了验证 KLEC 模型中语义信息模块和对比学习模块的必要性，本节对 KLEC 模型中这两个关键模块进行消融实验。实验结果如表 5-9、图 5-7 和图 5-8 所示，加粗部分为最佳实验结果，“↓”代表该指标越小越好。其中，None-KLEC 代表既不加语义信息模块也不加对比学习模块的 KLEC 模型，语义-KLEC 代表不加对比学习模块的 KLEC 模型，对比-KLEC 代表不加语义信息模块的 KLEC 模型，KLEC 代表本文所提出的 KLEC 模型。

表 5-10 消融实验结果

模型	Hits@10	Hits@3	Hits@1	MRR	MR↓
None-KLEC	0.538	0.520	0.502	0.515	407.37
语义-KLEC	0.597	0.553	0.358	0.470	289.11
对比-KLEC	0.626	0.581	0.543	0.537	262.84
KLEC (Ours)	0.669	0.608	0.572	0.601	212.95




图 5-7 数据集 APT5K 上 KLEC 的消融实验结果（一）




图 5-8 数据集 APT5K 上 KLEC 的消融实验结果（二）

从表 5-10、图 5-7 和图 5-8 可以看出，无论是消融语义信息模块还是对比学习模块，都会导致链接预测模型 KLEC 性能下降。相较于 None-KLEC 模型，语义-KLEC 模型在 Hits@10、Hits@3 指标上有所提升，但在 Hits@1 和 MRR、MR 指标有所下降，而对比-KLEC 模型则在各个指标上都稳定提升。此外，相较于语义-KLEC 模型，对比-KLEC 模型在各个指标上的提升更为明显，具体为：在 Hit@10 指标上提升了 0.029，在 Hit@3 指标上提升了 0.028，在 Hit@1 指标上提升了 0.185，在 MRR 指标上提升了 0.067，在 MR 指标上提升了 26.27。这说明了对比学习模块对于 KLEC 模型来说具有更大贡献，且对于模型性能的提升较为稳定。

为了进一步验证 KLEC 模型在 APT 组织攻击偏好预测任务上的有效性，本文在使用 APT5K 数据集训练好的各模型基础上，使用测试集 APTtest 进行预测效果评估，其结果如表 5-11、图 5-9 和图 5-10 所示。

表 5-11 消融实验结果

模型	Hits@10	Hits@3	Hits@1	MRR	MR↓
None-KLEC	0.374	0.365	0.311	0.335	436.12
语义-KLEC	0.412	0.384	0.213	0.257	412.75
对比-KLEC	0.425	0.401	0.376	0.391	387.24
KLEC (Ours)	0.453	0.417	0.394	0.403	302.74




图 5-9 测试集 APTtest 上的 KLEC 消融实验结果 (一)




图 5-10 测试集 APTtest 上的 KLEC 消融实验结果 (二)

从表 5-11、图 5-9 和图 5-10 可以看出，在 APT 组织攻击偏好预测任务上，无论是消融语义信息模块还是对比学习模块，都会导致 KLEC 模型性能下降。相较于 None-KLEC 模型，语义-KLEC 模型在 Hits@10、Hits@3 指标上有所提升，但在 Hits@1、MRR 和 MR 指标有所下降，而对比-KLEC 模型则在各个指标上都有所提升。此外，相较于语义-KLEC 模型，对比-KLEC 模型在各个指标上的提升更为明显。具体为：在 Hit@10 指标上提升了 0.013，在 Hit@3 指标上提升了 0.017，在 Hit@1 指标上提升了 0.163，在 MRR 指标上提升

了 0.134, 在 MR 指标上降低了 25.51。这说明对比学习模块对于 APT 组织攻击偏好预测性能提升的贡献更大且稳定。

5.6 本章小结

本章通过实验验证了命名实体识别模型 CyBERT-BiLSTM-CRF 在 APT 威胁情报实体识别上的有效性, 并验证了融合实体类型信息的数据增强方法、链接预测模型 KLEC 在链接预测任务以及具体的 APT 组织攻击偏好预测任务上的有效性。最后, 通过消融实验进一步验证了 KLEC 模型中语义信息和对比学习模块的必要性。

6 总结展望

6.1 工作总结

近些年来,全球范围内网络安全事件频发,具有国家和组织背景的 APT 攻击正在威胁着人们的财产安全。每个 APT 组织具有一定的攻击偏好,如目标攻击国家或地区、攻击领域和平台,然而现有 APT 威胁情报中对于 APT 组织攻击偏好的分析尚不完备。因此,本文围绕 APT 组织攻击偏好预测展开研究,主要工作如下:

(1)以 APT 威胁情报为数据源,构建面向 APT 组织攻击偏好预测的知识图谱 APT5K。其构建步骤如下:首先建立于 APT 组织攻击偏好相关且具有细粒度实体类型的本体,建立 CyBERT-BiLSTM-CRF 模型自动识别命名实体,并人工标注实体间关系,进而使用融合实体类型信息的数据增强方法,建立了知识图谱 APT5K。最后,通过对比实验验证 CyBERT-BiLSTM-CRF 模型对于自动识别 APT 组织攻击偏好相关实体的有效性、融合实体类型信息的数据增强方法对于提升链接预测性能的有效性。

(2)提出了一个融合外部信息 and 对比学习的链接预测模型 KLEC,用于预测图谱 APT5K 中缺失的 APT 组织攻击偏好。首先通过图转换将知识图谱转化为包含关系节点的图,计算邻接矩阵;然后使用语言模型 CyBERT 生成实体和关系节点的语义表示,并使用对偶四元数图神经网络 DQGNN 作为编码器,对节点的语义信息和邻域信息进行融合;进而使用基于三元组的对比学习来学习实体和关系节点的嵌入表示。最后,通过对比实验验证了 KLEC 模型在 APT 组织攻击偏好预测任务上的有效性。

6.2 未来展望

本文构建了一个面向 APT 组织攻击偏好的网络安全知识图谱,并提出了融合外部信息 and 对比学习的链接预测模型 KLEC,能有效预测 APT 组织的攻击偏好,但仍存在以下不足:

(1)本文采用半自动化方法构建知识图谱,使用人工方法来标注实体对之间的关系,但这对于构建大型知识图谱来说是比较低效的。未来可以考虑引入关系抽取方法,实现实体关系的自动抽取,以构建面向海量安全数据的知识图谱。

(2)本文使用的是英文的 APT 威胁报告,未来还可以使用中文的威胁报告来构建知识图谱。

参考文献

- [1] 张帅. 对 APT 攻击的检测与防御[J]. 信息安全与技术, 2011(9): 125-127.
- [2] 全球高级持续性威胁 (APT) 2022 年度报告[EB/OL]. (2023-03-14). <https://mp.weixin.qq.com/s/hqSmZa3cQETwOtcH-BjszA>.
- [3] Liu K, Wang F, Ding Z, et al. A review of knowledge graph application scenarios in cyber security[J]. arXiv:2204.04769, 2022.
- [4] Singhal A. Introducing the Knowledge Graph: things, not strings[EB/OL]//Google. (2012-05-16). <https://blog.google/products/search/introducing-knowledge-graph-things-not/>.
- [5] Beaune P. Semantic Web roadmap[J]. 1998.
- [6] 黄恒琪, 于娟, 廖晓, 等. 知识图谱研究综述[J]. 计算机系统应用, 2019, 28(6): 1-12.
- [7] Bizer C, Lehmann J, Kobilarov G, et al. DBpedia-A crystallization point for the Web of Data[J]. Journal of Web Semantics, 2009, 7(3): 154-165.
- [8] Bollacker K, Cook R, Tufts P. Freebase: a shared database of structured general human knowledge[C]//Proceedings of the AAAI Conference on Artificial Intelligence: Vol. 2. 2007: 1962-1963.
- [9] Huang M. YAGO: A Core of Semantic Knowledge Unifying WordNet and Wikipedia[C]//Proceedings of the 16th International world wide web conference, WWW. 2007: 697-706.
- [10] Speer R, Chin J, Havasi C. ConceptNet 5.5: An Open Multilingual Graph of General Knowledge[C]//Proceedings of the AAAI Conference on Artificial Intelligence: Vol. 31. 2017: 4444-4451.
- [11] Carlson A, Betteridge J, Kisiel B, et al. Toward an Architecture for Never-Ending Language Learning[C]//Proceedings of the AAAI Conference on Artificial Intelligence: Vol. 24. 2010: 1306-1313.
- [12] 刘烨宸, 李华昱. 领域知识图谱研究综述[J]. 计算机系统应用, 2020, 29(6): 1-12.
- [13] Auer M. Lack of experts in cyber security[EB/OL]//ThreatQuotient. (2020-07-14). <https://www.threatq.com/lack-of-experts-in-cyber-security/>.
- [14] Iannacone M, Bohn S, Nakamura G, et al. Developing an Ontology for Cyber Security Knowledge Graphs[C]//Proceedings of the 10th Annual Cyber and Information Security Research Conference. 2015: 1-4.
- [15] Syed Z, Padia A, Finin T, et al. UCO: A Unified Cybersecurity Ontology[C]//Proceedings of the AAAI Workshop on Artificial Intelligence for Cyber Security. 2016.

-
- [16] Rastogi N, Dutta S, Zaki M J, et al. MALOnt: An Ontology for Malware Threat Intelligence[C]//Deployable Machine Learning for Security Defense. 2020: 28-44.
- [17] Kiesling E, Ekelhart A, Kurniawan K, et al. The SEPSES Knowledge Graph: An Integrated Resource for Cybersecurity[C]//Proceedings of International Workshop on the Semantic Web. 2019: 198-214.
- [18] Sarhan I, Spruit M. Open-CyKG: An Open Cyber Threat Intelligence Knowledge Graph[J]. Knowledge-Based Systems, 2021, 233: 107524.
- [19] Rastogi N, Dutta S, Zaki M J, et al. TINKER: A framework for Open source Cyber threat Intelligence[C]//Proceedings of IEEE International Conference on Trust, Security and Privacy in Computing and Communications (TrustCom). 2022: 1569-1574.
- [20] Mittal S, Das P K, Mulwad V, et al. CyberTwitter: Using Twitter to generate alerts for cybersecurity threats and vulnerabilities[C]//Proceedings of IEEE/ACM International Conference on Advances in Social Networks Analysis and Mining (ASONAM). 2016: 860-867.
- [21] Rass S, König S, Schauer S. Defending Against Advanced Persistent Threats Using Game-Theory[J]. PLOS ONE, 2017, 12(1): e0168675.
- [22] Zhao J, Liu X, Yan Q, et al. Automatically predicting cyber attack preference with attributed heterogeneous attention networks and transductive learning[J]. Computers & Security, 2021, 102: 1-13.
- [23] Moon D, Im H, Lee J D, et al. MLDS: Multi-Layer Defense System for Preventing Advanced Persistent Threats[J]. Symmetry, 2014, 6(4): 997-1010.
- [24] Ren Y, Xiao Y, Zhou Y, et al. CSKG4APT: A Cybersecurity Knowledge Graph for Advanced Persistent Threat Organization Attribution[J]. IEEE Transactions on Knowledge and Data Engineering, 2022, 35(6): 1-15.
- [25] 徐有为, 张宏军, 程恺, 等. 知识图谱嵌入研究综述[J]. 计算机工程与应用, 2022, 58(9): 30-50.
- [26] 张天成, 田雪, 孙相会, 等. 知识图谱嵌入技术研究综述[J]. 软件学报, 2023, 34(1): 277-311.
- [27] Bordes A, Usunier N, Garcia-Duran A, et al. Translating embeddings for modeling multi-relational data[C]//Proceedings of the 26th International Conference on Neural Information Processing Systems: Vol. 2. 2013: 2787-2795.
- [28] Mikolov T, Chen K, Corrado G, et al. Efficient Estimation of Word Representations in Vector Space[J]. arXiv:1301.3781, 2013.

-
- [29] Wang Z, Zhang J, Feng J, et al. Knowledge graph embedding by translating on hyperplanes[C]//Proceedings of the AAAI conference on artificial intelligence: Vol. 28. 2014: 1112-1119.
- [30] Lin Y, Liu Z, Sun M, et al. Learning entity and relation embeddings for knowledge graph completion[C]//Proceedings of the AAAI conference on artificial intelligence: Vol. 29. 2015: 2181-2187.
- [31] Ji G, He S, Xu L, et al. Knowledge graph embedding via dynamic mapping matrix [C]//Proceedings of the 53rd Annual Meeting of the Association for Computational Linguistics and the 7th International Joint Conference on Natural Language Processing: Vol. 1. 2015: 687-696.
- [32] Ji G, Liu K, He S, et al. Knowledge graph completion with adaptive sparse transfer matrix[C]//Proceedings of the AAAI Conference on Artificial Intelligence: Vol. 30. 2016: 985-991.
- [33] Sun Z, Deng Z H, Nie J Y, et al. Rotate: Knowledge graph embedding by relational rotation in complex space[J]. arXiv:1902.10197, 2019.
- [34] ZHANG S, Tay Y, Yao L, et al. Quaternion Knowledge Graph Embeddings[C]//Proceedings of the 33rd International Conference on Neural Information Processing Systems. 2019: 2735-2745.
- [35] Zhang Z, Cai J, Zhang Y, et al. Learning hierarchy-aware knowledge graph embeddings for link prediction[C]//Proceedings of the AAAI conference on artificial intelligence: Vol. 34. 2020: 3065-3072.
- [36] Cao Z, Xu Q, Yang Z, et al. Dual quaternion knowledge graph embeddings[C]//Proceedings of the AAAI conference on artificial intelligence: Vol. 35. 2021: 6894-6902.
- [37] Nickel M, Tresch V, Kriegel H P. A three-way model for collective learning on multi-relational data[C]//Proceedings of the 28th International Conference on International Conference on Machine Learning: Vol. 11. 2011: 809-816.
- [38] Balažević I, Allen C, Hospedales T M. TuckER: Tensor Factorization for Knowledge Graph Completion[C]//Proceedings of the 2019 Conference on Empirical Methods in Natural Language Processing and the 9th International Joint Conference on Natural Language Processing. 2019: 5184-5193.
- [39] Yang B, Yih W tau, He X, et al. Embedding entities and relations for learning and inference in knowledge bases[J]. arXiv:1412.6575, 2014.

-
- [40] Trouillon T, Welbl J, Riedel S, et al. Complex Embeddings for Simple Link Prediction[C]//Proceedings of the 33rd International Conference on Machine Learning. PMLR, 2016: 2071-2080.
- [41] Kazemi S M, Poole D. SimpleE Embedding for Link Prediction in Knowledge Graphs[C]//Proceedings of the 32nd International Conference on Neural Information Processing Systems: Vol. 31. 2018: 4289-4300.
- [42] Dettmers T, Minervini P, Stenetorp P, et al. Convolutional 2d knowledge graph embeddings[C]//Proceedings of the AAAI conference on artificial intelligence: Vol. 32. 2018: 1811-1818.
- [43] Nguyen D Q, Nguyen T D, Nguyen D Q, et al. A novel embedding model for knowledge base completion based on convolutional neural network[J]. arXiv:1712.02121, 2017.
- [44] Chen Y, Wang J. A Review Focusing on Knowledge Graph Embedding Methods Exploiting External Information[C]//Advances in Natural Computation, Fuzzy Systems and Knowledge Discovery: Vol. 153. 2023: 869-887.
- [45] Xie R, Liu Z, Jia J, et al. Representation Learning of Knowledge Graphs with Entity Descriptions[C]//Proceedings of the AAAI Conference on Artificial Intelligence: Vol. 30. 2016: 2659-2665.
- [46] Lin Y, Liu Z, Luan H, et al. Modeling relation paths for representation learning of knowledge bases[J]. arXiv:1506.00379, 2015.
- [47] Alberto G D, Antoine B, Nicolas U. Composing Relationships with Translations[C]//Proceedings of the 2015 Conference on Empirical Methods in Natural Language Processing. 286-290.
- [48] Xie R, Liu Z, Sun M. Representation learning of knowledge graphs with hierarchical types.[C]//Proceedings of the 25th International Joint Conference on Artificial Intelligence. 2016: 2965-2971.
- [49] Jain P, Kumar P, Chakrabarti S. Type-sensitive knowledge base inference without explicit type supervision[C]//Proceedings of the 56th Annual Meeting of the Association for Computational Linguistics: Vol. 2. 2018: 75-80.
- [50] Niu G, Li B, Zhang Y, et al. AutoETER: Automated entity type representation for knowledge graph embedding[J]. arXiv:2009.12030, 2020.
- [51] Ye Z, Kumar Y J, Sing G O, et al. A comprehensive survey of graph neural networks for knowledge graphs[J]. IEEE Access, 2022, 10: 75729-75741.

- [52] Kipf T N, Welling M. Semi-Supervised Classification with Graph Convolutional Networks[J]. arXiv:1609.02907, 2017.
- [53] Schlichtkrull M, Kipf T N, Bloem P, et al. Modeling relational data with graph convolutional networks[C]//The Semantic Web: 15th International Conference, ESWC 2018: Vol. 10843. 2018: 593-607.
- [54] Ye R, Li X, Fang Y, et al. A Vectorized Relational Graph Convolutional Network for Multi-Relational Network Alignment[C]//Proceedings of the 28th International Joint Conference on Artificial Intelligence. 2019: 4135-4141.
- [55] Vashishth S, Sanyal S, Nitin V, et al. Composition-based Multi-Relational Graph Convolutional Networks[J]. arXiv:1911.03082, 2020.
- [56] Nickel M, Rosasco L, Poggio T. Holographic Embeddings of Knowledge Graphs[C]//Proceedings of the AAAI Conference on Artificial Intelligence: Vol. 30. 2016: 1955-1961.
- [57] Nguyen D Q, Nguyen T D, Phung D. Quaternion Graph Neural Networks[C]//Proceedings of the 13th Asian Conference on Machine Learning. 2021: 236-251.
- [58] Devlin J, Chang M W, Lee K, et al. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding[J]. arXiv:1810.04805, 2019.
- [59] Ranade P, Piplai A, Joshi A, et al. CyBERT: Contextualized Embeddings for the Cybersecurity Domain[C]//2021 IEEE International Conference on Big Data (Big Data). 2021: 3334-3342.
- [60] Graves A. Long Short-Term Memory[M]//Graves A. Supervised Sequence Labelling with Recurrent Neural Networks. Berlin, Heidelberg: Springer, 2012: 37-45.
- [61] Graves A, Schmidhuber J. Framewise phoneme classification with bidirectional LSTM networks[C]//Proceedings of 2005 IEEE International Joint Conference on Neural Networks: Vol. 4. 2005: 2047-2052.
- [62] Lafferty J, McCallum A, Pereira F. Conditional Random Fields: Probabilistic Models for Segmenting and Labeling Sequence Data[C]//Proceedings of the 18th International Conference on Machine Learning. 2001: 282-289.
- [63] Zhou J, Cui G, Hu S, et al. Graph neural networks: A review of methods and applications[J]. AI Open, 2020, 1: 57-81.
- [64] Hamilton W, Ying Z, Leskovec J. Inductive Representation Learning on Large Graphs[C]//Proceedings of the 31st International Conference on Neural Information Processing Systems: Vol. 30. Curran Associates, Inc., 2017: 1025-1035.

-
- [65] Jaiswal A, Babu A R, Zadeh M Z, et al. A Survey on Contrastive Self-Supervised Learning[J]. Technologies, 2020, 9(1): 4182-4192.
- [66] Wang X, He S, Xiong Z, et al. APTNER: A Specific Dataset for NER Missions in Cyber Threat Intelligence Field[C]//2022 IEEE 25th International Conference on Computer Supported Cooperative Work in Design. 2022: 1233-1238.
- [67] kbandla. aptnotes/data: APTnotes data[EB/OL]. [2023-03-30]. <https://github.com/aptnotes/data>.
- [68] kbandla. aptnotes/tools: Tools to interact with APTnotes reporting/index.[EB/OL]. [2023-03-30]. <https://github.com/aptnotes/tools>.
- [69] Nakayama H, Kubo T, Kamura J, et al. doccano/doccano: Open source annotation tool for machine learning practitioners.[EB/OL]. [2023-03-30]. <https://github.com/doccano/doccano>.
- [70] Nguyen D Q, Tong V, Phung D, et al. Node Co-occurrence based Graph Neural Networks for Knowledge Graph Link Prediction[C]//Proceedings of the 15th ACM International Conference on Web Search and Data Mining. 2022: 1589-1592.
- [71] Luo Z, Xu W, Liu W, et al. KGE-CL: Contrastive Learning of Tensor Decomposition Based Knowledge Graph Embeddings[J]. arXiv:2112.04871, 2022.
- [72] 白洁仙, 剧雷鸣. 基于四元数图神经网络的知识图谱嵌入[J]. 重庆邮电大学学报(自然科学版), 2023, 35(1): 119-125.
- [73] 谢腾, 杨俊安, 刘辉. 基于 BERT-BiLSTM-CRF 模型的中文实体识别[J]. 计算机系统应用, 2020, 29(7): 48-55.
- [74] Lv X, Han X, Hou L, et al. Dynamic Anticipation and Completion for Multi-Hop Reasoning over Sparse Knowledge Graph[J]. arXiv:2010.01899, 2020.
- [75] Zhang W, Chen X, Yao Z, et al. NeuralKG: An Open Source Library for Diverse Representation Learning of Knowledge Graphs[C]//Proceedings of the 45th International ACM SIGIR Conference on Research and Development in Information Retrieval. 2022: 3323-3328.